HarnessRSI · 精选 Reel · **证伪类** · F1 诊断自改进

自演化代理的收益，不一定来自它读到的经验内容

对 4 个冻结骨干的自演化框架做经验内容干预：扰动原始轨迹（raw）会明显降分；把压缩经验（condensed）换成乱码、无关文本，聚合成功率却几乎不变——即使它是唯一提供的经验。

arXiv:2601.22436v3（2026-06-12）· Zhao, Wang, Zhang, Deng, Zhao, Che, Qin, Liu · 哈工大 / SMU · github.com/Dreamcatcher0622/Faithfulness

被检验的默认假设

“加上记忆分数变高” ⇒ “代理在按记忆内容做决策”

论文定义 experience faithfulness：扰动所给经验后，代理行为是否随之因果改变（§1）

对 condensed 经验不成立

1 观测矩阵：扰动后成功率是否下降

	整体移除	Empty 去内容	Shuffle 乱序	Irrelevant 换无关	Corrupt 改关键词	Filler 换乱码
raw 原始轨迹 ExpeL · DC · G-Memory	明显下降	明显下降	部分下降 随设置而异	明显下降	未设	未设
condensed 摘要 与 raw 同时提供	轻微	近乎不变	未设	近乎不变	近乎不变	近乎不变
condensed-only ReasoningBank · WebArena	一致下降	弱敏感	未设	轻微或略升	轻微或略升	轻微或略升

成功率明显下降＝行为依赖内容　几乎不变＝内容未被因果使用　该类经验未设此干预

关键一行是第三行：**拿掉整块摘要会降分，但把摘要内容换成乱码不会**——收益可能来自“有一块文本”这一格式/位置信号，而非摘要语义（§4.2 作者解读）。

示意：按原文 §4.1–4.3 与附录 D.3–D.5 的文字结论归纳，**非原图数值**；知识密集任务（GPQA、MMLU-Pro、FEVER）上两类经验敏感度接近，不在此矩阵的概括内。

2 研究动作：只动内容，不动外壳

同一道 HotpotQA 题的经验槽位（附录 Table 3，节选）：

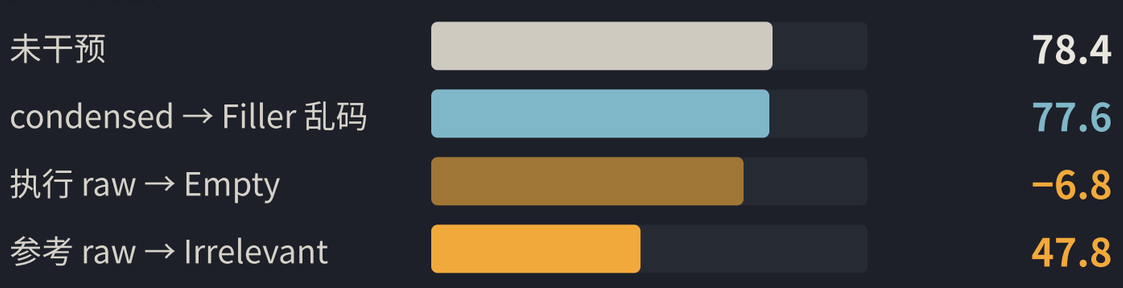
- **raw 原文** Action 1: `Search[Fleetwood Sheppard]` … Action 3: `Finish[…]`
- **Shuffle** 同样的步骤，顺序打乱
- **cond 原文** “遇到同名歧义时，按精确名称再查一次以核实身份……”
- **Corrupt** “遇到 conflicting `[CORRUPTED_561]` ambiguous… `[ERROR_INFO]`”
- **Irrelevant** “Literature contains various genres and styles.”
- **Filler** `1. … $$$ ###` `2. *** … ***`
- **Empty** 只保留“以下是你在类似任务上积累的经验:”

范围 框架：ExpeL（离线）、Dynamic Cheatsheet、ReasoningBank（在线）、G-Memory（多代理）· 骨干：GPT-4o(-mini)、GPT-5.2、Gemini-2.5-Flash / 3-Pro、Claude-Sonnet-4.6、Qwen3 1.7B–235B · 9 个基准（问答、数学、ALFWorld、WebArena、WebShop）· 骨干全程冻结

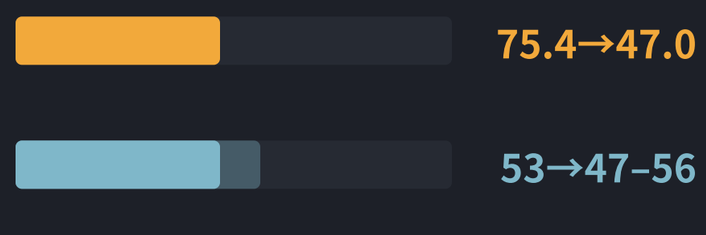
3 同条件对照：一个多代理设置里的实际数字

据原文附录 D.5 文字数值重绘 · 单次报告，无方差

G-Memory · Qwen3-235B-A22B · ALFWorld 同一框架、同一骨干、同一环境，仅替换某一类经验



同一模式在更强骨干上复现（附录 D.3 / D.5）



原文称 raw 干预在同一设置下“波动大得多”，但正文未给逐项数值。另：Qwen3 1.7B→32B 放大骨干、而 ExpeL 摘要由骨干自己生成，condensed 仍不敏感（§4.4）——不能只归因于“摘要写得差”。

4 反证边界：raw 也会失灵

ExpeL · Qwen3-32B · 每基准抽 100 题 · 精确匹配（Table 2）

条件	2WikiMultiHopQA	Musique
未干预	**62**	**48**
raw 三种干预	63–65	43–47
condensed 四种干预	63–65	44–47

任务可由预训练先验解决时，**两类经验都不再产生可见的因果作用**；作者据此把任务类型列为第三个成因（§5.3）。

5 加了摘要反而失败的样例如何分布

ReasoningBank · WebArena · 仅统计“去掉 condensed 成功、加上后失败”的样例（Table 1）

偏离任务目标
Gemini-2.5-Flash 18.8–45.2%
Qwen3-32B 61.9–79.2%
Qwen3-14B 60.9–86.7%

套用不符的先验
按摘要假定页面布局/元素，不看当前页面；Gemini 27.3–33.3%

过早下结论
摘要说“应该存在”便跳过核验；Gemini 22.6–50.0%

此外作者用逐层梯度归因（IG 近似）观察到 condensed 段贡献普遍偏低、当前轨迹在深层占主导（§5.2）——**这是相关性证据，不是独立因果检验**。

结论边界

- 未报告方差、种子或置信区间；“近乎不变”是对聚合成功率的描述，不等于动作序列相同。
- 收益与忠实度被拆开：condensed 仍可能“有用”（移除会降分），只是用的不是它的语义。
- 各框架沿用官方设置，离线/在线、检索条数和温度不同（附录 C），不是统一冻结测试协议。
- 失败类型统计按“去掉成功、加上失败”条件选样，比例不能外推为总体错误率。
- 知识密集与多跳问答上 raw 同样不敏感，结论依赖任务类型。
- 骨干数量：摘要写 13 个，§3.1 写 10 个，按列表计为 13；不影响主结论。

对 harness 设计的含义（本项目阅读判断）： 评估记忆/经验组件时，“加上后分数涨”只说明这块上下文有用；要声称“代理学会了用经验”，至少需要同格式的内容干预对照（Empty / Irrelevant / Filler）。

来源：arXiv:2601.22436v3 正文 §1–5、附录 C–D；数值均出自原文文字或表格，矩阵与条形为本项目重绘/示意，非原论文图。未运行任何实验，不构成复现。