HarnessRSI · 精选 Reel · 机制类 · F2 / F3 · 上下文与权重成对更新

同组 rollout 全对或全错，GRPO 就没有梯度：UI-Mem 让同一组拿到强弱不同的记忆指导

手机 GUI 在线强化学习里，结果奖励稀疏，一组采样常常全部失败；而给每条 rollout 都加强记忆指导，又可能让全组都成功。两种情况下组内优势都为零。UI-Mem 在同一组里分层注入“强 / 弱 / 无”指导，并让分层记忆随策略持续更新。

arXiv:2602.05832v1 (2026-02-05) · Xiao, Wang, Wang, Liu, Chai, Pan, Zhou, Chen, Wen, Li · CUHK MMLab / vivo AI Lab · ui-mem.github.io

因果链

1 奖励稀疏、轨迹很长

只有终局给 r∈{0,1}，任务常超过 10 步；做对了中间几步、最后一步错，仍得 0。

§1、附录 A

2 全组失败 → 优势全为 0 实测

每题采样 G=4 条；全失败时组内方差为 0，式(6)的优势消失。vanilla GRPO 的组内奖励方差“频繁塌到接近 0”，成功率剧烈波动。

§3.1、§4.4 Fig.7

3 每条都加强指导 → 全组成功，同样为 0 作者论证

另外，代理可能学会照外部计划执行，而不是把技能学进参数。原文只有消融支持：去掉分层、全部给完整指导时成绩“显著下降”（数值未在正文给出）；组内方差曲线没有画这一条件。

§1、§3.3、Fig.5

4 修法：同组分层 + 逐步撤除

强	弱	无
工作流 + 子任务技能 + 失败模式	只给工作流	无记忆，测内化程度

按每题成功率 EMA 线性调整比例：越熟练，强指导越少、无指导越多；无指导成功另有加分 α，并加子任务进度奖励。

§3.3 式(2)–(5)

5 记忆随策略自更新

每轮用奖励模型判定成败，再由 LLM 从成功轨迹抽工作流/技能、从失败轨迹抽首个失败子任务的诊断，参数化为模板（如 {{filename}}）后合并入库；检索用 UCB 打分。

§3.2、§3.4、附录 D–G

一组 4 条 rollout 的优势怎么算

示意 · 按式(6)手算的玩具例子

全失败（无指导）

0	0	0	0
无	无	无	无

方差 0 → A = 0, 0, 0, 0
没有学习信号

全成功（都给强指导）

1	1	1	1
强	强	强	强

方差 0 → A = 0, 0, 0, 0
同样没有学习信号

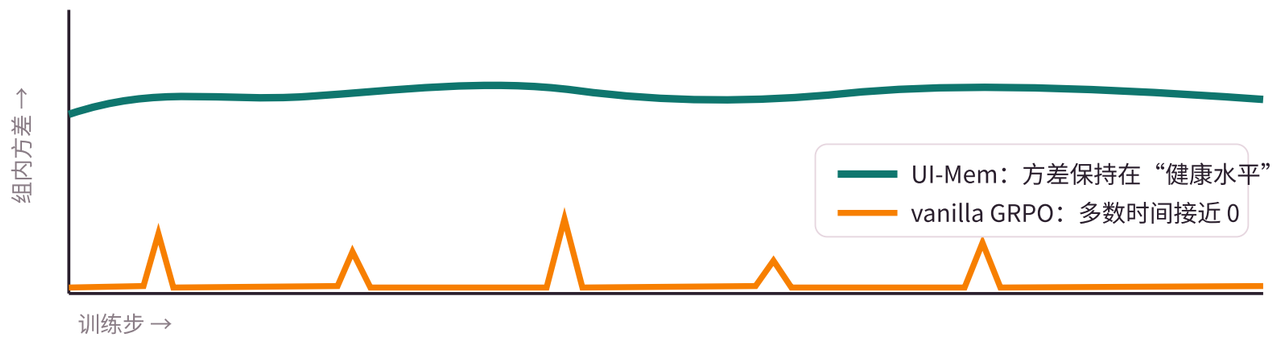
分层（强 / 弱 / 无 / 无）

1.0	0.6	0	0
强	弱	无	无

均值 0.4 · 标准差 0.42 →
A = +1.41, +0.47, −0.94, −0.94

式(6)：$A_i = (R_i - \text{mean } R) / (\text{std } R + \varepsilon)$。玩具例子取总体标准差、忽略 ε；奖励 1.0 / 0.6 / 0 借用附录 H 图 14 的三档示例（同一任务在强、弱、无指导下的结果），真实训练中的奖励还含进度奖励和无指导加分，且每组强弱无比例由课程动态决定。

训练中组内奖励方差的形状（示意）



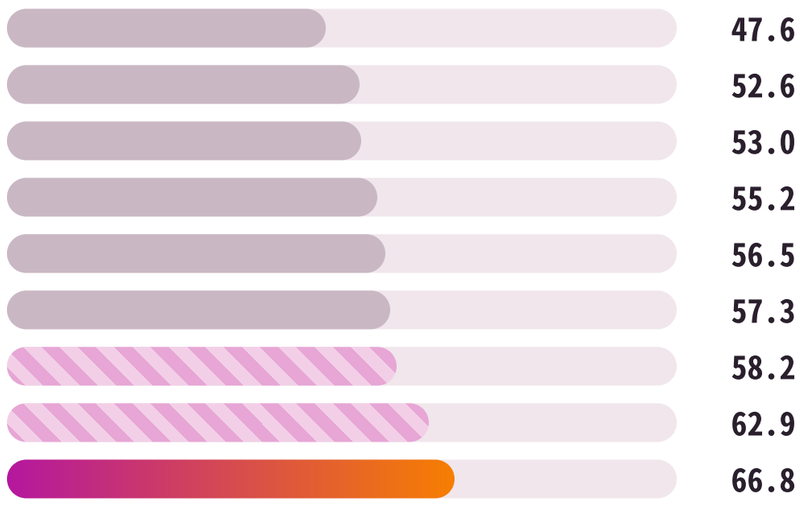
只画原文 Fig.7(b) 的文字描述（基线“频繁塌到接近 0”，UI-Mem“保持健康方差”），无坐标数值，**不是原图数据**。注意：对照组是无记忆的 vanilla GRPO（全失败塌缩），不是“全部强指导”（全成功塌缩）。

推理时检索：训练过才用得上

未训练模型直接检索记忆：47.6 → **52.6**；vanilla GRPO 后再检索：53.0 → **55.2**
UI-Mem 训练后再检索：8B 66.8 → **71.1**，4B 58.2 → **62.5**（Table 1、3）
作者解读：只给上下文不够，模型需要先学会怎么用它。本项目注：这三组差值来自不同训练流程，并不是对“检索”单独做的受控对照。

同骨干对照：AndroidWorld 成功率

Qwen3-VL-8B · Table 3 · Fig.5



UI-Mem 本身含进度奖励，所以“记忆引导”部分的较公平对照是 GRPO + 进度奖励（+9.5）。推理时再检索记忆为 71.1（Table 1）。“去分层”“只用单一层级记忆”的消融在 Fig.5，正文未给数值。

其他证据

4B 也成立： Qwen3-VL-4B 45.3 → UI-Mem-4B 58.2
AndroidLab（8B）： SR 34.8 → 43.5，Sub-SR 45.3 → 52.7；MobileRL 42.5
5 个训练中未出现的 App（Bluecoins、Cantook、Maps.me、Pi-Music、Zoom）：不检索时持平或优于基线，检索后进一步提升（Fig.6，正文无数值）

附录 C：训练奖励器核对

Qwen2.5-VL-72B 把截图转文字 → DeepSeek-V3 判断关键状态是否达成。
准确率 **0.900**，直接用 MLLM 打分 0.724；P 0.909 · R 0.943 · F1 0.902（Table 4）。
测试奖励另由 AndroidWorld 系统状态程序判定，与训练奖励器无关。

补读附录 C 后确认的

- ✓ 文本化两段式校验比直接看截图更准（0.900 vs 0.724），所选组合 F1 0.902。
- ✓ 进度奖励来自 DeepSeek-V3 对 essential states 的判定（附录 B 模板）。
- ✗ 训练奖励器仍有约 10% 判错（按其自报准确率），对 GRPO 的影响未分析。

附录 C 没有回答的

- ? 验证集规模、来源与标注方式均未报告。
- ? F1 0.902 与 P/R 的调和平均（≈0.926）不符，平均方式未说明。
- ? 训练查询源（含 AndroidLab）与测试任务的去重**不在附录 C**，全文未见。

限制

- 无种子、无方差报告；每组只有 G=4 条，比例与阈值的具体值未给。
- 训练查询取自 AMEX / AndroidLab / UI-Genie，AndroidLab 主表部分在分布内；以 AndroidWorld 为主结论。
- 附录 B 的训练记忆示例是 Markor，AndroidWorld 也含该应用（本项目判断）：AndroidWorld 更像“未见任务”，不是“未见 App”。
- 奖励器、抽取器（Seed1.8）、参数化（DeepSeek-V3）的调用成本未报告，与基线的算力不匹配。
- 方差曲线只证明全失败塌缩被缓解；全成功塌缩一侧只有整体成绩消融，没有直接的方差测量。

来源：arXiv:2602.05832v1 正文 §1–4、附录 A–H（含附录 C 全文）。因果链与玩具算例、方差曲线为本项目示意；条形数值取自 Table 1–3 与 §4.4 正文。未运行任何实验，不构成复现。