别让 LLM 一口气写完整个优化器：只演化三个算子，全局搜索交给盆地跳跃

ImprovEvolve：LLM 只写初始化、局部改进、扰动三个方法；固定的两阶段 basin-hopping 负责在崎岖地形上找更深的盆地。与单体程序基线同演化参数、同时限，各做 3 次独立运行。

Kravatskiy, Khrulkov, Oseledets · arXiv 2602.10233**v2**（2026-06-26）· 基于开源 GigaEvo 框架

图例

- 等高线：解的适应度地形（示意），越深越好
- perturb 扰动跳跃（σ 控制步幅）
- improve 下坡到盆底（适应度不降）
- 一个程序 = init · improve · perturb

比例尺：HEX 11 演化期的 σ 档位（表 2，逐档递减）

1e2	50	10	5	1	.5	.1	.05	.01	5e-3	1e-3

壹 问题：要 LLM 一次写出完整求解程序，负担太重

§1、§3 · 附录 A.1 提示词接口

单体程序（AlphaEvolve / GigaEvo 式）

```
def entrypoint(hex_num=11, seed=0):
    # 初始化、搜索策略、终止条件
    # 全部写在这一个函数里
    return centers, angles
```

每次调用直接输出一个解。作者观察到生成的程序常依赖 L-BFGS-B 等现成例程，在约束全开后的非凸、非光滑地形上不够用。

ImprovEvolve 要求的接口

```
class Improver:
    generate_config(seed) → 可行初始解
    improve(x)   → x′，适应度不低于 x
    perturb(x, σ) → 按强度 σ 随机扰动
```

LLM 只负责这三块里的领域知识；怎么组合它们由固定算法决定。

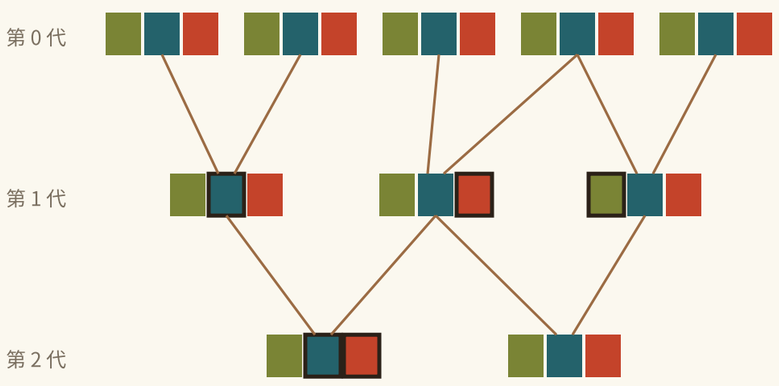
作者给出的三个好处：
① 拆开后每块更容易写对，也便于人和 LLM 读懂、调试；
② 每个方法都有放领域知识的位置；
③ **同一个程序可以从任意给定解继续优化**，例如专家构造或 AlphaEvolve 已有的最好解——单体程序做不到这一点。

贰 机制：外层演化程序种群，内层在地形上跳盆地

算法 1 · §3 · 表 2 · 附录图 7 · 地形与路径为本项目示意

外层 · 程序种群 MAP-Elites

单岛；以适应度为唯一描述子，分 150 个箱



黑框 = 本代被 LLM 改写的算子（示意）

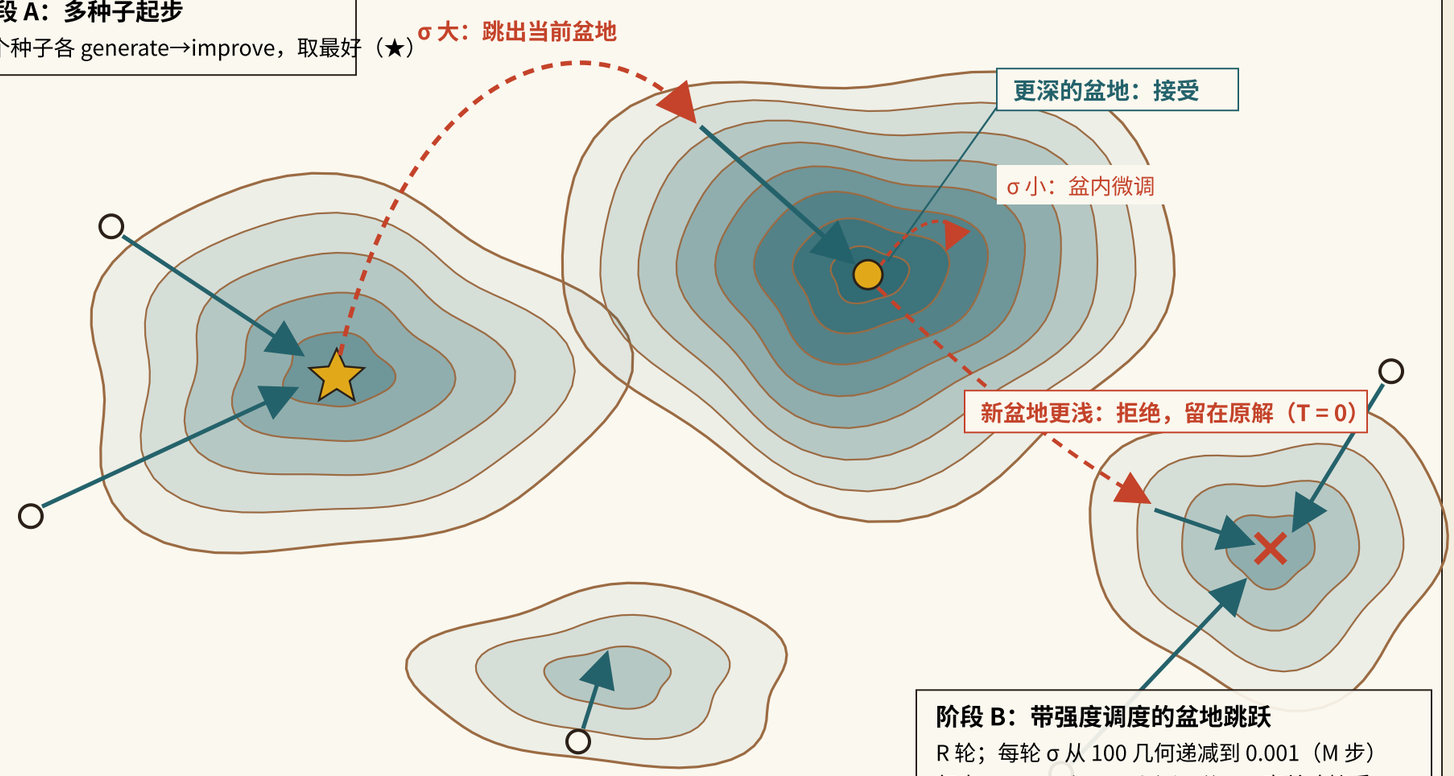
- 初始 5 个程序：Gemini 3 Pro 生成并修到能过校验
- 演化：Gemini 3 Flash Preview 作变异算子
- 每代按适应度比例抽 6 个精英，每次把 2 个父代及其指标交给 LLM，产出 10 个子代
- improve 返回无效解的程序在演化期直接丢弃

程序适应度 = 在内层跑一遍盆地跳跃找到的最好解

单体基线则是直接调用一次程序拿到一个解

内层 · 运行一个程序（算法一）

阶段 A：多种子起步
K 个种子各 generate→improve，取最好（★）



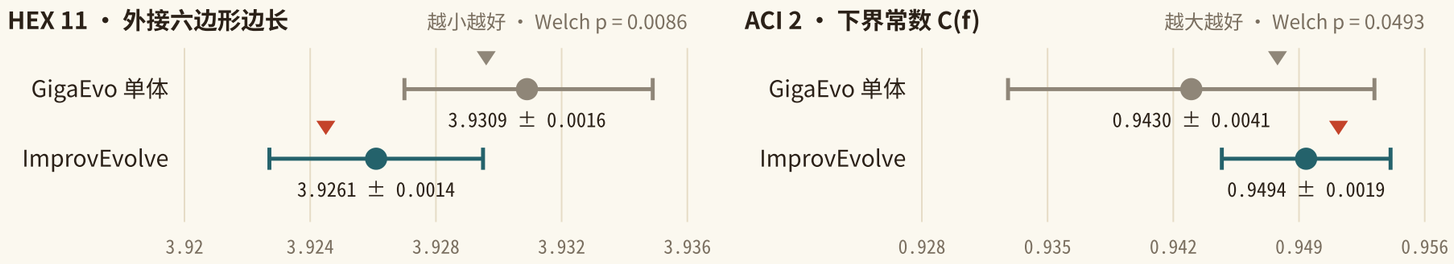
阶段 B：带强度调度的盆地跳跃
R 轮；每轮 σ 从 100 几何递减到 0.001（M 步）
每步 improve(perturb(x*, σ))，不变差才接受
每轮重启 σ 调度，反复尝试大跳

叁 结果：同参数、同时限、各 3 次独立运行，均值优于单体基线

§4.1–4.3 · 表 1、3、4、5

多次运行的均值与 95% 置信区间（表 4）

每种方法 3 次独立的 100 代演化，演化参数与时限相同。圆点 = 均值，横线 = 95% CI，三角 = 3 次中的最好一次。



单次最好值对照（表 1）：HEX 11 上 ImprovEvolve 3.9245，AlphaEvolve 3.9301，商用全局求解器 3.9249；ACI 2 上纯演化 0.9512，仍低于 AlphaEvolve 的 0.96102。

两项都通过 Welch t 检验（$p < 0.05$），但**只有 n = 3，两组置信区间都有重叠**；ACI 2 的 $p = 0.0493$ 处在显著边缘。

反例：让 LLM 代替专家调参，结果变差

HEX 11 消融，单位为最好边长 L（越小越好）。K = 阶段 A 种子数，R = 阶段 B 轮数。

设置	K	R	L
只有阶段 A	1000	0	3.9282
只有阶段 B	1	100	3.9269
A + B（原程序）	**100**	**5**	**3.9245**
A + B + Gemini 3 Pro 改参	100	100	3.9270
LLM 改后的初始化 + B	100	100	3.9310

对单体基线，LLM 把 Langevin 噪声调大，结果六边形重叠（应当调小）。作者结论：LLM 会给出听来合理但实际有害的改动。各行预算不同，均为单次结果。

同一个在 n = 11 上演化出的程序，拿去跑 n = 11–24（表 1、表 3，L 越小越好）

单体基线的最好程序换到 n = 12 就出现六边形重叠（无效解）。ImprovEvolve 程序在 GPU 上用更大预算（K = 100、R = 100）验证。* = 需专家编辑（+E：换 SLSQP、软化罚权、放宽边界与迭代上限）后的值。

n	11	12	13	14	15	16	17	18	19	20	21	22	23	24
L	3.9245	3.9416	4.0000	4.2690*	4.4473	4.5275	4.6136*	4.6188	4.6188	5.0000	5.0000	5.2856*	5.4000*	5.4848

未经人工改动即超过已知最好：11、12、15、16　专家编辑后作者报告新最好：14、17、23　与已知最好持平：13、18–22、24（22 需 +E 才持平；23 未编辑时为 5.4848，差于已知 5.4286）

肆 边界：哪些结果不能算作全自动演化

§4–6、Limitations · 本项目阅读判断

1. **样本小：**受控对比只有 n = 3，置信区间重叠；表 1、表 3 的新纪录是单次运行的最好值（作者在限制中承认）。
2. **部分纪录依赖人工：**HEX 14 / 17 / 23 靠专家编辑；ACI 2 的 0.96258 是专家改程序后从 AlphaEvolve 的 0.96102 解继续优化 15 轮得到，纯演化程序为 0.9512。
3. **不是盲测：**目标本身就是公开纪录；n > 11 的验证预算远大于演化期。
4. **范围窄：**三个数学优化问题；第三个（球面码，v2 新增）未上图，其 ++ 版本另经校准搜索，评测与校准配置是否分开原文未说明。
5. **算力：**HEX 一次演化约 10 小时（单机），ACI 2 约 40 小时。

读图说明

作者结果　表 1–5 数值、p 值、置信区间、运行时长均为论文报告值。
阅读判断　“不是盲测”“预算差异”为本项目判断。
示意　等高线地形、跳跃路径、种群谱系为本项目绘制，不是论文实验图。

与第一期各篇的区别：第一期没有种群搜索类。本篇不涉及经验或记忆，改的是“LLM 产出什么单元”——从完整求解器缩小为三个算子。