系统类 · F1 / F5 · 归因与修补现任 harness

别给提议者看摘要：让它自己翻原始执行轨迹

Meta-Harness 把所有历史候选的源码、分数和完整执行轨迹放进文件系统，由编码代理按需 grep / cat 后提出新的 harness 代码。同样的评估次数下，能读原始轨迹的接口明显好于只给分数或摘要的接口。

arXiv:2603.28052v1 (2026-03-30) · Lee, Nair, Zhang, Lee, Khattab, Finn · Stanford / KRAFTON / MIT

实验规格

提议者	Claude Code + Opus-4.6
被包装模型	冻结（随域而定）
一次典型搜索	约 20 轮 · 60 个候选
选择依据	只看 search set
测试集	最后对前沿评估一次
harness 形态	单文件 Python

问题 harness 的错要过很多步才显现，压缩后的反馈找不到源头

一个“存什么、何时取、怎么给模型看”的决定，可能在许多推理步之后才让任务失败。只给标量分数、只给上一个候选或给一段 LLM 摘要，**会把定位失败所需的细节压缩掉**。作者把这看作现有文本优化器为可扩展性做的取舍，而不是长程依赖没有用的证据（§1）。

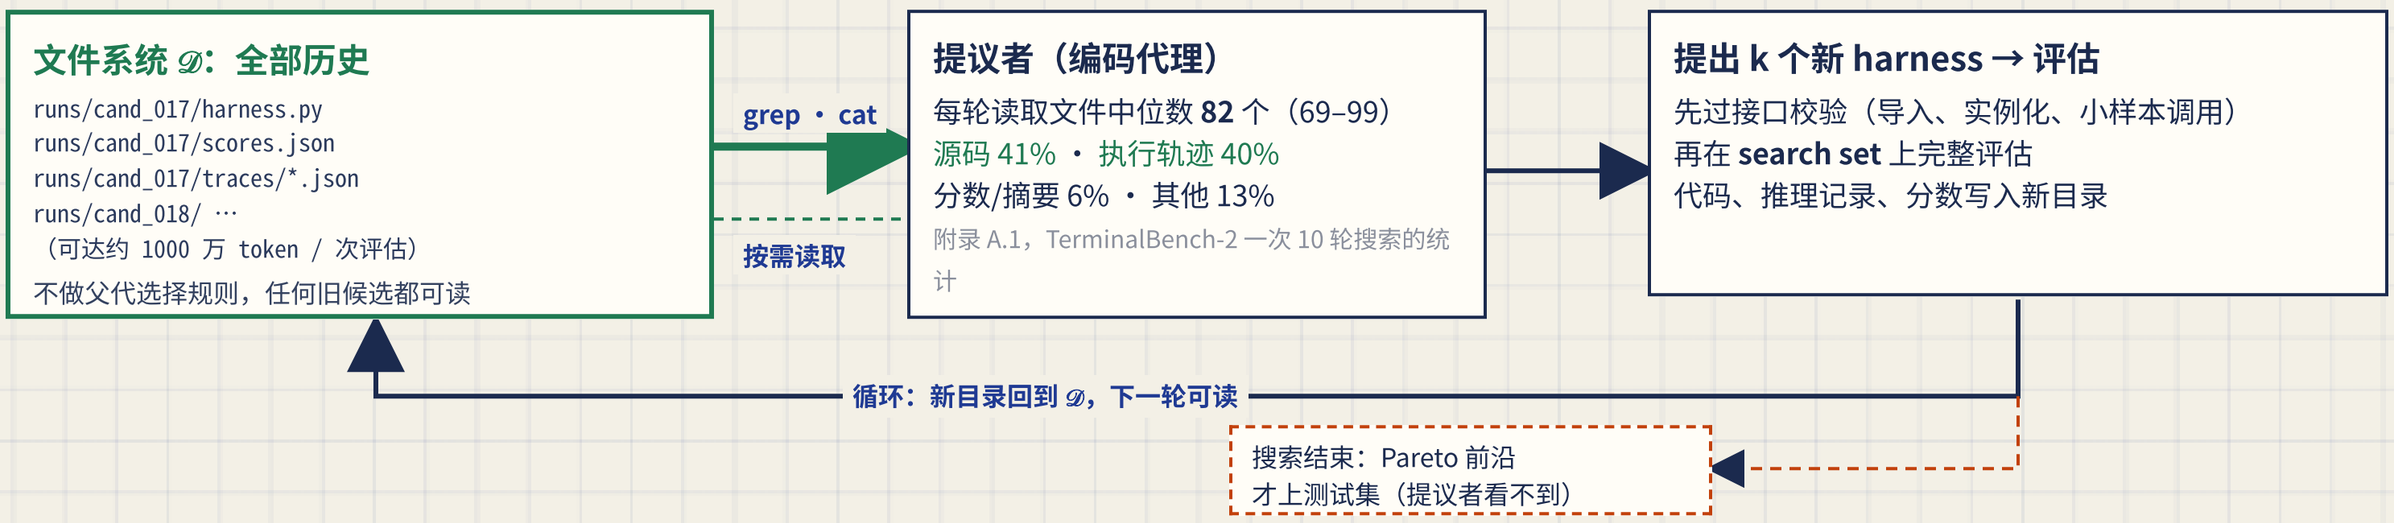
每轮可用反馈上下文（MTok / iter，对数刻度；Table 1 作者估计）



各方法取其论文中最大设置的估计值，跨任务合并；条长按 log10 绘制，起点 0.001（示意比例）。

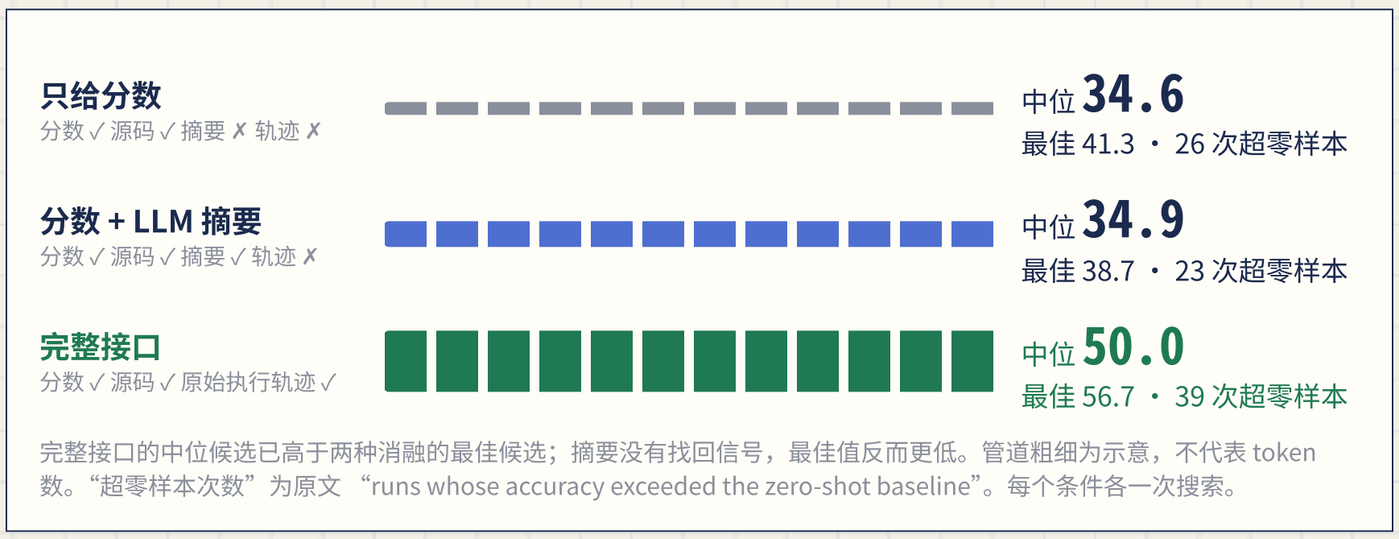
机制 搜索回路：历史全部落盘，由提议者自己决定读什么

示意 · 按 §3、Fig.2、Algorithm 1 与附录 A.1 重绘



结果 同评估次数，只换提议者看到的信息

文本分类 · GPT-OSS-120B · search set（Table 3、Table 4）



完整接口的中位候选已高于两种消融的最佳候选；摘要没有找回信号，最佳值反而更低。管道粗细为示意，不代表 token 数。“超零样本次数”为原文 “runs whose accuracy exceeded the zero-shot baseline”。每个条件各一次搜索。

同一提议者、同评估预算下的其他优化器

方法	中位	最佳
GEPA	32.6	40.2
Best-of-N（无搜索结构）	34.0	44.2
TTT-Discover	34.1	45.6
OpenEvolve	39.1	43.3
Meta-Harness	**50.0**	**56.7**

“同预算”指候选评估次数相同，不是提议者 token 相同；提议者读 82 个文件的成本未计入对照。

留出 搜到的 harness 拿到搜索之外还剩多少

留出测试集

文本分类 3 数据集（Table 2）

48.6 平均准确率

ACE 40.9（+7.7）· MCE 40.0 · few-shot(all) 40.8
附加上下文 **11.4K**，ACE 50.8K
另 9 个未见数据集平均 73.1，ACE 70.2（Table 5）

未见题目 模型部分未见

检索增强数学：250 题搜索 → 200 道 IMO 级新题（Table 6）

pass@1（3 次平均）	无检索	BM25	Dense k=5	Meta-H
GPT-OSS-20B（选择用模型）	47.6	48.9	46.7	50.6
其余 4 个未见模型均值*	30.8	34.7	35.9	35.8
5 模型平均	**34.1**	**37.5**	**38.1**	**38.8**

*本项目由 Table 6 逐项计算。相对无检索 +4.7，但相对 BM25 只 +1.3、相对 Dense k=5 +0.7；4 个未见模型上与 Dense k=5 持平（35.8 vs 35.9），Gemini-3-Flash 上低于 BM25（46.3 vs 46.6）。

非留出

TerminalBench-2（Table 7）

搜索与评估用**同一套 89 题**，作者称其为 discovery 问题。
Opus-4.6：76.4，Terminus-KIRA 74.7
Haiku-4.5：37.6，Goose 35.5
他方数字取自公开榜单，不是本地同条件重跑；相对 KIRA 只在 7/89 题上有增益。

案例 为什么要原始轨迹：一次搜索日志里的归因

TerminalBench-2 · 附录 A.2 · 基线 KIRA 64.4%（该搜索设置）

第 1–2 轮
58.9 / 57.8
两个不同的结构修复都附带同一份清理型 prompt 改写，均退步

第 3 轮：识别混杂
63.3
推断共同因素是 prompt 改写，单独保留结构修复，退步明显变小

第 4–6 轮
仍退步
继续改完成流程与等待逻辑，得出“改 prompt / 控制流风险高”

第 7 轮：纯增量
本轮最佳
首轮前注入环境快照（语言、包管理器、/app 列表），不改其他方法

限制

1. 接口消融只在文本分类的 search set 上，每个条件一次搜索，没有方差。
2. 只用一个提议者（Claude Code + Opus-4.6）；作者自己指出换提议者的效果尚未研究。
3. TerminalBench 搜索与报告同一套题，不能当泛化证据。
4. 数学“5 个留出模型”中 GPT-OSS-20B 就是选择 harness 用的模型；数学 search set 在 §4.2 写 250 题，附录 D 写 88 题。
5. 对照只匹配评估次数，不匹配提议者 token 和墙钟成本。
6. 迭代日志是定性案例，不是“轨迹访问导致收益”的受控证明。

来源：arXiv:2603.28052v1 正文 §1–5、附录 A–D。流程图与管道为本项目示意，数字均出自原文表格；“4 个未见模型均值”为本项目计算。未运行任何实验，不构成复现。