记忆 HARNESS · 跨任务迁移对局表

一套记忆 harness，走不遍所有任务

M★ 把记忆写成可执行的 Python 程序，按目标任务演化；把演化出的最佳程序搬到别的任务上，结果多半不如最朴素的通用种子。

对局结果 · Fig.5

5 / 6

次跨任务迁移**低于**通用种子程序；3 个目标任务上本地演化程序都最好。

M★ · arXiv 2604.11811v2

问题

记忆设计在“设计时”就被定死了

对话需要人物与事件的语义索引，具身规划需要可复用的动作模式，专业推理可能需要结构化数据库。Mem0、ReasoningBank、GEPA 等固定设计各自擅长某些任务——论文 Table 1 中最强基线随任务而变。问题是：**能否针对给定任务自动找到合适的存储、检索与使用方式**，以及一种任务上找到的设计能不能直接搬走。

研究动作

把“记忆”写成一段可执行程序，再演化它

每个候选是一个固定接口的 Python 模块，同时规定 **Schema**（存取的数据格式）、**Logic**（read / write 后端，可用 SQLite、ChromaDB、LLM 调用）和 **Instruction**（代理如何抽取、查询与使用记忆的提示常量）。编码代理读执行轨迹与失败样例后打补丁，程序池按验证分数抽样父代。最后拿各任务的最佳程序**交叉测试**。

迁移棋盘：行是目标任务，列是程序来自哪里

同一 task agent（GPT-5.4 Mini），各目标任务的留出测试集；每格是“来源任务上演化出的最佳程序”放到目标任务上的成绩。灰格为原图的 “Universal mem.” 通用种子（其数值与 Table 1 的 Vector Search 一致，本项目据此标注为 Vector Search）。

目标任务 ↓ / 来源程序 →	通用种子 Vector Search	LoCoMo 演化 对话记忆	ALFWorld 演化 具身规划	PRBench-Legal 演化 法律推理
LoCoMo token F1	0.26 基准线	♛ 0.46 本地	0.02 低于种子	0.09 低于种子
ALFWorld Unseen 成功率	0.64 基准线	0.62 低于种子	♛ 0.88 本地	0.58 低于种子
PRBench-Legal rubric 分	0.47 基准线	0.06 低于种子	0.58 唯一高于种子	♛ 0.66 本地

本地演化（金框）　迁移后低于通用种子（斜纹）　迁移后仍高于种子　格底细条：成绩占该行坐标上限的比例，黑竖线 = 种子成绩

最惨的两步：ALFWorld 程序搬去 LoCoMo 只剩 0.02；LoCoMo 程序搬去法律推理只剩 0.06。

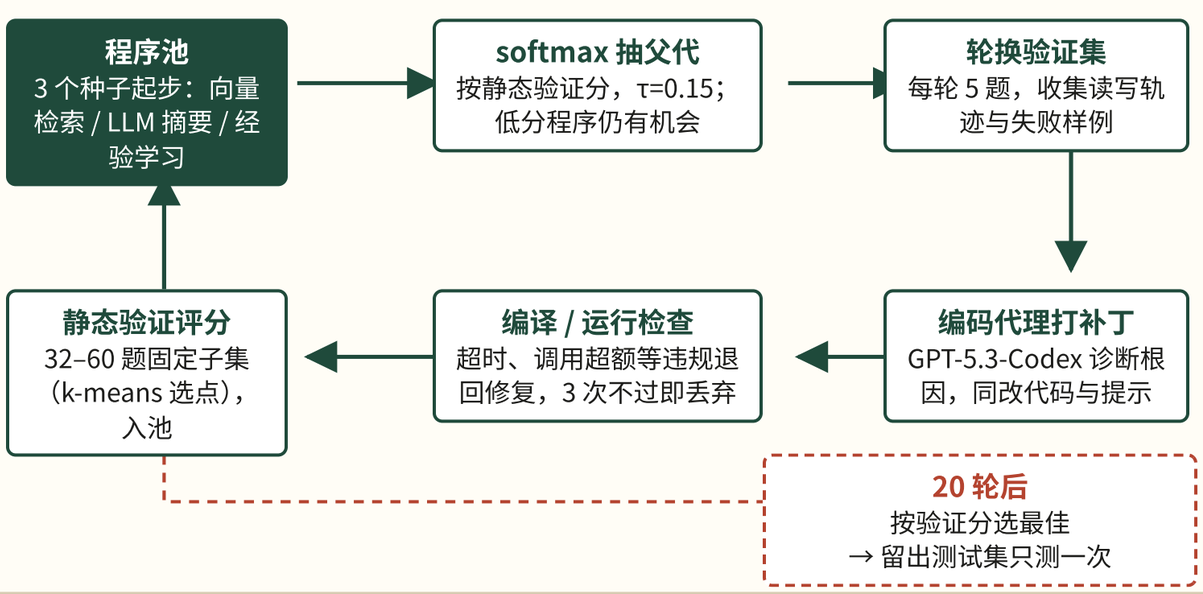
唯一“过线”：ALFWorld 程序在 PRBench-Legal 得 0.58，高于种子 0.47，但仍低于本地 0.66。

作者给出的原因：演化会把任务特定的启发式直接写进逻辑（如 ALFWorld 程序里的同义词表），任务内更好，迁移变差（附录 J）。

数值读自论文 Fig.5（arXiv HTML v2 矢量图 fig4.svg 上的柱顶标注，两位小数），本项目按目标×来源重排成棋盘；不是新实验。坐标上限沿用原图各面板：0.6 / 1.0 / 0.8。

机制

程序池 + 反思式代码演化：每轮读失败样例、打补丁、过编译检查、回池



- **Schema**　dataclass 规定写入与查询字段。LoCoMo 最佳程序 7 个字段，PRBench-Legal 22 个。
- **Logic**　read() / write() 实现。ALFWorld 最佳程序只用 SQLite 并加精确匹配加分；LoCoMo 用 SQLite + ChromaDB 混合打分。
- **Instruction**　抽取、查询、作答提示常量与常驻知识，随代码一起改。
- **Toolkit 约束**　每次 read/write 至多 1 次 LLM 调用，read 输出 ≤3000 字符，60 秒超时。

附录 E、F、Table 7–9；棋子图标仅作装饰，示意。

本地对决：4 个基准 8 项指标

7 / 8 项最优

例：PRBench-Finance 0.586 对 GEPA 0.449；LoCoMo F1 0.459 对 Mem0 0.373。唯一不是第一的是 ALFWorld Seen：0.700 对 GEPA+Vector Search 0.820（Table 1）。

换随机种子再演化

14 / 15 次胜最强基线

LoCoMo、HB-Data、PR-Finance 各 5 次；变异系数 ≤10%；LoCoMo 有一次 0.364 低于 Mem0 0.373（Table 3、附录 I.2）。

只演化提示、不改代码

−0.203 F1

LoCoMo 上从 0.459 掉到 0.256；只改代码不改提示 −0.106；去掉程序池 −0.141；总选最高分父代 −0.078（Table 2，仅 LoCoMo）。

限制 · 这盘棋只下了这些格

- 迁移棋盘只有 3 个目标任务、每格一个最佳程序，没有给出重复或误差；结论是“这几个程序不可迁移”，不是“任何记忆设计都不可迁移”。
- 全部实验只用一组模型：GPT-5.4 Mini（任务代理、评委、工具 LLM）+ GPT-5.3-Codex（反思）；作者未测程序对这组模型的依赖程度（附录 J）。
- 和固定基线的比较不含搜索成本：每个基准演化一次约 $12–90，ALFWorld 约 100 小时墙钟（附录 D.1）；LoCoMo 测试集 100 题，时间与因果类问题仍是 Mem0 / GEPA+VS 更强（Table 4）。

来源：Pan, Liu, Zhou, Zhang, Shi, Xu, Jia. M★: Every Task Deserves Its Own Memory Harness (CityU HK / Microsoft), arXiv:2604.11811v2。逐数溯源见 SOURCE.md。

棋盘与流程图为本项目重绘 / 示意；本项目未运行或复现实验。