结果揭晓之前没有标签，靠什么修订 harness?

Milkyway：同一道未决题的多次重访之间，证据与预测的变化本身就是信号

Harnessing Pre-Resolution Signals for Future Prediction Agents
Wei, Gao, Han 等
arXiv:2604.15719**v3**（2026-05-08）

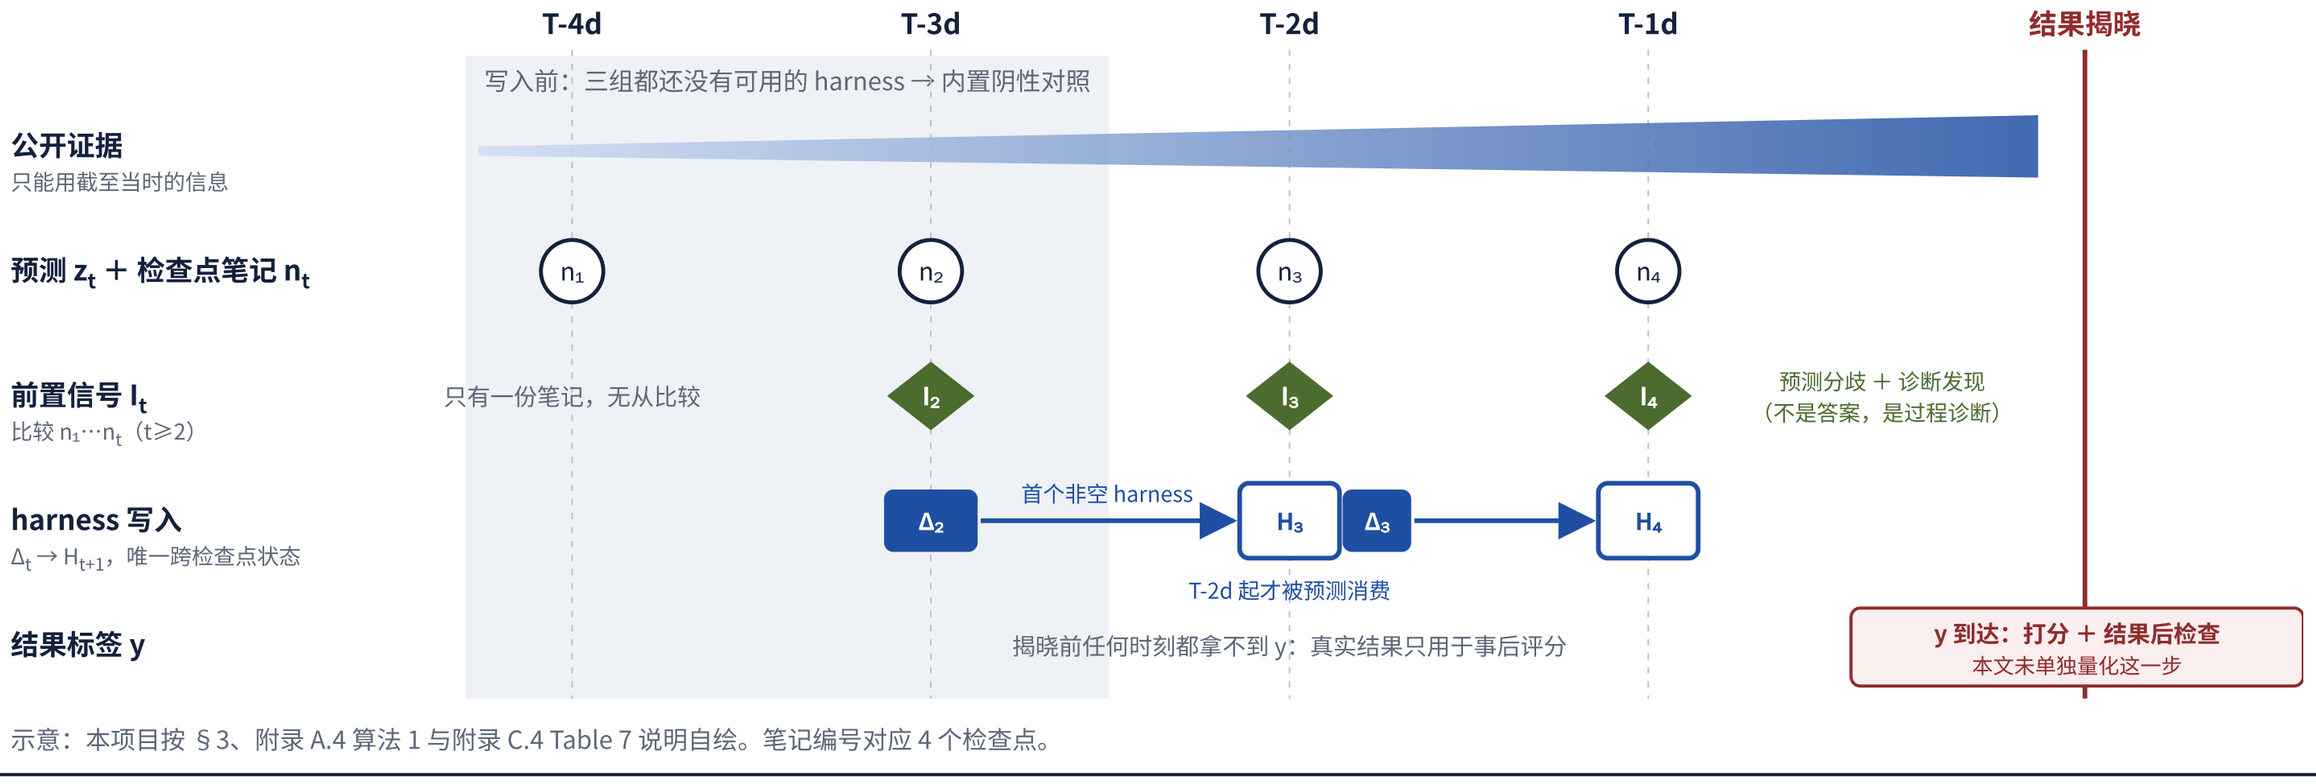
问题 标签来得晚，而且太粗

未来预测题只能用截至预测时刻的公开信息作答。结果要等揭晓后才有，而且只告诉对错，不告诉过程中该追踪什么、该核实什么、哪里该保持不确定（§1、§3.1）。

研究动作 用“重访之间的差异”写有界补丁

每个检查点产出一份固定格式的笔记；从第 2 次起比较前后笔记，每个检查点至多写一次补丁（add / revise / deprecate / 空）进题内 harness 的三条轴：**F** 因素追踪、**E** 证据处理、**U** 不确定性。只存程序性指导，不存答案和原始证据（§3.2–3.3、附录 A）。

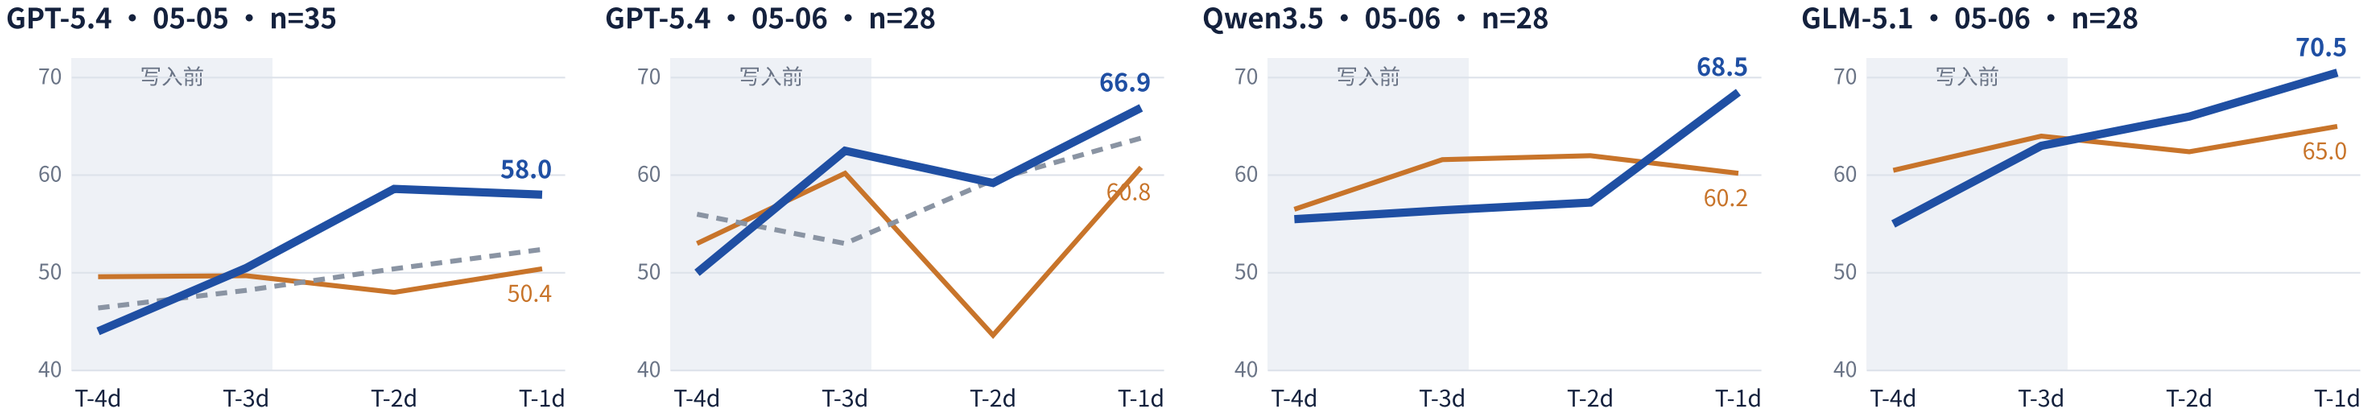
机制 每个时刻能拿到什么信号



示意：本项目按 §3、附录 A.4 算法 1 与附录 C.4 Table 7 说明自绘。笔记编号对应 4 个检查点。

同条件梯度（附录 C.4 Table 7 数值重绘）

FH typed F/E/U harness　GH 同字节、同写入次数的自由文本记忆　NH 无持久状态，只重复预测



纵轴为 FutureWorld 得分。灰底为写入前检查点。开源骨干的 GH 对照未完成，所以没有画出。

同条件结果 T-4d → T-1d 的提升 Δ（Table 2）

格（单次运行）	n	Δ NH	Δ GH	Δ FH	FH−NH	FH−GH	T-1d 端点差 FH−NH
GPT-5.4 · 05-05	35	+0.9	+6.0	**+14.0**	**+13.1**	**+8.0**	+7.6
GPT-5.4 · 05-06	28	+7.8	+7.8	**+16.9**	**+9.1**	**+9.1**	+6.1
Qwen3.5 · 05-06	28	+3.7	—	**+13.0**	**+9.3**	—	+8.3
GLM-5.1 · 05-06	28	+4.5	—	**+15.5**	**+11.0**	—	+5.5

格内固定：骨干、scaffold、工具、题目、日程、已揭晓子集、200K 有效上下文、每检查点 50 次工具调用；只改变题内持久状态（§4.3）。T-1d 主代理的工具调用与提示 token 在 NH 的 ±5% 以内（Table 9）。端点差：05-05 由 Table 7 计算（58.0−50.4），其余取自 Table 8。

同日重复对照（同一证据快照，GPT-5.4，n=28，附录 C.4 Table 10），R1→R2→R3→R4（R4−R1）：NH 54.4→40.1→32.5→52.9（−1.5）；GH 57.0→46.8→42.9→44.8（−12.2）；**FH 51.0→41.5→43.6→56.7（+5.7）**
日历时间固定时 NH/GH 没有提升；FH 的提升不到其日历梯度 Δ 的一半。

案例：harness 改的是取证路线，不是答案（Table 3）

河北省级**迁入**占比，真值 4.48。T-4d 时 harness 为空，预测锚定在错口径的排名统计上；NH/GH 到 T-1d 仍停在约 27。

检查点	写入	FH	NH	GH
T-4d	—（空）	35.20	0.98	27.10
T-3d	U：没有同口径锚点前，限制置信度	5.46	33.60	28.10
T-2d	E：排名页是错口径，先去实时迁入目的地省级视图	5.23	27.50	27.10
T-1d	复用，不再新写	**5.24**	27.18	27.30

单个已揭晓题的定性例子，写入内容按原文意译。

限制 这些条件之外不要外推

1. **留存只在题内：**harness 不跨题，作者不主张跨题学习；结果揭晓后的检查没有单独量化（§5、附录 A.5）。
2. **样本小、单次运行、无置信区间：**每格 n=28–35。同日对照里 NH 在各轮之间从 54.4 摆到 32.5，可见单格噪声不小（我们的阅读）。
3. **Δ 差里含起点差：**FH 在 T-4d（三组都还没有写入）起点偏低，所以 T-1d 端点差 +7.6/+6.1/+8.3/+5.5 小于 Δ 差 +13.1/+9.1/+9.3/+11.0。
4. **主表不是消融：**Table 1 中基线在预热后冻结，Milkyway 在题内更新，协议不同；开源骨干缺 GH 对照；Table 9 只统计主代理开销。