技能库自演化 · 分层拆解图

执行器冻住，只训练写技能库的那一个

SkillOS 让一个 8B “整理者”学会插入、改写、删除技能——奖励不看它刚处理的那道题，而看**后面相关的题**做得怎样。

SkillOS（Google Cloud AI Research / UIUC / MIT）
arXiv 2605.06614v1
整理者 Qwen3-8B · GRPO · 16×H100
ALFWorld / WebShop / AIME / GPQA

问题

整理决策的信用来得晚、来得间接

一条技能写得好不好，要等以后某道相关任务用到它才知道；删除和改写的价值更难看出。手工整理不可扩展，规则式记忆操作拿不到下游反馈，已有 RL 工作要么教代理**用**技能，要么只在很短的任务流里学操作，难以学到改写、删除这类长期决策。

研究动作

把训练样本做成“一组相关任务”

按任务属性（ALFWorld 用自带的 6 类任务类型；数学题由 Gemini-2.5-Pro 标注主题、技能、易错点）把 5–12 道相关题串成一组，库从空开始。前面的轨迹由整理者写进库，后面的题检验这些写入——**后续任务的平均成功率**成为整理决策的主奖励。执行器始终冻结，只更新整理者。

机制 · 拆解图（示意）

任务组 G（训练时每步采样一组，库清空）

① x_1 空库作答 不计奖励 | x_2 用库作答 | x_3 用库作答 | x_4 … | $x_{|G|}$ $|G| = 5–12$

$r_task = x_2 \cdots x_{|G|}$ 的平均成功

每道题做完 → 轨迹交给整理者

SkillRepo：每条技能一个 Markdown 文件

②

```
name: search-fallback
description: 找不到物品时…
```
穷尽搜索 → 确认缺失 → 找替代品 → 继续

```
name: look-under-lamp
description: 指令含“台灯下”…
```
先找物品，再到台灯处查看

```
name: verify-then-act
description: 元技能…
```
先核对条件，失败时换策略

`insert_skill` `update_skill` `delete_skill` 整理者只能通过这三种函数调用改库

BM25 取回相关技能 → 放进执行器提示

③ FROZEN 冻结执行器（训练时 Qwen3-8B，ReAct）

参数从不更新；测试时换成 Qwen3-32B、Gemini-2.5-Pro、Gemini-3.1-Flash-Lite 也照样接这个库。

技能卡片内容按论文附录 Figure 17/19 的案例意译缩写，示意；层间关系按 §3 与 Algorithm 1 绘制。

TRAINABLE 整理者（唯一被训练）

Qwen3-8B，GRPO，组大小 8，学习率 1e-6，去掉 KL 项

输入

- 刚完成任务的轨迹
- 执行器**自己判断**的对错（LLM 自评，非真值）
- BM25 取回的相关旧技能

输出

- 一串 insert / update / delete 调用 → 改写 ②

奖励（每组一次）

$$r = r_task + 1.0 \cdot r_fc + 0.1 \cdot r_cnt + 0.05 \cdot r_comp$$

r_task：后续题平均成功
r_fc：函数调用有效率
r_cnt：Qwen3-32B 评委打的内容分
r_comp：库越精简越高，防止照抄轨迹

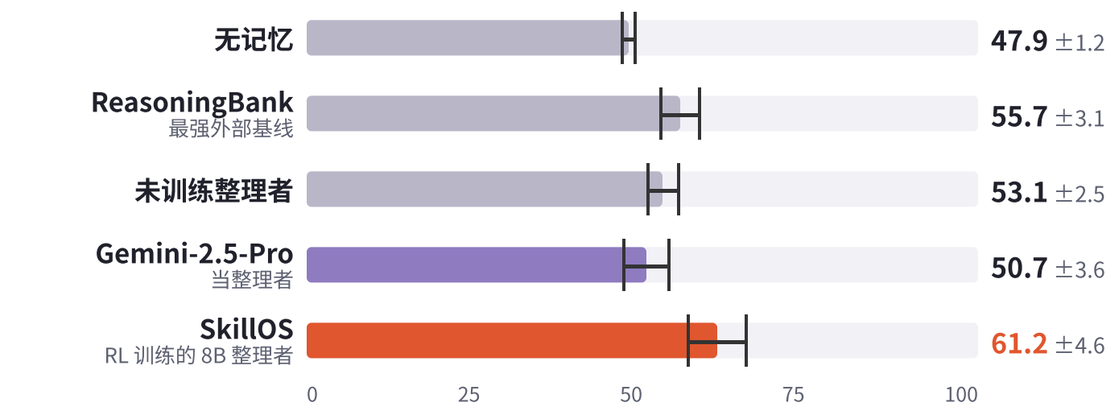
同一组任务采 8 条完整整理序列，各自演化出不同的库历史，用组内相对优势更新（§3.2.2）。

结果 · 同执行器对照

ALFWorld 平均成功率：只换“整理者”，执行器与检索预算不变

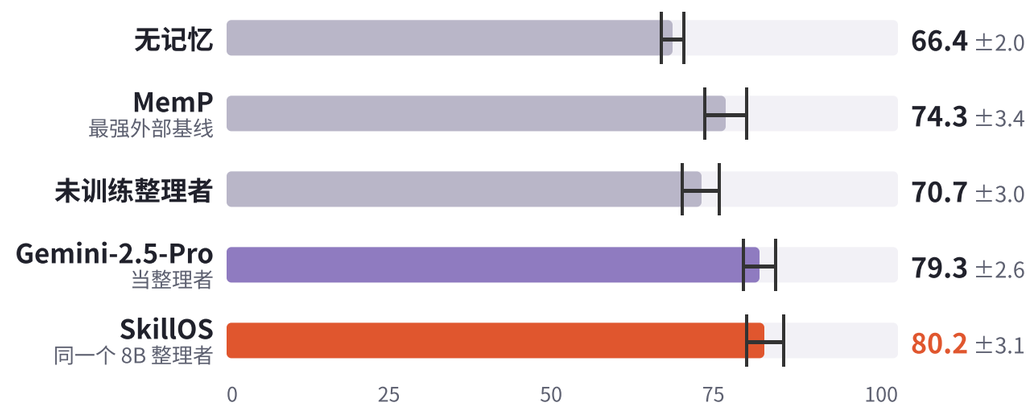
同一冻结执行器、同一 BM25 检索预算、同一步数上限与解码温度；3 次运行均值 ± 标准差；测试为 ALFWorld valid_seen 140 题（Table 1，附录 B.3）。“未训练整理者”= 同一 Qwen3-8B 不做 RL。

执行器 Qwen3-8B（与训练时相同）



这里差距清楚：训练过的 8B 整理者比同基座未训练版高 8.1，比 Gemini-2.5-Pro 直接当整理者高 10.5。

执行器 Gemini-2.5-Pro（训练时没见过）



迁移到更强执行器仍明显高于无记忆（+13.8）与未训练整理者（+9.5）；但与 Gemini 当整理者只差 0.9，误差棒重叠，**不能说更好**。

消融（ALFWorld，Qwen3-8B 执行器）

完整 SkillOS	**61.2**
去掉任务分组（随机任务序列）	**57.3**
去掉内容质量奖励	**58.6**
去掉压缩奖励	**60.0**

Table 3 只报均值；去分组的 −3.9 小于完整方法自身的标准差 4.6。

整理者行为怎么变

训练初期几乎全是 insert；随训练推进 update 占比上升、insert 下降，delete 一直占小头但略增（Fig.4）。库里逐渐出现验证、回退规划等“元技能”（Fig.5）。这些是过程观察，没有逐条技能的因果检验。

其他任务：增益更小

Qwen3-8B 执行器：WebShop 成功率 16.5（未训练整理者 13.6，无记忆 9.8）；推理三项平均 73.8（无记忆 69.6）。AIME24/25 各只有 30 题，作者也说推理题的增益普遍小于代理任务（Table 2）。

限制

- ALFWorld 测试集是 valid_seen（见过的房间布局），不是未见环境；评测时整理者仍按执行器的**自评对错**在线改库，原文没有写明测试流是否从空库开始。
- 对比不含训练成本：整理者训练用 16 张 H100，ALFWorld 约 3 天、WebShop 约 5 天；内容奖励来自 Qwen3-32B 评委，不是人工或真值。
- 平均成功率在 3 次运行间的标准差为 0.7–4.6 分，部分对照（Gemini 执行器下与 Gemini 整理者、消融各项）落在噪声范围内；复合奖励也不能给单条技能的因果信用。

来源：Ouyang et al. SkillOS: Learning Skill Curation for Self-Evolving Agents, arXiv:2605.06614v1。逐数溯源见 SOURCE.md。

拆解图为示意；条形图按 Table 1 数值重绘；本项目未运行或复现实验。