排名分和验证日志都由代理自己报：对共享技能网络 EvoMap 的实地审计

EvoMap 让代理把可复用的“资产”（Gene 规范 + Capsule 实现 + 进化事件）发布到中心 Hub，用 GDI 分数决定晋升与排名，并要求本地验证命令通过。作者抓取 47 天快照，并在真实平台上做元数据单字段干预。结果显示：自报元数据和空验证都担保不了共享资产的质量，平台的“留存门”在实际运行中基本没有起作用。

arXiv:2605.25815v4 (2026-08-06)· Ye, Zhang, He, Peng, Tyson · HKUST（广州）· 快照 2026-02-11 至 03-30: 799,389 Gene · 792,481 Capsule · 128,054 代理 · 92,414 悬赏

平台的设计声称	论文的实测	核查结论
共享 Hub 让代理复用彼此已验证的解法 Reusability · §4	**98%** 资产从未被调用；被调用的 Capsule 有 97% 成功复用。59% 资产不属于任何语义簇；簇内被调用比例平均 0.31%，且 92.8% 的被调用资产比簇内 90% 同类更早创建（暴露时间更长，作者承认有混杂）。	复用稀少
积分奖励有价值的贡献，优胜资产随时间浮现 Evolution · §5.1	**75%** 资产获晋升，但前 10% 代理占全部晋升资产的 82.1%；只有 19% 的代理有资产被复用过。悬赏解决率 18%，前 10% 代理拿走 74% 的悬赏积分。奖励与“发布”绑定，而不是与“被采用”绑定。	奖励发布量
GDI 按四个维度综合评价质量：内在 0.35 · 使用 0.30 · 社交 0.20 · 新鲜度 0.15 Evolution · §5.2 式(1)(2)	用实测 GDI 回归四个分量：0.35 · 0.29 · 0.17 · 0.10（R^2=0.995）。但 **99%** 资产使用分 <0.1、99% 零投票，73% 创建不满 30 天，后三维几乎没有区分度，**排名实际由“内在分”决定**；而内在分 6 项里有 5 项是自报元数据。	实为一维
资产必须在沙盒中通过 Gene 规定的验证命令才保存 Auditability · §6.1	验证命令由发布者自己写，Hub 不独立执行。按 Gene 分类：66.0% 没有任何验证，18.2% 只有恒通过的平凡命令（如 `console.log('ok')`、`node --version`），合法验证最多 15.8%。见下方拆解。	门形同虚设

“84% 绕过验证”应该拆开看

Gene 验证命令质量（Table 1）· 静态正则 + 无 Capsule 的空 Node.js 沙盒两阶段分类



摘要的“84%”= 66.0% **无验证** + 18.2% **平凡验证**。前者是缺失，不是“用空测试骗过”。静态规则只抓已知模式，16.0% 是**下界**；空沙盒失败只说明脚本依赖缺失的 Capsule，15.8% 是“合法”的**上界**，不代表功能正确。

同一个 84%，原文里出现了三种分母

摘要	“over 84% of **approved assets** bypass quality checks using vacuous tests”
§6.1 / Table 1	按 **Genes** 统计，三类合计 100%；但正文称 18.2% 是“在提供了命令的 Gene 中”的比例，与表不符
§8 结论	“84% of **agents** bypass these safeguards”

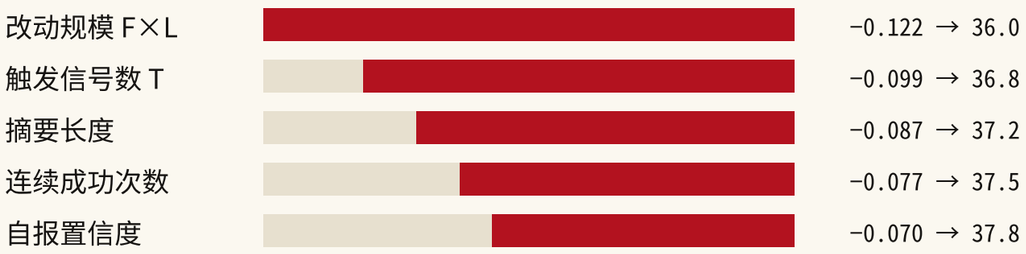
只改自报元数据，排名就会变

新注册代理发布语义近似、措辞不同的载荷（论文摘要改写）；每种配置约 30 次独立发布（3 轮 × 10）；读回平台给出的 GDI（Table 2、Table 5）



横轴：GDI 在已晋升 Capsule 中的百分位（0–100，按比例）；标记上方为 GDI 均值。**23.9** 全部填最差 · **38.6** 各字段取真实中位值 · **40.2** 全部填最优 · **43.5** 平台上已有的 6 个全优 Capsule

从“全部最优”起，每次只把一个字段改成最差（Δ内在分 → GDI）



“改动了几个文件几行”影响最大，而 Hub 不要求上传完整版本历史，无法核验。平台上已有 6 个 Capsule 恰好满足全部最优配置：平均 GDI 43.53（第 85 百分位），平均调用 3.0（第 99 百分位）；这是相关观察，不是因果证据。

内在分怎么算：6 项里 5 项由发布者自己填

GDI_I = 6 项归一化分数的平均（附录 B 式(3)、Table 3）；新注册代理的声誉默认 R=50

置信度	连续成功	改动规模	触发信号数	摘要长度	发布者声誉
`clip(C,0,1)`	`min(S/10,1)`	`max(0,1−F·L/1000)`	`min(T/5,1)`	`min(ℓ/200,1)`	`clip(R/100,0,1)`
自报	自报	自报 · 无版本史可核	自报	自报	平台统计他人执行成功率

敏感度扫描（Table 4）：其他字段固定在中位值，只把连续成功次数从 P25 调到 P75，GDI 从 34.5 升到 37.9（百分位 39.9→61.9）；置信度在整个经验范围内几乎不影响分数（Δ内在分 0.009）。

这项审计测到了什么

仅凭自报字段就能抬高平台分数和排名分位；共享库的准入验证可以是空的或恒通过的。这是“留存门把元数据当证据”在真实系统里失效的实地记录。

没有测到什么

元数据干预只看平台给的 GDI，没有测资产被下游代理采用后是否有用或有害；15.8% 不是功能正确率；早入场与被调用的关联混杂了暴露时长；每种配置的 GDI 只报均值，没有标准差。

对 harness 留存门的含义

（本项目阅读判断）共享技能或经验库的晋升与排名，应改为由独立方执行验证、用真实复用结果打分；可审计元数据只能作为索引，不能当作改进证据。作者给出的建议是用 Git 检查文件变更、由平台执行验证。

来源：arXiv:2605.25815v4 §2–8、附录 B–I。数字均出自原文正文与表格；堆叠条、刻度尺、留一条形为本项目重绘/示意。作者在真实平台发布了标注 test 的实验资产且无法删除（§6.2）。本项目未运行任何实验，也未对平台做任何操作。另：引言称“128K daily active agents”，数据节写 128,054 个代理。