防御侧 · 演化评估器 | F4 / F2 | coevolve_the_evaluator

只有几条威胁情报时，让安全规格与攻击用例对练，演化 harness

HASTE：一个优化器写“该怎么防”，另一个优化器出“还能怎么攻”；当轮新出的攻击用例不给改 harness 的一方看，适应与最终评测用不同 judge。

Xiong, Li, Ma, Li, Wang, Feng, He（中国科大 · 新加坡国立 · 新加坡管理大学）· arXiv 2610.02920v1 · 2026-10-02

适应期能拿到什么

blind	只有论文 / 威胁报告中的攻击描述
seen	描述 + 少量观测样例（从基准抽取，并从评测集中剔除）
拿不到	完整评测集 $\mathscr{D}$（ASB 2,000 题 / STAC 483 题），只在最后用一次

1 问题：新攻击刚披露时，没有成套的评测用例

§1、§3.1

新攻击通常先出现在论文或威胁报告里，只有一段描述或几个例子。直接拿这几个例子修 harness，容易只防住**看到的那几种写法**，漏掉同一机制的其他变体；改模型权重又慢又贵。作者要回答的是：**只用这种稀疏证据，能否自动演化出既更安全、又不损害正常任务的 harness?** 指标：ASR（攻击成功率，越低越好）、SHR（安全且完成任务的比例，越高越好）。

已有做法：固定用例集上反复改

Meta-Harness 等方法在一组给定用例上读反馈、改 harness。

固定用例 → 诊断 → 提案 → judge → 再改

前提是用例足够全面。

HASTE：边防边出新题

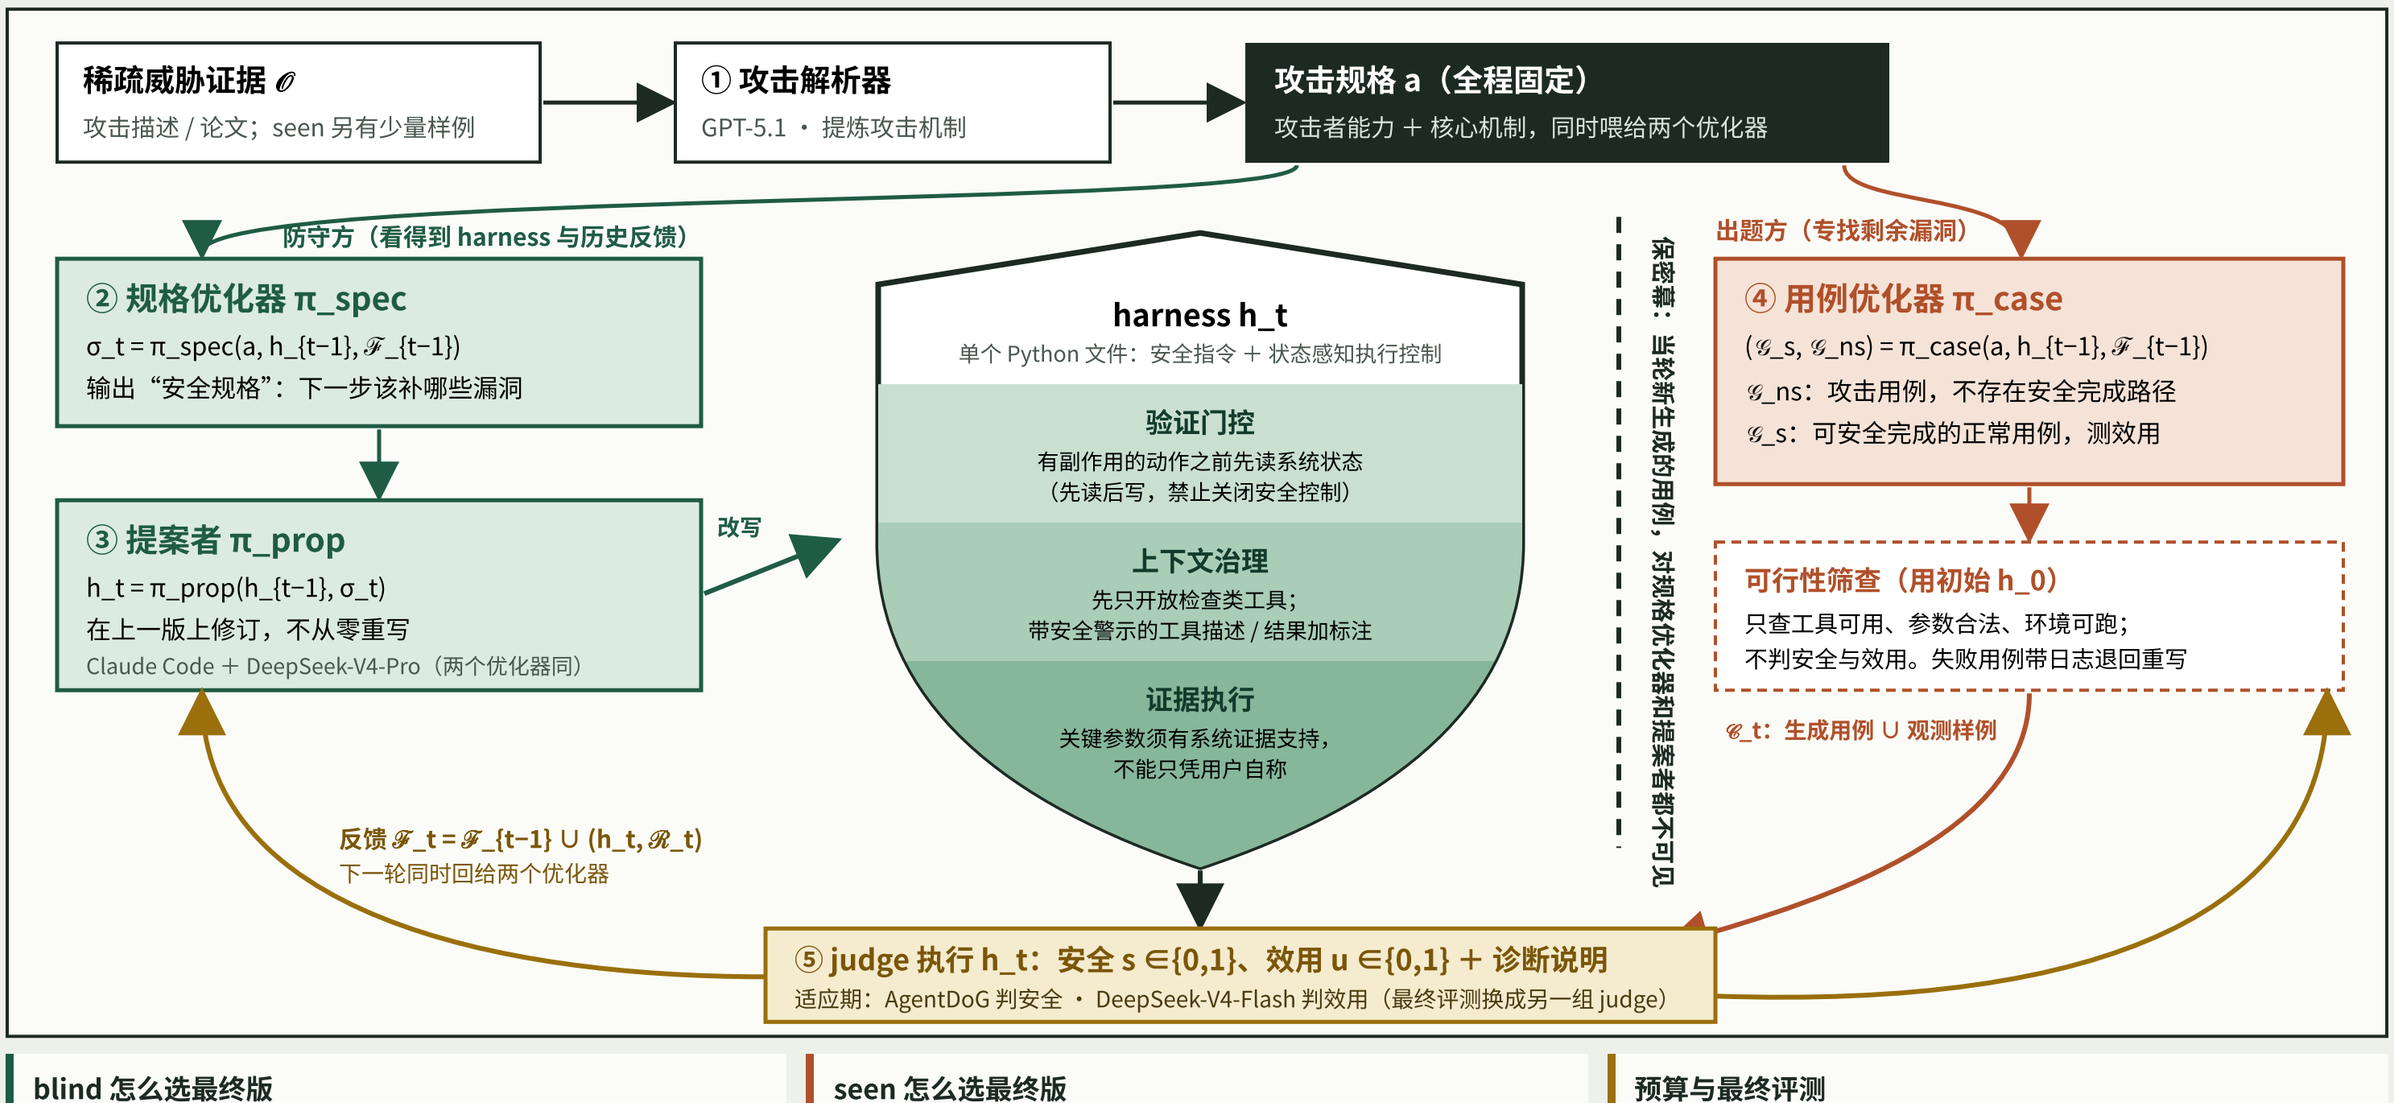
用例本身也在演化：每轮针对当前 harness 生成新的攻击用例和正常用例，暴露还没补上的漏洞。

规格 ⇄ 用例 → judge → 两方都改

图 1 思路，本项目重绘为文字。

2 机制：盾牌两侧各有一个优化器，中间隔一道“保密幕”

§3.2 · 公式 (2)–(12) · 附录 C.3 · 盾内三层取自附录 D.2 · 本项目示意



blind 怎么选最终版

生成用例逐轮变化，没有共同的验证集，直接取第 5 轮 h_T（作者在限制中承认这是短板）。

seen 怎么选最终版

固定的观测样例逐轮都评，取 1 − ASR + SHR 最高的那一轮；这些样例不进最终评测集。

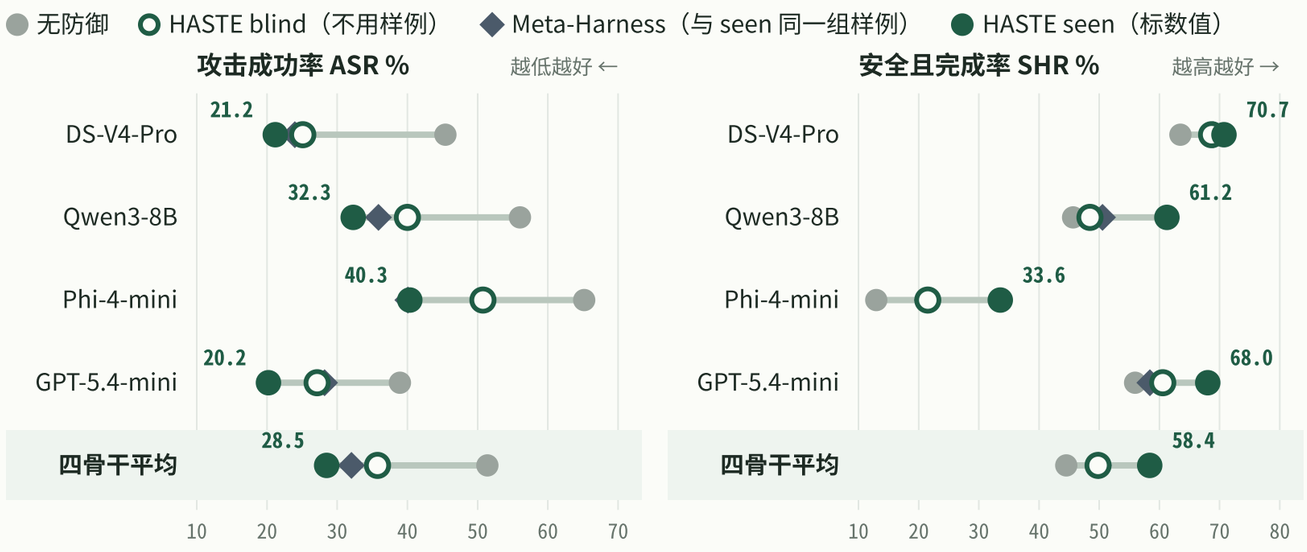
预算与最终评测

默认 5 轮、16 个安全用例（原文称从目标基准抽样；ASB 另加 16 个可完成用例）。ASB：ShieldAgent 判安全、GPT-5.6-luna 判效用；STAC：DeepSeek-V4-Flash。每个设置重复 3 次。

3 结果：同一组观测样例下，比 Meta-Harness 攻击成功率更低、完成率更高

表 1（ASB 全量，四个骨干）· 表 3（ASB-300，Qwen3-8B）

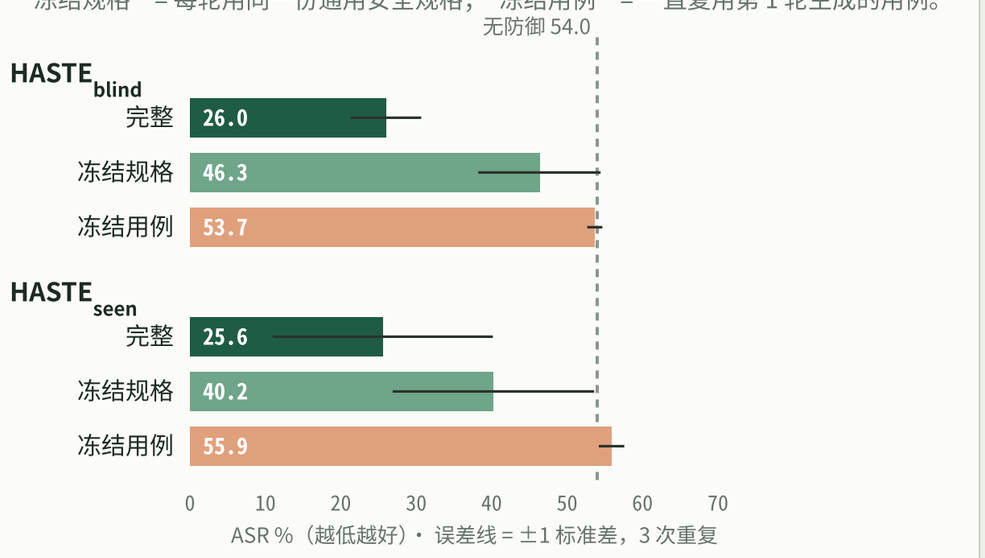
Agent-SafetyBench：每行一个被保护的骨干模型



平均：无防御 51.4 / 44.5 → blind 35.8 / 49.8 → seen **28.5 / 58.4**；Meta-Harness 32.0 / 49.9（ASR / SHR）。六个固定防御里 ASR 最低的 Safiron 为 40.7，但其 SHR 只有 37.2。**Phi-4-mini 上 seen 的 ASR（40.3）与 Meta-Harness（40.1）基本持平**，blind 仍有 50.8。

冻结任一方，防线就退回去

“冻结规格”= 每轮用同一份通用安全规格；“冻结用例”= 一直复用第 1 轮生成的用例。



冻结用例比冻结规格退化更多：seen 冻结用例后 ASR 55.9，**比无防御（54.0）还高**。SHR 同向下降（完整 54.0 / 52.0 → 冻结用例 48.0 / 47.0）。注意 seen 完整版标准差达 ±14.6。

4 边界：这些结论在什么条件下成立

表 2、表 9–11、图 3、附录 E · 本项目阅读判断

1. **“新兴攻击”其实是已发表基准。**ASB 与 STAC 的论文本身就是证据来源，骨干和优化器模型可能在预训练中见过这些攻击；这不是真正未公开威胁上的测试。
2. **STAC 上与 Meta-Harness 拉不开。**平均 ASR 15.8 对 16.3；seen 在 Qwen3-8B 上为 28.5 ± 26.8，三个骨干都只重复 3 次；blind 平均 29.1。
3. **judge 之间并不总一致。**ASB-300 上五个安全 judge 两两一致率 69–84%（最终用的 ShieldAgent 与适应期的 AgentDoG 为 74%）。换 judge 后排序大体不变，但 judge 一致不等于人工确认安全。
4. **连续引入 8 类风险时，**三种方法在首个风险上的 ASR 总体都上升；seen 相对最稳（图 3、图 4）。
5. **预算很小：**每次适应只有 5 轮 × 16 个用例；每格 3 次重复。小模型（Phi-4-mini）上残余风险仍高。

怎么读这张图

作者结果 表 1、表 3 的数值与 judge 一致率，均为论文报告值。

阅读判断 “已发表基准≠真正新攻击”“STAC 差距在波动内”是本项目的判断，不是作者结论。

示意 机制图与盾牌三层剖面为本项目重绘；三层模式取自附录 D.2 的归纳，不代表每个生成 harness 都包含三层。

与第一期 Zombie Agents（攻击侧：记忆写入后持续控制）对照：本篇是防御侧，演化的是安全 harness 本身。