检 验 报 告

HarnessRSI Reel · arXiv:2610.29005v1 · Li, Yuksel, Tur, Hakkani-Tür, Maia（UIUC / aiXplain）

| 送检对象 | 主样本 | 参照标准 | 执行器 |
|---|---|---|---|
| 由代理合成的可执行评估器 | MCPMark Filesystem 全部 30 个任务 | MCPMark 官方 verifier（不给任何模型看） | Claude（强） / GLM-5.2（弱） |

# 自己出的考卷全对，真实搜索状态里才露出缺口

VeriEvolve 先从任务指令合成“挑战状态”和可执行评估器，再用冻结的评估器作 fitness 演化工作流；两个执行器终态的差异再用来修补评估器。

## 01 问题

有状态的工具任务（文件系统、数据库、浏览器、仓库）由最终环境状态判对错：文件在不在、内容、层级、一致性、有没有误伤别的东西。这些约束隐含在指令里，没有现成的可执行 fitness。

人写 verifier 可靠但贵（MCPMark 报告每个任务与 verifier 需数小时专家工作）；LLM 评审易扩展，但语义判断不能保证每条状态约束都成立。

**本文问：**代理能否自己合成一个足以指导工作流改进的评估器？只在“成功可从状态观测、且有外部 verifier 可校准”的有利设定下作可行性检验。

**外部 verifier 站在环外**

源码、判定、诊断从不给任何模型角色，也不用于排序工作流或修补评估器；但它决定哪些评估器进入 S2（事后一致率 ⩾0.85）、哪些被接受状态算假阳性从而触发 S3，且 $F^+$ 本身是它接受的状态。

## 02 研究动作：评估器先行

**S1 造评估器**
指令 + 初始状态 → 正例 / 干净负例 / 对抗近似错例，由确定性适配器落成真实状态 → 合成评估器，过内部门槛（正例接受 ⩾0.90、对抗拒绝 ⩾0.80）
冻结 $E^{(0)}$

→

**S2 演化工作流**
5 个功能节点（理解、规划、ReAct 执行、产物检查、后处理），每节点保留多个备选；评估器给部分分数与逐项检查证据
评估器全程不变

→

**S3 修评估器**
强执行器状态 $F^+$ 对弱执行器被接受的状态 $F^-$ 做差异 → 成对反事实用例（只改一处）→ 局部修订；须接受 $F^+$、拒绝旧假阳性、保留所有旧判定才晋级
冻结 $E^{(k+1)}$ 后重跑 S2

## 03 两张化验单：同一批冻结评估器，换一批状态

Filesystem · 与外部 verifier 对照

A · 在自己生成的挑战状态上

**141/141**

30 个评估器全部建成；141 个状态（其中 62 个对抗近似错例）全部与外部 verifier 一致

B · 在执行器搜索中实际到达的状态上

**113/122**

92.6%（95% CI 86.6–96.1）；仅 60 个最终状态时 57/60

| | 外部 verifier 判通过 | 外部 verifier 判失败 |
|---|---|---|
| 内部评估器 判通过 | **41** 一致 | **3** 假阳性 → 触发 S3 |
| 内部评估器 判失败 | **6** 假阴性（4 个任务） | **72** 一致 |

| 执行器 | 状态 | ✓/✓ | ✓/× | ×/✓ | ×/× |
|---|---|---|---|---|---|
| GLM-5.2 | 85 | 18 | **3** | 1 | 63 |
| Claude | 44 | 30 | 0 | 5 | 9 |
| **合计（去重）** | 122 | 41 | **3** | 6 | 72 |

内部/外部；7 个状态两执行器都产生过，合计时只算一次（原文 Table 2）。精确率 93.2%，召回 87.2%，特异度 96.0%。

**读法：**在生成套件上的“全对”不保证覆盖完整。搜索会主动走到评估器没想到的状态，错误两个方向都有。

B 的状态在评估器冻结之后由别的模型在真实任务上产生，从未参与构建；但只保留了每轮评估器打分最高的状态（258 个，去重后 122），作者明言不是独立随机样本。

## 04 冻结评估器指导下的工作流演化（30 个任务）

种子 = 第 0 轮内部选出的最佳候选；每格一个任务

| | | 第 0 轮种子 | | 演化后 | 得 / 失 · McNemar |
|---|---|---|---|---|---|
| **GLM-5.2（弱）** | 外部验证 | **6/30** [0.10, 0.37] | → | **18/30** [0.42, 0.75] | **+12 / −0** $p < 0.001$ |
| | 内部评估器 | **8/30** [0.14, 0.44] | → | **21/30** [0.52, 0.83] | **+13 / −0** $p < 0.001$ |
| **Claude（强）** | 外部验证 | **27/30** [0.74, 0.97] | → | **30/30** [0.89, 1.00] | **+3 / −0** $p = 0.25$ |
| | 内部评估器 | **24/30** [0.63, 0.90] | → | **30/30** [0.89, 1.00] | **+6 / −0** $p = 0.031$ |

深色 = 外部 verifier 通过，浅色 = 内部评估器通过；格子按数量填充，顺序不对应具体任务。方括号为 Wilson 95% 区间（原文 Table 14）。GLM 演化后被内部接受的 21 个状态中 18 个外部通过（内部精确率 85.7%），剩下 3 个就是上面的假阳性。

## 05 用强弱执行器的状态差修补评估器：3 个假阳性全部修掉

| 任务 | 差异暴露的漏检约束 | 修订 | 弱执行器之后 |
|---|---|---|---|
| `uppercase` | 精确文本与结尾换行（原检查用 .strip() 放宽了） | $E^0 \to E^1$（1 次调用） | **仍未做对**，内外都判失败 |
| `debugging` | 必须出现所要求的固定代码片段 | $E^0 \to E^1$（3 次调用，2 次被回归检查拒绝） | **仍未做对**，内外都判失败 |
| `structure_mirror` | 缺失的嵌套目录与叶目录占位文件 | $E^0 \to E^1$（1 次调用） | **第 3 轮收敛，内外都通过** |

三例都由外部 verifier 选出，$F^+$ 都是外部 verifier 接受的 Claude 状态；修订本身只接收指令、两个状态、当前评估器与挑战集。修补调用共约 64K token，不到 S3 总 token 的 1%，其余花在修订后重跑弱执行器搜索（49 轮）。structure_mirror 的第二轮由文件同步产生的重复目录触发，已排除。

**structure_mirror：$E^{(0)}$ 只检查了 8 个空叶目录中的 5 个**




GLM-5.2 的状态少了另外 3 个 → $E^{(0)}$ 照样通过，外部 verifier 拒绝。差异聚成三簇（缺目录、缺占位文件、目录留空），6 个成对用例 → 补齐路径的 3 行修订 → $E^{(1)}$ 通过累计回归。

示意：按原文 Figure 2 文字重画，目录名与位置为示意。

## 06 代价与其他环境

| | |
|---|---|
| Filesystem S2 · GLM-5.2：执行器 token / 演化器费用 / 墙钟 | **33.18M · $31.24 · 43.5 h** |
| Filesystem S2 · Claude（不含 prompt cache 读取） | **0.58M · $1.74 · 5.3 h** |
| Filesystem S3（三例合计） | **8.10M · $3.49 · 4.6 h** |
| PostgreSQL：建成评估器 / 生成状态一致 | **18/21 · 115/120** |
| PostgreSQL：进入 S2 / 任一执行器解出 | **15 · 3（另 12 个都未收敛）** |

S1 成本未记录。PostgreSQL 从未产生触发 S3 的假阳性；Playwright、Notion、GitHub 只是较小或不完整的压力测试。作者：评估器可用后，瓶颈转向搜索与执行。

## 07 限制（作者已写明的为主）

- **不是无 verifier 闭环：**准入、假阳性的发现、参照状态 $F^+$ 都依赖外部 verifier。回溯测试的替代触发“强弱状态有任何差异”能抓到 3/3 假阳性，但同时误报 18 个正确状态中的 10 个。
- **无等预算基线：**每个 Filesystem 条件只跑一次，演化结果只与自己的第 0 轮比较，作者承认部分增益可能来自反复采样而非评估器指导。
- **同源：**挑战集生成与评估器构建都用 Claude；S1 的 verifier 信息隔离是流程约定，S3 才有数据包级技术隔离。
- **3/3 不是可靠率：**修订后的评估器没有在未参与修订的新状态上再检验；$F^+$ 出错时修订会怎样未测。

来源：Li et al.，“VeriEvolve: Evaluator-First Evolution for Tool-Using Agents”，arXiv:2610.29005v1（§ 1，§ 3– § 8，Tables 1–4，附录 D.2–D.4，E.6）。逐数出处见 SOURCE.md。

流程、格子与目录树为本项目示意或按原文数字重绘。本项目未运行实验，未复现。