能自己搭出 harness，不等于能把它改好

同一个模型经固定编码引导（OpenCode）从最小仓库自建 ARC-AGI-3 游戏 harness，凭 5 个开发游戏的反馈改写两次；三个冻结版本全部在 20 个从不提供反馈的游戏上评测。

开发游戏（5 个）均值变化 H0→H2	留出游戏（20 个）均值变化 H0→H2	适应差距 G_2 = 开发增益 − 留出增益	27 条谱系里 H2 对 H0（留出）
+8.42	**+2.80**	**5.62**	**15 升 · 12 降**
RHAE 分；这些游戏的反馈直接驱动了修订	95% 区间 [−1.44, 7.35]，含 0	95% 区间 [1.78, 9.77]	无平局；符号检验 p = .70

问题

开发集涨分，能当作“自我改进”吗？

自改 harness 的研究常用演化曲线或开发集分数说明进步。作者把四种能力拆开：①搭出能运行的 harness；②修复接口与生命周期错误；③把执行证据变成具体修改；④**选出能在未见任务上变好的修改**。前三项不蕴含第四项。

若把“初始能力强”或“开发集涨分”当成更新能力，就会部署不迁移、甚至丢掉已有本事的修订。

研究动作

固定谱系协议：每一版都冻结，每一版都在留出游戏上评

H0 初始构建
最小仓库 → 候选 → 控制器在 2 个开发游戏上做冒烟检查（只查能否运行，不看分），失败可修 ≤10 次 → 冻结
在 5 个开发游戏上运行

→

H1 修订 1
输入：自身源码、轨迹、得分、动作、推理费用（固定反馈包）。可改任意文件，也可保留父版本 → 冒烟检查 → 冻结
再跑 5 个开发游戏

→

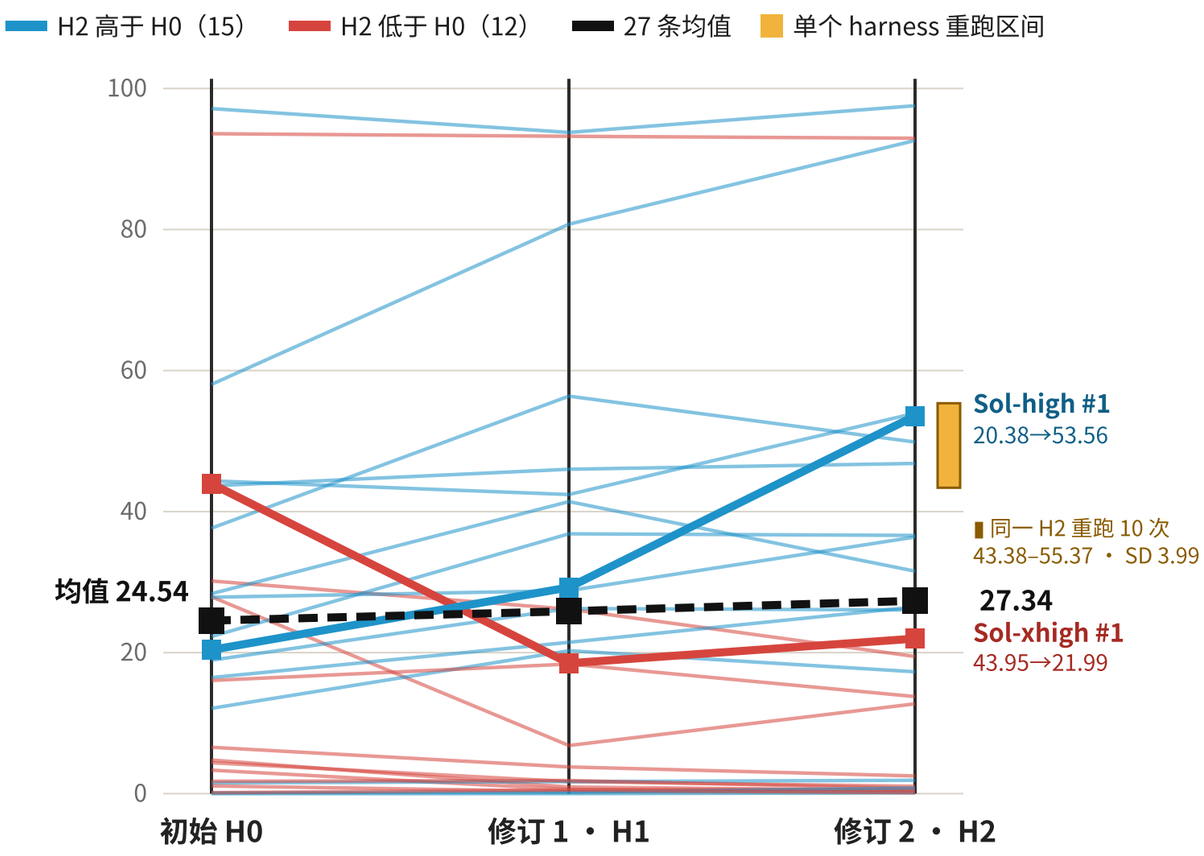
H2 修订 2
同一流程；主终点就是 H2，不按留出成绩挑版本。两版之间没有任何人工编辑或自然语言指导
只评测，不再修订

20 个留出游戏：H0、H1、H2 各评一次；不参与提案、接受、停止或选择。开发游戏在战役前随机选定（tr87 · vc33 · r11l · bp35 · ft09）。动作在本地与官方服务重放核分。

固定不变：模型与推理强度（构建与游戏同一 profile）、OpenCode 引导、无联网、无跨游戏状态；24 小时 / 1 GiB 上限。**没有统一的推理美元或调用上限**，费用只记录。

谱系图

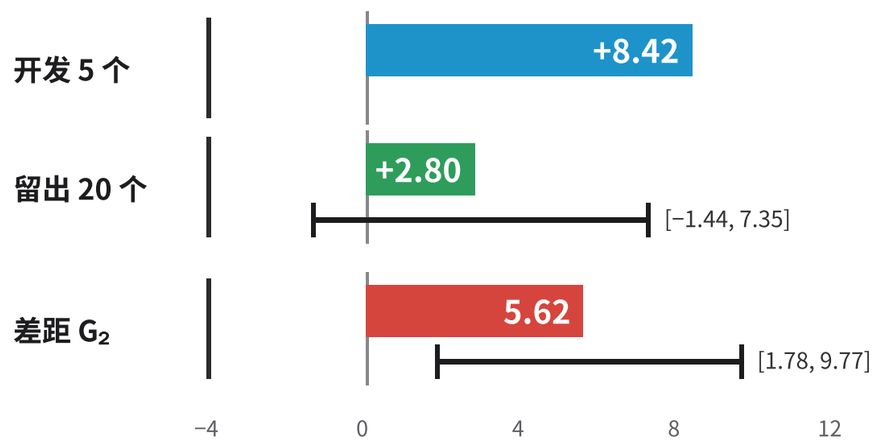
27 条谱系在留出游戏上的走向



按原文附录 D Table 3 逐行重绘（纵轴为 20 个留出游戏的平均 RHAE，0–100）。Claude Sonnet 5 #3 在表中两位小数同为 0.14，作者按未取整值计为下降。黄色区间是作者事后选定的一个 harness（Sol-high #1 的 H2）在同样 20 个游戏上重跑 10 次的结果，其余快照都只评测了一次。底部 9 条近零的线是 Terra、Luna、Sonnet 各 3 条谱系（始终在 0–5 分）。

关键结果

开发增益高估了迁移



区间为对整条谱系做 100,000 次自助重抽的 95% 百分位区间，只描述这 27 条谱系与这一游戏划分。单独去掉开发游戏 r11l，差距从 5.62 降到 3.02（作者的描述性影响检查）。

事后诊断：用开发分挑版本会怎样

部署策略	留出 RHAE	较 H0	$/游戏
保留 H0	24.54	0.00	10.30
总是部署 H2	27.34	+2.80	7.57
按开发 RHAE 选 H0/H1/H2	**29.06**	**+4.53**	**9.15**
留出 oracle（仅作参照）	30.66	+6.13	9.80

按开发分选择在 9/6/12 条谱系里分别选中 H0/H1/H2；+4.53 的 95% 区间 [0.81, 8.68]。这是事后计算，没有作为预先设定的策略检验过。所有修订版都改了实现，没有一次选择“保留父版本”。

分数 × 成本

H0→H2：变便宜的一半在丢分

	留出 RHAE 上升	留出 RHAE 下降
每游戏更便宜	**9** 两项都变好	**9** 省钱但丢分
每游戏更贵	**6** 花更多换分	**3** 两项都变差

原文附录 D Table 7（H0→H2，27 条）。均值每游戏省 $2.72，中位只省 $0.54。全部实验按冻结价目表至少 $18,129.27。

修订行为（探索性）

“看了证据、改了对的地方、通过检查”仍不保证变好

- 54 次修订全部检查了逐游戏开发证据，最终 diff 都至少针对一个有证据的问题，并都通过了运行检查——但留出结果有升有降。
- 第一次修订 27 次中 22 次“改变策略方向”（控制优先级、上下文、重放、动作 / 推理调度）；没有一次更换整个 harness 族。
- 大范围重写平均 +3.75，局部改动 −0.20；改完即交付的 36 次平均 +2.48，看到结果再改的 18 次 −0.76。两项对比的区间都含 0。
- 标注由 GPT-5.6 Sol 对屏蔽结果的记录做两次独立编码；未与人工标注比对。诊断（κ=0.35）、保护现有能力（0.47）、资源元推理（0.29）低于预设 0.67 可靠性阈值，不用于解释。

限制与边界

- 一个基准、一组 5 个开发游戏、只改两次；更长的改进序列和其他任务仍未知。
- 没有统一推理预算，也没有“更新者 × 使用者”交叉，模型之间的排名只是描述，不能分离模型、harness 设计与花费的作用。
- 每个快照只评测一次；一个 harness 重跑 10 次 SD 3.99，单条谱系几分的变化难以解读。
- 公共游戏可能出现在预训练中。人类引导系统（Tycho 等）在同一批游戏上报告 100 RHAE，但其开发与选择流程不同，不能据此量化“人类引导”的贡献。

来源：Lehmann & Vahdati，“Can LLMs Improve Their Own Harness? A Controlled Study on ARC-AGI-3”，arXiv:2610.30499v1（§2，§4–§8，附录 A, D, E）。逐数出处见 SOURCE.md。

谱系图、四象限与条形为本项目按原文表格重绘；顶部像素条为装饰。本项目未运行实验，未复现。