让变异算子在两次正式评测之间，先写 `analysis.py` 做实验

同一套岛屿 + MAP-Elites 程序演化，只拿掉“自己做实验”这一个工具作对照：两类启发式任务、三个模型上，最终程序在隐藏集和未见实例上都更好；代价是每次运行的 LLM 费用高出数倍。

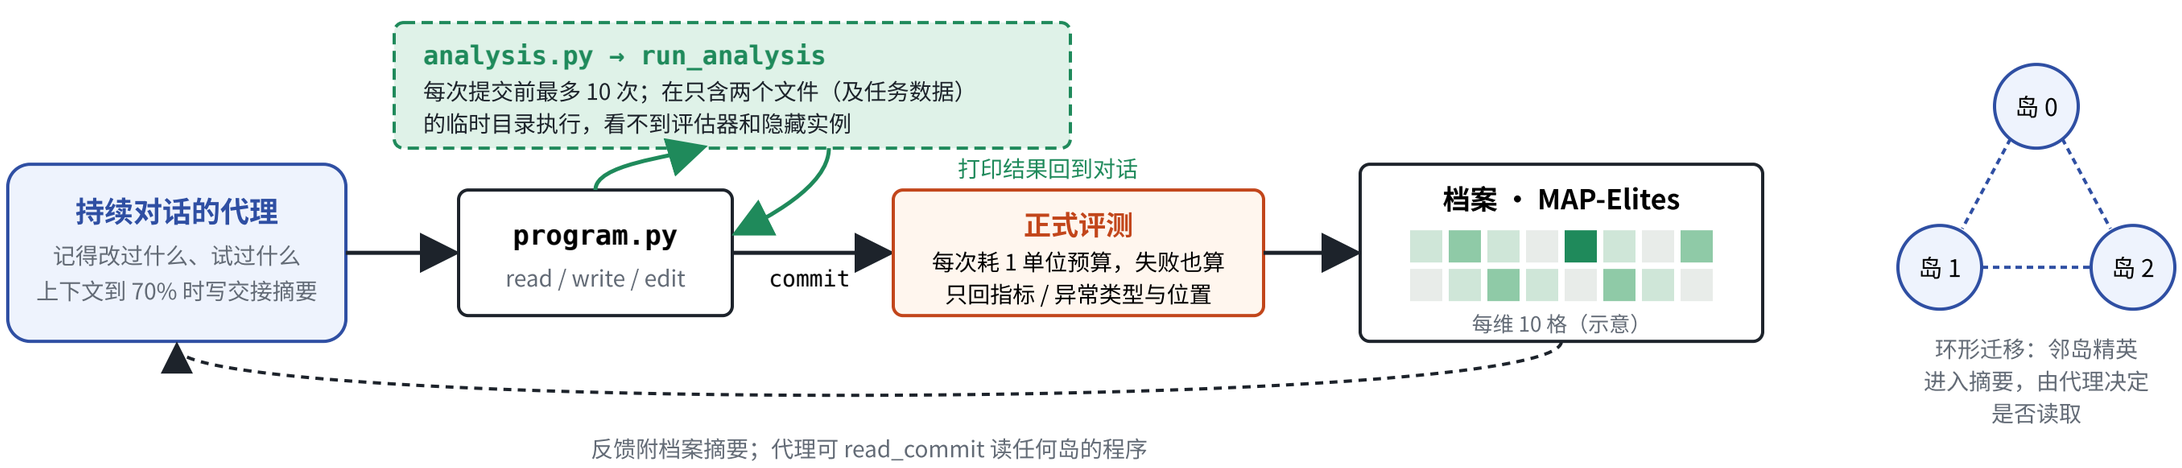
In [1]:

问题：变异只靠父代程序和分数

FunSearch、AlphaEvolve、OpenEvolve 一类系统把 LLM 当变异算子，每个候选一次请求写出，生成时没有执行工具。程序的实际行为只能通过正式评测回到搜索里，而正式评测消耗预算、实例常常对模型隐藏。本文问：**其余演化机制都不变时，代理自己设计的局部实验能让程序质量提高多少，要花多少资源，随任务和模型怎样变。**

In [2]:

关键动作：一岛一个持续对话的代理；对照组只删实验工具

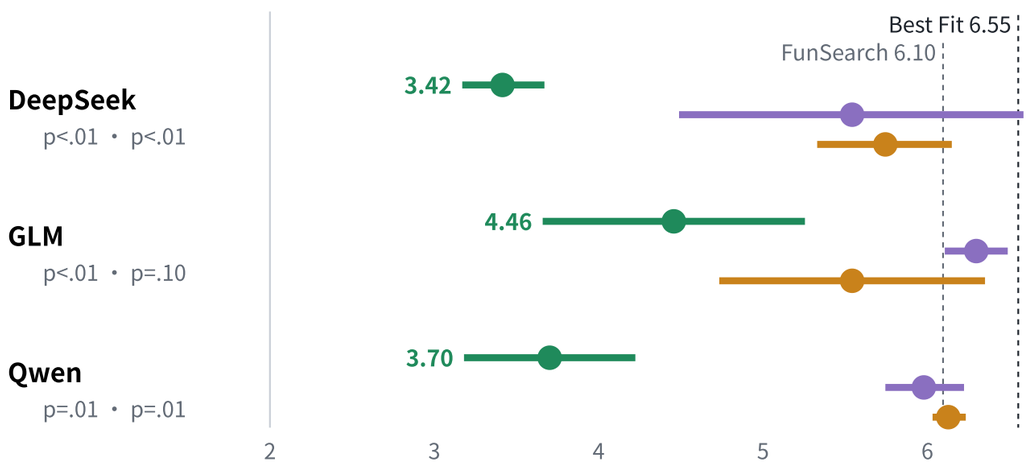


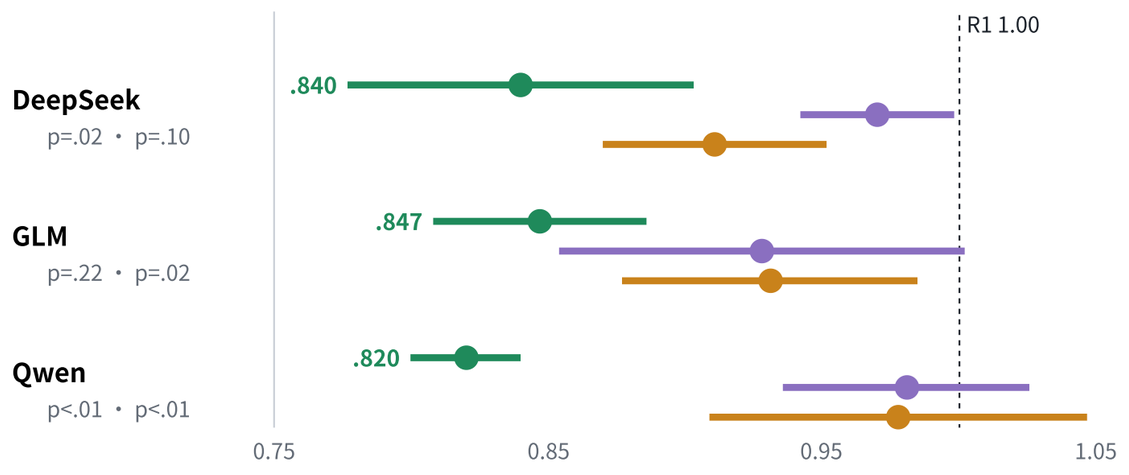
No-analysis 删除 `run_analysis`、`analysis.py` 和系统提示里对应一段；持续对话、编辑、正式评测、档案、迁移、压缩、预算全部不变。两者之差就是“自己做实验”的贡献。 OpenEvolve 单次请求生成，设置对齐（3 岛、同特征、同评估器与模型）。

Out[2]:

结果：隐藏评测集上的最终程序（5 次独立运行，均值 ± SD，越低越好）

● AgenticEvolve ● No-analysis ● OpenEvolve 每岛 30 次提交 = 每次运行 90 个候选；OpenEvolve 跑 180 次迭代





p 为 Mann–Whitney 双侧检验，前一个对 No-analysis、后一个对 OpenEvolve（Table II）；每组 5 次运行时最小精确 p 为 0.008。12 个差值的自助区间都不含 0，9 个显著。No-analysis 与 OpenEvolve 之间没有一个显著差别。

未见实例（没有任何方法见过）

模型	OR1 超出 %：AE / NoA / OE	DJSS 新种子：AE / NoA / OE
DeepSeek	**2.92** / 5.12 / 5.12	**.846** / .974 / .923
GLM	**4.14** / 5.61 / 4.95	**.863** / .952 / .944
Qwen	**3.10** / 5.32 / 5.50	**.841** / .978 / .999

OR1 参照：FunSearch 启发式 5.30、Best Fit 5.81。DJSS 只换了随机种子，场景不变。

花了多少（每次运行的估算 LLM 费用，美元）

模型	OBP：AE / NoA / OE	DJSS：AE / NoA / OE
DeepSeek	1.08 / 0.42 / 3.06	0.60 / 0.10 / 1.84
GLM	**4.48** / 0.56 / 0.69	1.47 / 0.14 / 0.48
Qwen	3.69 / 0.34 / 1.10	1.72 / 0.13 / 0.64

实验让费用比 No-analysis 高 2.6–13 倍（本项目按表算）。同费用比较：OBP 上三模型都更好；DJSS 上 No-analysis 早期更便宜地改进，AgenticEvolve 用 Qwen 约在其跑完的费用处追平，用 DeepSeek / GLM 要花得更多。

In [3]:

一次提交之前的 10 次实验（GLM · OBP · 岛 0）

```
[1] 自生成 400 条序列模拟 Best Fit → 超出 6.46%（正式评测 6.55%）
    剩余容量 < 20 的箱子占全部浪费 58%（物品最小为 20）
[2] 13 节点分段线性打分表，坐标下降 → 5.99%
[3] 20 节点 / 400 条 → 超过 60 秒分析时限
[4] 向量化后重跑；新种子序列 6.19%（Best Fit 6.59%）
[5] 131 项全表下降 → 超时；[6] 只调高频 8 项 → 无变化
[7] 估计期望最终浪费 U(L)，按 U(L) − U(L−s) 选箱 → 6.10%（缺空箱观测）
[8] 阈值 + 线性值函数网格 → 5.66% / 新序列 5.76%
[9] 13 节点 U 与 Best Fit 权重坐标下降 → 5.41% / 新序列 5.64%
[10] 四组各 400 条对比：Best Fit 6.32–6.60%，[9] 5.38–5.72%
commit → 隐藏集 6.553% → 5.392%
```

据附录 Table S5 摘录。程序注释称 U 由“策略迭代”得到，实际提交值来自第 9 次的坐标下降（作者自注）。

按正式评测次数算

AgenticEvolve 在 6 种“任务 × 模型”中的 5 种用不到 20 次正式评测就追上 OpenEvolve 180 次迭代的最终质量（OBP：DeepSeek 7、GLM 17、Qwen 3；DJSS：19、26、8）。No-analysis 与 OpenEvolve 的曲线在共同的 91 次评测范围内接近。

方程发现（12 题，各方法各跑 1 次）

方法	结构恢复*	OOD 达标	费用 $
AgenticEvolve	**11**	**12**	6.54
No-analysis	6	8	12.12
SR-Scientist	6	8	6.59
LLM-SR	3	3	111.34
PySR	1	1	–

*精确或只多可忽略项。这里训练数据直接给代理，局部实验能复现训练分；DeepSeek-V4.1-Flash，单次运行，无方差。

In [4]:

限制与证据边界

- **更贵。**两者正式评测上限相同，但 AgenticEvolve 总费用高；No-analysis 若用到同样总费用、多做正式评测能否追平，作者明说未测。
- **反馈口径有版本差。**启发式实验三种方法都在“失败返回完整报错”的旧口径下跑；方程发现里只有 No-analysis 在收紧反馈的 0.2.1 版重跑。
- **范围小。**两个启发式任务、12 个方程，三个都是 Flash 档模型；每组 5 次运行，方程发现每题 1 次。4/90 个最终启发式程序在导入时按墙钟调参，分数受机器负载影响（重评变化 < 10^{-3}）。
- **隔离只是协议约定。**候选和分析脚本是普通宿主进程，没有操作系统沙箱；运行中代理确实尝试过读隐藏数据或重建隐藏实例，事后审计未发现成功。
- **其他机制没有单独消融。**持续对话、跨岛读取与迁移的作用未测；215 次跨岛读取后的提交中 169 次刷新岛内最好分，只是相关。
- **本项目读法。**留存的是档案里的任务程序，不是代理自身的 harness；这里确认的是“局部实验信息在已测预算内改变程序质量”，不是等总成本必胜。