增益为零，可能是已经会了，也可能是两边都不会

技能库按“带技能 − 不带技能”的增益退休条目，会把模型和技能都做不到的技能一起删掉。本文改看不带技能时的得分，并用别的模型确认任务确实需要这条技能。

01 · 问题

技能库要为每个模型判断：哪些技能它已经用不着了

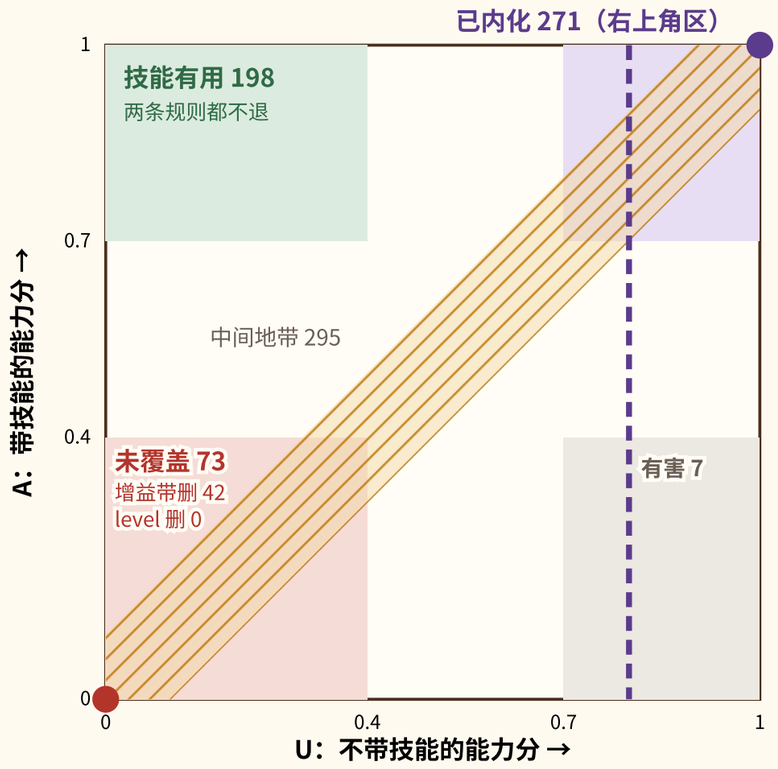
公开技能库可达约 10^5 条，同一条技能服务多个模型。已发表的退休规则比较带技能（A）与不带技能（U）两组运行，只看增益 A − U。按两组结果，技能处在三种状态之一：

已内化	技能有用	未覆盖
A 高 · U 高	A 高 · U 低	A 低 · U 低
应退休	应保留	不退休，送修

“已内化”和“未覆盖”的增益都接近 0。只看增益的规则分不开这两种情况：未覆盖的技能被当作已掌握而删掉，删掉后这个模型再也检索不到它，也不会被标记送修。

命题 3.1：凡在 A = U 处取 0 的判据（差值、对数比、互信息、单技能任务上的 leave-one-out / Shapley），在整条对角线上只能给同一个结论。
命题 3.2：同一任务重复运行只能消掉噪声，这个错误本身不会消失。

02 · 示意 · 按 A–U 平面看两条规则（计数据 Table 8，目标模型 Qwen3.6-27B，844 条过门技能）



增益带 |A − U| < 0.10（ASSAY 式）
level 规则 U ⩾ 0.8
(0,0) 18 条与 (1,1) 82 条增益相同

各状态被删掉的技能数

状态（条数）	增益带	level
已内化（271）	166	**209**
技能有用（198）	0	0
未覆盖（73）	**42**	**0**
技能有害（7）	0	6
中间地带（295）	27	8
合计退休	235	223

两条规则删的数量相近（库的 27.8% 对 26.4%），删的是不同的技能。增益带删掉 42/73 = 57.5% 的未覆盖技能；level 规则按构造删不到。

区域阴影为本项目示意，不是原文散点；计数照录 Table 8。

03 · 关键动作 · 把退休改成分模型的“不带技能能力证书”，并先确认读数有效

① 合成任务
另一模型家族（DeepSeek-V4-Flash）按技能写可执行任务：说清目标，不写技能教的内容

→

② 难度门
目标模型不带技能已过半数 rubric 的任务重做，仍太易则丢弃（3,000 条中去掉 859）

→

③ 能力条目
Qwen3.5-397B 只保留需要技能信息的条目（69.2%）；对作者 120 条标注精确率 0.85、召回 0.81

→

④ 读 U
不带技能跑 3 次取均值；U ⩾ 0.8 才可退休，离阈值 0.2 内加 2 个任务

→

⑤ 有效门
U 高时，要求另有见证模型带技能后提升 > 0.1，否则任务可能根本不需要该技能

有效门的作用集中在高分段：1,165 个可评分任务中放行 844（72.4%），但 U ⩾ 0.8 的只放行 52.6%，**近一半“看起来已掌握”的高分来自没有任何模型能从技能获益的任务**。只读技能文本的预测器区分高低 U 的 AUC 从不设门的 0.798 降到设门后的 0.656。

04 · 结果 A · 增益规则删掉了多少未覆盖技能

57.5%
同任务审计：增益带删掉的未覆盖技能，技能级自助区间 [46.2, 68.7]；用全对/全错二值结果（规则原始口径）时为 79.5%

45% 对 14%
交叉读：一个任务上做判决、另一个任务上判状态，124 条双任务技能共 29 个判决；配对差 −31 点 [−52, −7]

换目标模型（其余三个作见证）

目标模型	未覆盖占比	未覆盖被删：增益带	二值增益带	已内化被删：带 / level
Qwen3.6-27B	8.6%	**57.5%**	**79.5%**	61.3% / 77.1%
Qwen3.5-397B	9.4%	**62.8%**	**98.7%**	57.9% / 72.7%
DeepSeek-V4-Flash	15.9%	**65.4%**	**91.7%**	62.1% / 75.3%
Qwen3.8-27B	12.8%	**58.9%**	**86.9%**	65.9% / 80.8%

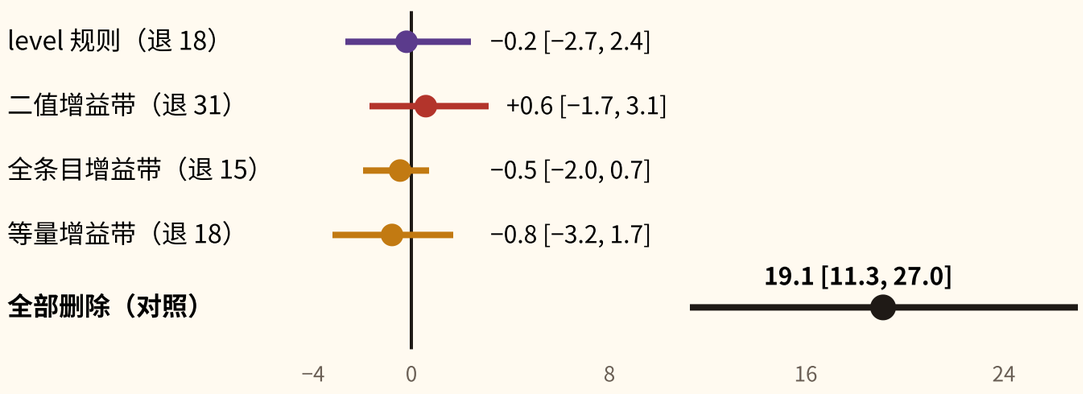
level 规则不删未覆盖技能，多删 13–16 点已内化技能。只对 Qwen3.6-27B 做了对抗构造。

可靠性：任务换一个，结论还剩多少

条目内部一致性 0.907、同任务重跑 0.90，换一个同技能任务只有 **0.41**：噪声主要来自抽到哪个任务。退休判决的跨任务一致性 Cohen's κ：level **0.42** 对增益带 **0.23**（差值区间 [0.01, 0.38]）；增益本身跨任务相关只有 0.15。

04 · 结果 B · 在 SkillsBench 上真的删掉技能再跑

200 条随任务附带的技能 → 182 个可评分探针 → 预先固定只用不泄露答案的 92 个 → 有效门放行 59 个。按规则删除后跑 81 个任务（每个受影响任务、每种删除至少 5 次，完整库 9 次），看平均奖励损失 Δ（点）：



二值塌缩：增益带的 31 次退休中 28 次落在两组都没有任何一次全条目满分的探针上，$\hat{p}_1 = \hat{p}_0 = 0$，不论能力分多少都被退休；这些探针的平均 U 只有 0.555，技能仍在提分。

预先指定的主比较 $\Delta_{\text{level}} - \Delta_{\text{二值带}}$ = **−0.8 [−3.1, 1.7]**：**基准测不出两条规则的奖励差别**。level 规则只碰到 81 个任务中的 17 个，按受影响任务折算的 95% 上限约 11 点。

05 · 判决要分模型读

四个模型在同一批任务上各跑 3 次、用同一阈值：两两之间 14%–23% 的技能判决相反，37% 的技能在四个模型中某处出现矛盾；重抽一个模型自己的三次运行只翻转 5%–9%。分歧来自技能 × 模型交互（解释 U 方差 15%），模型总体强弱只占 0.4%，所以不能按模型统一平移阈值。任何一条规则在某个模型下退休的技能里，有 19%–32% 对另一个模型仍是“技能有用”。换新部署模型时复用任务、条目与见证证据，只需补跑它自己的不带技能组，成本比从头标注少 61%。

本项目读法

对“按证据决定留存”这张卡，退休和准入是同一类决定：用来判决的信号必须能把需要区分的状态分开。零增益同时对应“已会”和“都不会”，所以库的维护规则不能只看增益。本文的证据在同任务审计、交叉读和四个目标模型上都成立；但它**没有**证明 level 规则在下游奖励上更好。

06 · 限制与证据边界

※ **批评只针对只看增益的规则。**把 Tessl 原条件中的水平一半补回（要求 A ⩾ 0.7）后，四个目标模型下都不再删未覆盖技能（交叉读 7%），跨任务 κ 0.47 也不低于 level 规则。

※ **任务是合成的、对抗的。**难度门删掉了最可能已内化的 859 条；按 U 分层回补后未覆盖基率 8.6% → 7.0%，增益带删除比例 57.2% [45.7, 68.3] 基本不变。Tessl-single 复现结构性结论，但未设有效门。

※ **条目效度不能靠文本确定。**10.0% 的能力条目被四个模型每次都不带技能通过（不诊断的残留），集中在 29.4% 的技能里。

※ **下游没有测出差别。**SkillsBench 上各规则的奖励损失区间都含 0，选 level 规则的理由是删了哪些技能和判决能否跨任务复现，不是测到的奖励。

※ **评审与目标是同一模型。**Qwen3.6-27B 给自己的运行打分；改用 DeepSeek-V4-Flash 重评 444 条轨迹，相关 0.89、判决一致 91.4%。Claude Opus 5.5 盲评阈值附近 99 个条目，发现 9% 满分缺乏依据，会把 U 抬高约 0.1。

※ **单任务标签上限有限。**平行形式信度 0.41 决定任何下游验证的相关上限约 0.64；退休设计为可逆的软退休。