表号

MT-1

记忆净值申报表

申报对象：持久代理记忆
参照：直接检索原始历史

arXiv:2610.34073v1 • cs.CL • 2026-10-25 • UIUC / 清华 / 人大 / Verdent.ai / Waterloo

费力建一套记忆，比直接检索原始历史赚还是亏？

Memory Tax: Dissecting the Net Value of Agent Memory —— 多数被测记忆系统交的“税”超过了它带来的“收益”。

项目	HarnessRSI Daily
期别	Reel 第六期
问题族	F1 归因 • F5 单调
卡片	index_experience_for_reuse
核对	Opus 5.5 • 全文

第 A 栏 • 记忆收益
RAG 答错、记忆答对

−

第 B 栏 • 记忆税
RAG 答对、记忆答错

=

第 C 栏 • 净值（相对参照，逐题计）
税 > 收益 → 总分低于 RAG

第一部分 申报口径：怎么比才公平

§ 3.1；附录 A、B

1 **参照**：原始历史分块，BM25 + 稠密检索，重排取 top-k（1 轮 / 2 轮）。分块、检索、嵌入、重排逐项消融，多数变体相差几分以内。

2 **申报方**：11 个开源记忆系统，平铺 3、分层 / 生命周期 3、图 3、RL 训练策略 2。

3 **共用**：同一嵌入与重排模型、同一 QA 提示、同一 judge（Qwen3.6-27B，与人工一致 95.1% / 100% / 97.3%）。

4 **检索量对齐**：按“检索范围”（看到的记忆 token / 自身库总 token）把各系统 top-k 调到不低于 RAG（1 轮），多数是**调大**；作者逐项核验改动不压低对方。

第二部分 总账：相对 RAG（2 轮）的判分差（百分点）

Table 1（据表重绘）

系统		LongMemEval-s（全 500 题）			PersonaMem-v2（20% 分层子集）			MINT-Eval（10% 分层子集）		
		Qwen3.5-4B	Qwen3.6-27B	5.6-luna	Qwen3.5-4B	Qwen3.6-27B	5.6-luna	Qwen3.5-4B	Qwen3.6-27B	5.6-luna
参照	**RAG（2 轮）绝对分**	**72.2**	**81.4**	**90.0**	**36.2**	**48.7**	**48.4**	**26.1**	**33.1**	**34.5**
平铺	A-Mem	−1.8	−2.0	−6.0	−2.5	−0.3	−6.6	−1.7	−8.7	−7.4
平铺	MemOS	−10.2	−4.8	−12.0	+1.0	+1.5	−6.7	−8.1	−13.4	−4.2
平铺	SimpleMem	−12.0	−7.8	−6.0	−1.5	−2.0	−3.3	−7.5	−13.3	−11.6
分层	MemoryOS	−7.6	−8.0	−10.0	+0.9	−0.5	−5.4	−7.2	−6.9	−1.3
分层	LightMem	−14.6	−2.6	−13.0	+0.2	−1.7	−2.5	−5.4	−10.2	−9.3
分层	OpenViking	−40.4	−22.6	−27.0	−4.9	−10.1	−10.2	−15.9	−14.6	−10.3
图	HippoRAG2	−3.4	−3.2	−9.0	−2.3	−2.3	−3.1	−1.5	−9.6	−6.7
图	MAGMA	−11.4	−13.2	−14.0	−3.1	−8.3	−7.8	−2.4	−6.2	−5.0
图	PlugMem	−4.2	−5.6	−20.0	−1.2	−3.5	−8.6	−4.7	+0.1	+3.3
训练	Mem-T	−1.2	−6.4	−12.0	−4.1	−6.6	−7.4	+0.9	−2.7	+3.9
训练	Memory-R2	−6.4	−8.4	−11.0	+2.0	−0.3	−4.2	−4.8	−11.6	−11.6

11 × 9 = 99 格里只有 **9 格**高于 RAG（2 轮）；LongMemEval-s 上 33 格**全部**低于它，最大差 −40.4（OpenViking）。按题拆开，记忆**确实**答对了一些 RAG 答错的题（收益），但同时丢掉更多 RAG 本来答对的题（税）。

逐题收益 / 税的维恩图见原文 Fig. 2、附录 C.1（对 RAG 1 轮），原文文本未给计数，本画报不转述具体数。5.6-luna 在 LongMemEval-s 上为 100 题分层子集。

第三部分 税从哪来：存丢了，还是存了找不到

§ 4.2–4.5；附录 C.2–C.5

5 **保真**：抽 500 条原始对话轮，人工追到对应记忆单元

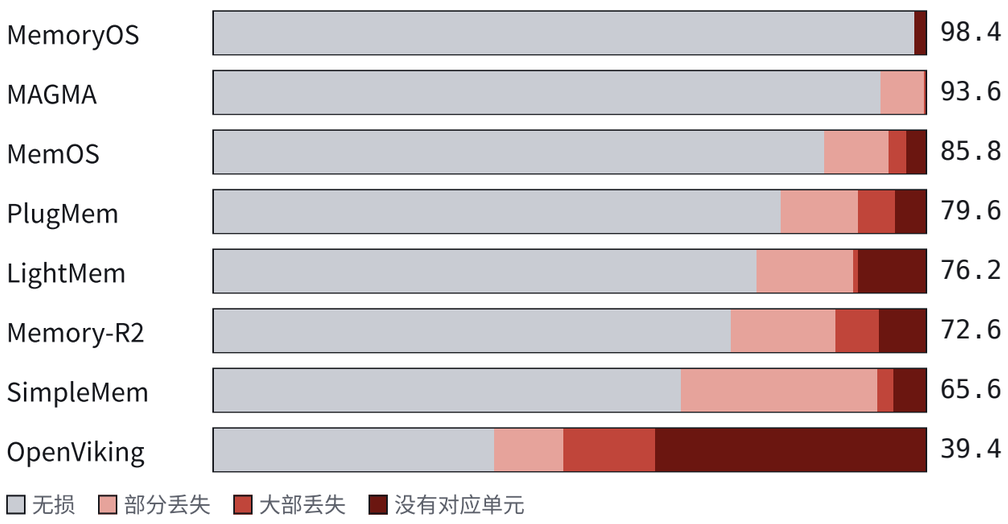


Table 2；附录 C.2。不限于金标证据，一对多映射时给标注员全部候选单元。

6 **可达**：MemoryOS 的样本 **98.4%** 无损，在 LongMemEval-s 上仍低 RAG 7.6–10.0 点。MAGMA、LightMem 直接给金标记忆单元时接近金标原文，却远高于它们自己检索时的成绩：**存住了，但难检出**。逐轮重放检索，记忆系统第一轮召回的金标单元少于 RAG；证据被拆碎、稀释或改写。

7 **稳健**：同一份记忆换 QA 模型，许多系统掉分比 RAG 多（Fig. 6，未给统一数值）。

8 **评测余量**：只取两个最稀有词的关键词检索在 EverMemBench-MCQ 得 68.2、LoCoMo 58.8；混合 RAG 在 15 个基准中 7 个达 69–83。题目偏“直接找原文”，记忆能多赚的空间小，税就更显眼（Table 15）。

第四部分 附表：经验记忆（离自我改进最近的一栏）

§ 5.1；附录 C.6.1 Table 16 • Qwen3.5-4B

训练集积累经验 → 测试时冻结	ALFWorld	WebShop	Mind2Web	BigCode	AppWorld	τ^2-Bench
无记忆（ReAct）	52.2	45.9	48.5	16.9	12.5	61.0
RAG：取最相似的 2 条原始轨迹	**73.1**	**38.4**	**45.3**	**21.6**	**22.6**	**69.0**
Memp（步骤工作流）	**76.1**	**44.5**	**47.9**	20.3	14.3	62.0
ReasoningBank（推理策略）	62.7	34.3	**49.9**	14.9	14.3	51.0
G-Memory（三层图）	**73.9**	**39.5**	**47.0**	20.3	22.6	**78.0**
SkillPro（演化技能池）	47.0	**42.5**	43.6	11.5	10.7	55.0

绿 = 高于 RAG 行，红 = 低于。WebShop 上 RAG 本身低于无记忆。SkillPro 在 ALFWorld 每题约 1,226K token，RAG 为 235K。单骨干、单次运行。

申报说明（限制）

☐ 检索范围是**相对**比例，不等于等 token / 等算力；单元很少的系统（OpenViking）固定 top-k。

☐ 后两套基准为子集；无重复构建的方差；金标单元映射有 LLM 辅助。

☐ “税”相对所选参照定义；不说明记忆普遍有害，web 类经验任务中抽象可以更好。

☐ § 6 的两条改进（保留回原文的路径、把检索经历写回记忆）在全文文本中缺结果表，本画报不展示。

本项目读法：一次持久记忆升级要晋级，先和“直接检索同一份原始历史”比，并按题分开记账收益与税；只比哪套记忆分更高，会把“存丢”和“找不到”的损失藏进总分里。这是可放进自我改进闭环的 B 类审计口径。