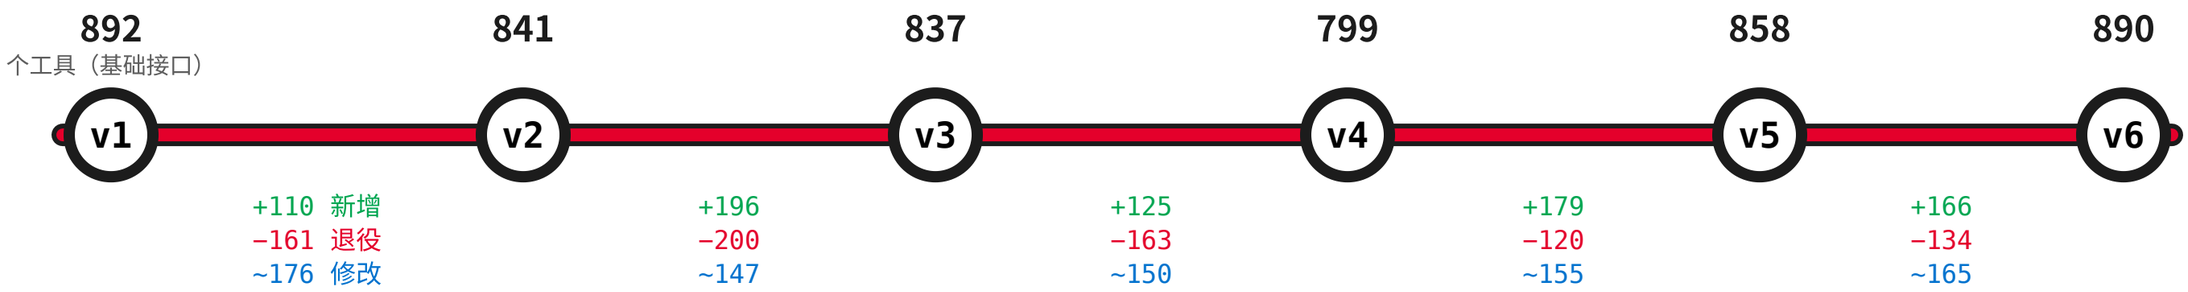
arXiv:2610.34238v1 · cs.CL · 2026-10-25 · 浙江大学 / 伦敦大学学院（Shuofei Qiao, Xuanguang Pan 等）

Δτ-Bench：工具一直在换，留下的技能跟得上吗？

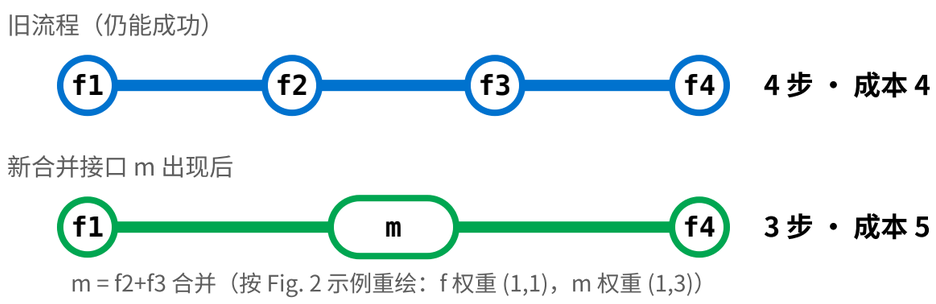
把大型工具生态的演化做成可执行基准：42 个领域、1,588 个多轮任务、**六个依次演化的生态版本**。旧接口会退役、拆分、合并，更省的路径会出现——**任务成功率会掩盖错过的更短路径**。最强模型 / harness 成功率仅 42.3%；现有技能学习方法起步有益，却跟不上后续变化。作者提出 STEWARD：按工具依赖增量维护技能，并在执行中按需供给工具与流程。

01 线路图：同一意图、同一目标状态，六个版本的可用接口不同



每次转换只施加有限个“保能力”的变换：① 一对一（改名、加参数、换格式）② 一拆多 ③ 多合一（只合并已验证轨迹里相邻的调用）。新接口可与旧接口并存（要在重叠中选），也可直接替换（旧流程断掉）。每个版本都校验所有基础能力仍可通过现役接口达成；可选地扰动部分描述，模拟残缺或过期文档。训练 1,191 / 测试 397 个意图 × 6 版本 = 9,528 个任务-生态实例。

02 成功率看不到的损失



m = f2+f3 合并（按 Fig. 2 示例重绘：f 权重 (1,1)，m 权重 (1,3)）

参考路径由动态规划在**构造出的实现空间内**分别求“最少步数”与“最低成本”。只看成功率（终态数据库变化覆盖金标变化）时，继续走旧路的代理不会被扣分；本文另设 **SPE**（成功加权的路径效率）、**IDR**（最优路径变短 / 变便宜的任务上是否发现新路）、**DAR**（最优路径变长时能否恢复）。

03 模型：找得全、挑不准、走不省

模型 / harness	成功率	检索召回	检索精确	Step-SPE	SPE/SR
Codex-GPT-5.5	**42.27**	**90.36**	**19.90**	**26.93**	**63.71**
Gemini-3.6-Flash	41.65	87.51	19.30	25.49	61.20
GPT-5.5	31.74	81.08	20.21	23.11	72.81
Claude-Sonnet-5	29.97	76.93	19.36	20.48	68.34
DeepSeek-V4-Pro	33.29	79.00	18.65	13.49	40.52
GLM-5.2	32.28	78.25	19.32	19.39	60.07

召回近九成、精确不到两成：相关工具多半拿到了，却排除不掉无关和过期的。DeepSeek-V4-Pro 成功率高于 GLM-5.2，Step-SPE 反而低一截——**成功不等于高效**。逐级给提示（领域内 → 任务涉及 → 仅现役相关工具）成功率与 SPE 逐级上升；再给出参考路径几乎不再提升，差距主要在“认出现役且高效的接口并用对”，不在高层规划。

表摘自 Table 1（另有 Qwen-3.8-Max、Kimi-K3、GPT-oss-120B，成功率 27.00–30.10）。消融为 Fig. 3，原文只给图。

04 现有技能方法：起步有益，换站就掉队

同一任务模型（DeepSeek-V3.2）下比较 EvoSkill、AutoSkill、Trace2Skill、SkillOpt 与不用技能。v1 四种方法的成功率与 SPE 都高于不用技能，但：

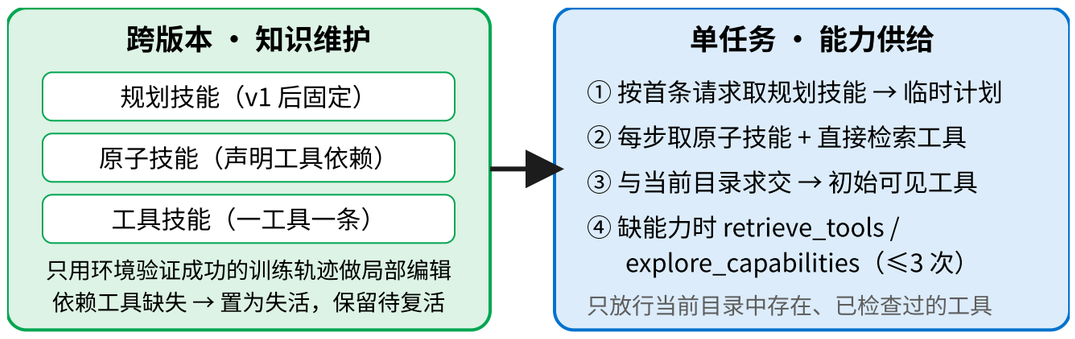
v3 的 DAR（最优路径变长时的恢复）



条长按 Step-DAR 绘制（11.11 = 300px）；其余版本数值原文只以 Fig. 4 给出

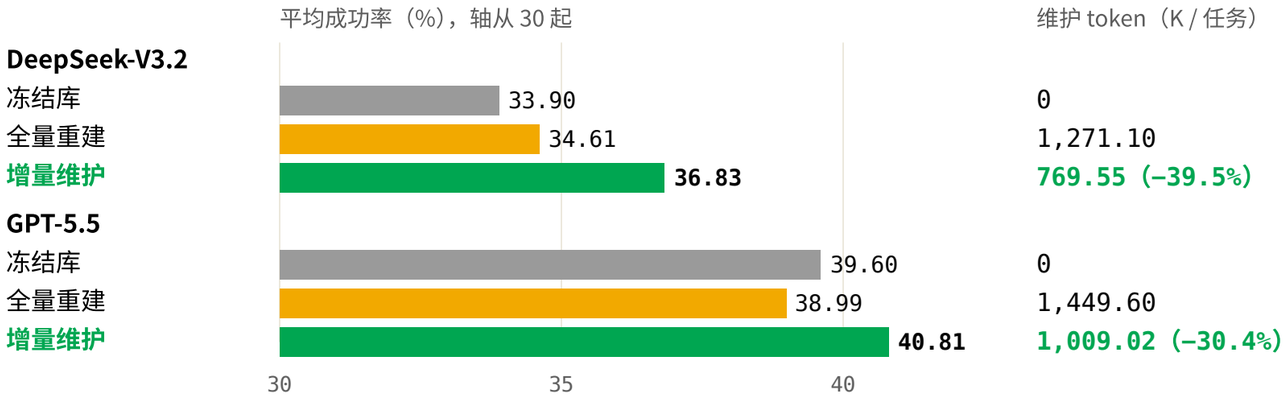
- AutoSkill 在 v3、v5 成功率低于不用技能；AutoSkill / EvoSkill 在若干中间版本 SPE 也低于它。
- 不用技能在 v2 拿到最高 Cost-IDR、在 v5 拿到两项 DAR 最高。
- SkillOpt 各版本成功率与 SPE 领先，但 IDR / DAR 并不一致领先，技能生成与优化约 3,000K token / 任务，是其他方法的 2–3 倍。

05 STEWARD：把工具和技能当一个系统管



DeepSeek-V3.2 上六个版本成功率都最高，平均 **39.04%** 对 SkillOpt **36.36%**；v2 起其他方法的维护 token 是它的 1.2–5.5 倍。相对每格最强基线，Step / Cost-IDR 平均 +4.04 / +3.69 点，Step / Cost-DAR +5.28 / +4.76 点。

06 对照：同一份 v1 技能库，只换 v2 起的维护方式



两个模型上增量维护在成功率、SPE、IDR、DAR、工具 F1 都最好；比全量重建高 **2.22 / 1.82** 点，维护 token 少 39.5% / 30.4%。GPT-5.5 上全量重建（38.99）甚至低于直接冻结（39.60）。

供给消融（DeepSeek-V3.2，Fig. 7）：只加技能搜索几乎无提升；只加工具搜索成功率 +8.65、工具 F1 +4.14，但 Step-DAR −2.76；两者合用各项都提升，相对只用工具搜索 DAR 再 +11.41 / +9.30。

均为单次运行，未报告种子方差；1–2 点的差别未必稳定。

07 限制与核对备注

- **合成生态**：服务、任务、变换都由 LLM 在 42 个模拟领域生成并执行校验；一条变化流，不是真实开放 API 的演化。
- **“最优”有边界**：参考路径只在构造的实现空间内最优；成本是 LLM 按定义给的 1–10 分，不是实测延迟。
- **无方差**：模型表、技能方法比较、STEWARD 与消融都没有独立种子或置信区间；用户模拟器与技能研究的任务模型都是 DeepSeek-V3.2。
- **核对备注**：Table 2 中 DeepSeek-V3.2 增量维护平均成功率 36.83，与 Fig. 6 中 STEWARD 平均 39.04 口径不同，原文未说明（可能是供给设置或平均范围不同）；本画报两处数字分开引用，不互相推算。

读 本项目读法

能带走的判断：留存技能的价值取决于它跟着工具目录走：过期依赖要能失活、复活；维护最好是局部编辑而非每版重建。评估自演化代理时，只报成功率会漏掉“旧路还能走、新路没发现”的损失，需要像 IDR / DAR 这样以当前可达最优为参照的指标。

问题档位等字段是本项目的阅读判断，不是审稿结论。