失败了，就一定是 prompt 的错吗？

GEPA-Curator: Curated Learning for Self Improving Agents —— 反思式 prompt 优化器从失败里学；但工具缺失、任务含糊、judge 不稳也会造成失败。**先挑出值得学的任务，再给反思器一个可信的成功对照。**

展品 I · 一次被接受的坏变异（附录 A.2，原文逐步描述，本项目重绘）　Optimizable + Impossible 组 · 第 7 轮

两个“不可能”任务的反馈，写进了一条过度泛化的搜索规则

两个意图不明的任务（没给仓库也没给群组）都失败了；evaluator 建议“去手动翻项目和群组”。反思器把它写成：

> “全局搜索常受限。搜不到就手动翻群组、项目和文件树；先查 Your groups / Your projects，再去公开的 Explore……”

这条规则让一个原本能解的任务从 **5 步成功**变成 **30 步用尽仍失败**。可 minibatch 总分从 **8 → 9**，于是变异**被接受**为候选 5。

验证式闸门只看聚合分，且在变异生成之后才起作用——它挡不住这种“总分涨、可解任务回退”。§ 1、附录 A.2。

父 prompt · “Check the guide to WCAG documents and standards”

起始页认出 The A11Y Project → 打开仓库 → Find file 搜索 “WCAG” → 到达 src/posts/wcag2-documents.md ✓　5 步

变异后 prompt（加入“穷举搜索”规则）· 同一任务

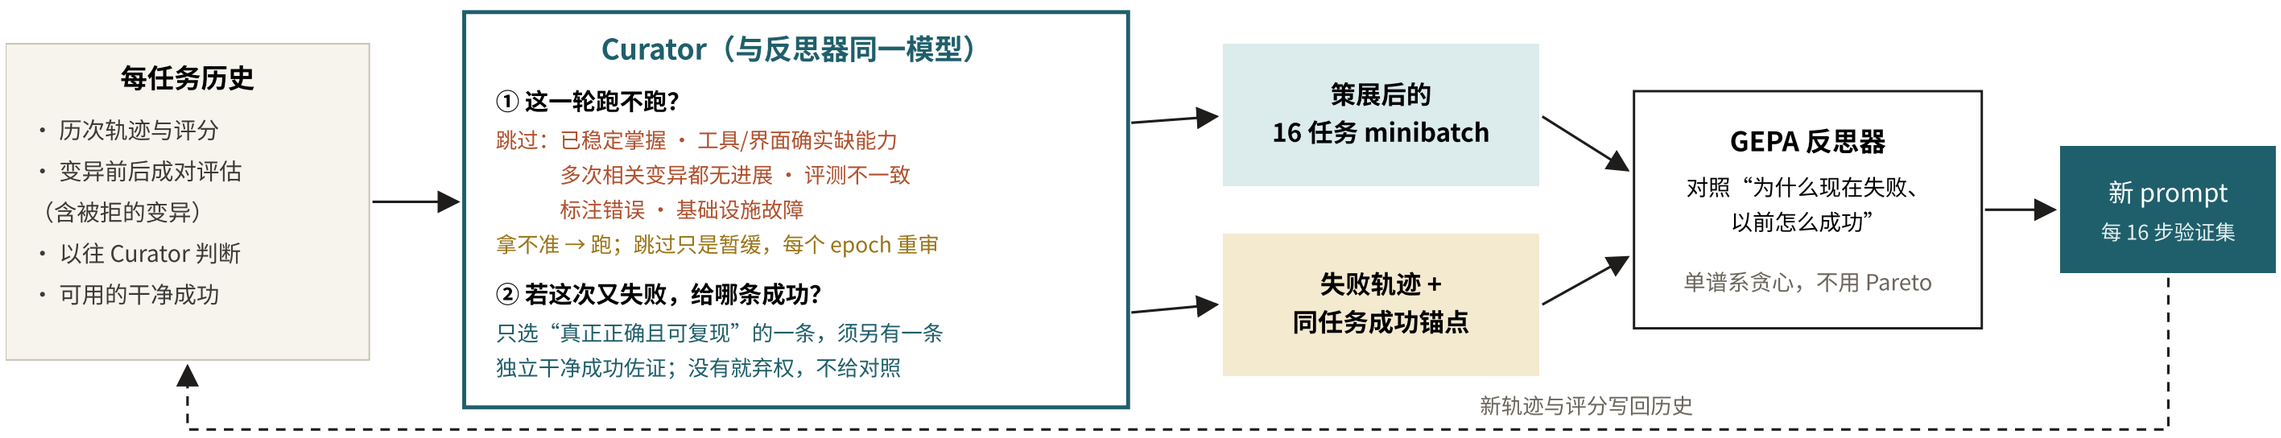
筛选个人项目 | Explore | Topics | Help | 全局搜索 | 群组页 | 终于回到 A11Y Project

看 README 和 Wiki | 手动逐层翻 src 目录树…… | 30 个动作用尽，没到指南 ✗

中间各步按原文顺序列出，未逐一计数；示意，不是原论文图。　30 步上限

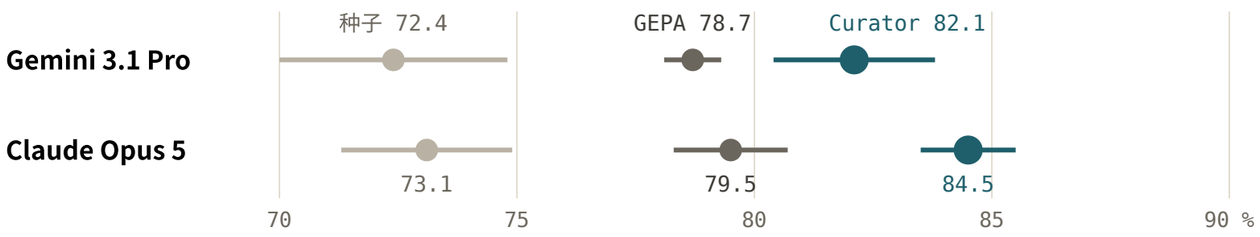
展品 II · 机制（§ 3.1–3.2、附录 B.2 提示词；本项目绘制）　优化器本身不改，Curator 是套在外面的一层

Curator：每个任务一次 LLM 调用，决定“跑不跑”和“给哪条成功做对照”



展品 III · 主结果：held-out 测试集（§ 4.1–4.2，Table 1–2）　actor gpt-oss-120b

WebArena 四站：两种优化器下都比 GEPA 高



四站总体：GEPA 比种子 prompt 高 6.3 / 6.4 点，Curator 高 9.7 / 11.4 点；两者差 **3.4 / 5.0 点**。逐站增益 0.6–7.4 点，每站都为正。每站 3:1:1 划分，验证集选终版、测试集只报告；同种子 prompt、同 evaluator、同 5,000 次 rollout。

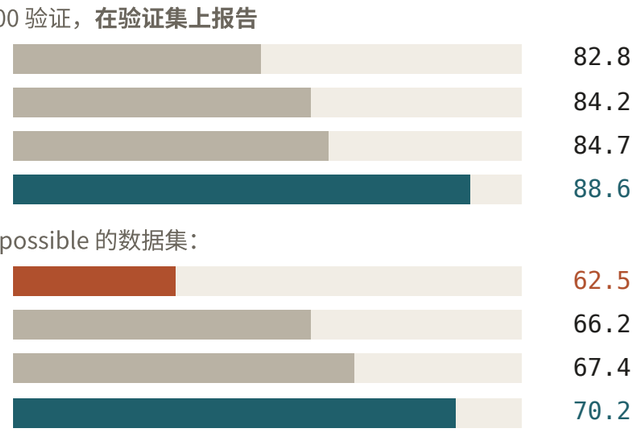
其他基准（测试集 %）	ALFWorld	AppWorld-N	AppWorld-C	τ-bench
Gemini · GEPA / ACE	82.4 / 90.1	38.0 / 55.7	27.8 / 34.5	75.4 / 80.6
Gemini · Curator	**91.8**	**58.7**	**46.2**	**84.0**
Opus · GEPA / ACE	95.8 / 89.7	52.9 / 61.2	32.5 / 33.4	82.9 / 61.7
Opus · Curator	**98.4**	**68.8**	**46.4**	**82.9（持平）**

“±”为原文所报标准差；原文写“5 次重复”，未说明是否重复优化（成本按每法每基准一次运行计）。QA 类附录 E：HotpotQA 上 Curator 反低 1.3 点。

展品 IV · 拆开看（§ 4.3 Table 3；§ 5.1 Table 4）　注意报告集

两件都要，只看成败计数不够

GitLab 消融：520 训练 / 200 验证，**在验证集上报告**



条长自 76 / 58 起算、满格 14 点，以放大差异。只看成功/失败历史的课程表反而比 GEPA 低：flaky 和可学任务都会时好时坏，要读轨迹才分得开。

展品 V · Curator 实际判了什么（附录 C）　Gemini · WebArena 四站

1,581 个训练任务里 **75 个（4.7%）**至少一次被判 impossible / flaky。作者人工复核：18 个 impossible 中 **12 个**是 harness / 环境缺能力；65 个 flaky 中 30 个任务本身含糊或有误，7 个属推测、5 个复查后被推翻。

成功锚点：554 个合格任务中，从可靠与有噪成功里挑对的 **17 个**，有理由弃权 **50 个**。

展品 VI · 成本（Table 8 / 15）　美元 · 单次运行

	rollout	反思	策展	合计
WebArena · GEPA	552.77	41.27	—	594.05
WebArena · 高效版	**578.47**	**98.87**	**99.54**	**776.88**
其余三基准 · ACE	175.43	593.25	—	768.69
其余三基准 · 高效版	**97.81**	**31.55**	**44.62**	**173.98**

成本表用的是“高效版”Curator（只留近期完整轨迹），不是主结果表里的完整版；高效版 WebArena 均值 82.3、总成本为 GEPA 的 1.31 倍。按 Gemini 价格计，不含测试与托管。

展品 VII · 边界　作者结果 ／ 本项目读法分开

- “噪声任务会污染 prompt”的受控实验（Fig. 2：可学任务混入 impossible 或 flaky 后最多解 12/16）在**训练集**上画曲线，分组依据先导运行与人工检查事后挑选。
- 消融在验证集上报告；Curator 的 impossible / flaky 判断没有独立准确率审计，只有作者的人工归类。
- 增益量级随基准变：τ-bench（Opus）持平，QA 类平均只 +1.1 点；Meta-Harness 扩展每设置只跑一次。

本项目读法：反思式改进回路里，“失败”需要先归因到被改的对象，再决定喂不喂给优化器；聚合分闸门放得过“总分涨、可解任务回退”的变异。这是可直接放进闭环的 B 类组件。