arXiv:2610.39276v1 · cs.AI · 2026-10-29 · Huang, Lan, Yu, Peng, Lu（北京大学 · 微软亚洲研究院）

个人历史没有标注，也没有成败信号——能不能让它自己出题，来挑选和修改代理的记忆设计？

记忆系统怎么存、怎么检索、怎么拼上下文，应该随用户历史调整；MemEvolve、ALMA、M★ 这类优化器靠下游任务反馈来改设计，但聊天、邮件、照片本身给不出“对 / 错”。人工为每份新历史写题目、参考答案和证据又太贵。**MemSteer** 从未标注的历史里自动出题（带参考答案与来源证据），用来评估候选设计、定位失败、驱动修改；全程不更新模型权重。

出题车间 · 题怎么来

§3.2 · 附录 A.4 · 示意（据原文流程自绘）

① 记录图
同一对话、相邻章节、互相引用或词汇重叠的记录连边；从种子沿路径扩展，取一个预算内的材料包

→

② 答案计划
先定参考答案、支撑事实（引到原文片段）、每条证据的作用和组合方式

→

③ 程序检查
结构不一致或来源覆盖不全的计划，在出题前丢掉

→

④ 单独出题
另起一次调用，按计划写一个可独立成立的问题

→

⑤ 语义审计
LLM 审稿逐条判：答案有支撑、题与计划一致、每个事实与证据角色成立

→

⑥ 盲答复原
只给题目、答案类型和原始记录：须判可答、规范化后与参考答案完全一致、引用覆盖每条证据记录

拿题去改设计（MemSteer-Opt）：设计 = 存储 × 检索 × 上下文拼装；固定回答模型、提示与上下文预算。每个候选重建记忆、在生成的验证集上严格更高才替换；共 20 轮。

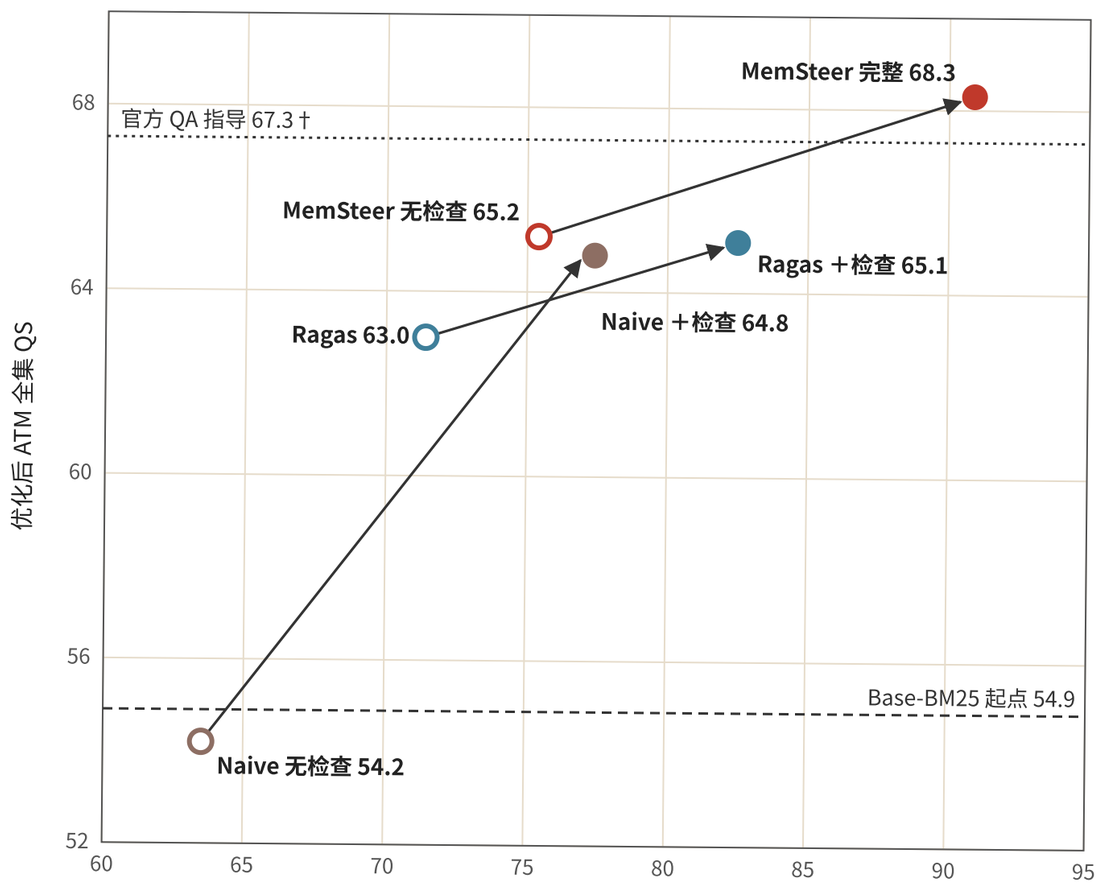
证据用于诊断：所需证据都在上下文里却答错 → **回答失败**；缺证据且记忆里找不回 → **存储失败**；缺但找得回 → **检索失败**。每类最多抽 10 例给提议者。

规模：ATM-Bench 约四年 11,034 条邮件 / 图片 / 视频记录，测 1,013 题 + 31 题难集；RHELM 10 个人设 21,142 条交互，测 1,305 题。生成题 ATM 上 400 训练 + 200 验证。

贴图 01 · 题出得好不好，决定优化走不走得动

Table 4 · 据原文数值重绘

○ 无检查　● 加 ⑤⑥ 检查　箭头 = 同一出题法加检查



出题质量 %（两个 LLM 评委均值，四项全过才算 1）

随机拼记录出的题（Naive）拿去优化，QS 54.2，**还不如不优化的起点 54.9**；同样的题只要过一遍检查就到 64.8（保留 21.2%）。换成记录图取材 + 答案计划，再加 3.5 点，到 68.3（保留 47.9%）。

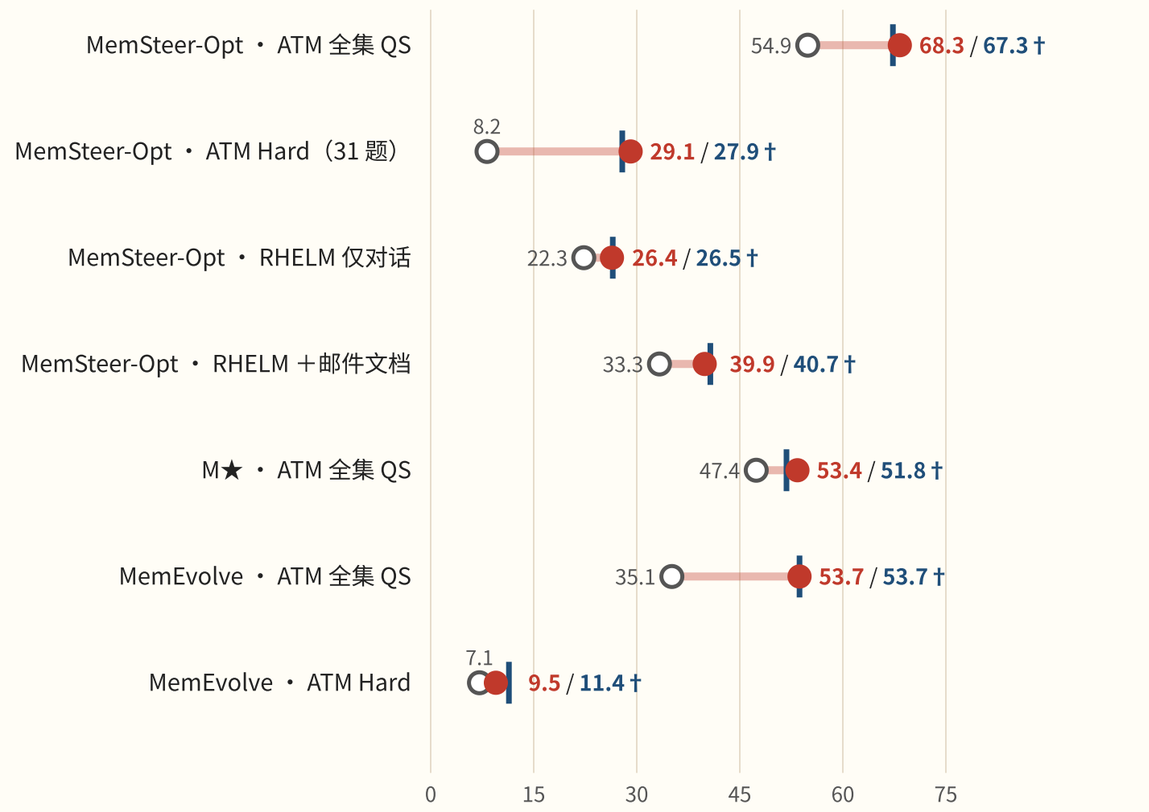
质量分由 GPT-5-mini 与 DeepSeek-V4-Flash 两个 LLM 评，不是人工；两者对“MemSteer 无检查”分歧最大（83.5 vs 67.3）。DeepSeek-V4-Flash 在 ATM 上同时是回答器、开放题判分和设计提议者。

贴图 02 · 和“用官方标注题来优化”比

Table 1–2 · 附录 A.3 · 据原文数值重绘

平手，而且对照偏向官方那边

○ 起点　● 用生成题优化　▌用官方题优化 †



† 官方对照拿 ATM 的 600 / 1,013 题、RHELM 的 788 / 1,305 题来训练与选设计，**这些题仍留在评测分母里**；生成题一题评测题都没用。七行里两者差 0–1.9 点，方向两边都有（正文写 ATM 领先 1.1 / 1.3，按表计算为 1.0 / 1.2）。

换官方 GPT-5-mini 判分（Table 7）：全集官方 69.6、生成 69.2；难集 24.3 vs 27.5。难集只有 31 题，一题约 3.2 点，约 1.2 点的差不到一题。MemEvolve 在难集上不如官方对照，R@10 还降 0.1。

便签 · 好题要花 token

Table 5

同 600 个任务、同源记录与生成器，三种出题法过同一个 GPT-4.1-mini 过滤器，再由盲评的 GPT-4.1 打质量分：

出题法	质量	token / 题
直接一次出题 + 答案 + 证据	67.8%	64.0k
同一回复里先计划后出题	73.1%	68.2k
两阶段：计划 → 程序检查 → 另起出题	**85.9%**	**105.1k**

训练题预算从 100 加到 200 时增益最大，之后检索召回基本持平（附录 B.2）。

便签 · 换个用户还行吗

Table 3 · Table 9a · §4.3

RHELM，含外部数据	起点	共享设计	继续优化
6 个源用户（合并）	31.5	**34.3**	–
4 个留出用户（合并）	35.3	**35.1**	–
Martin Keller（228 题）	41.2	**37.7**	**44.3**
David R. Ellis（158 题）	37.3	38.6	**39.2**

在 6 个用户上优化的共享设计，搬到另外 4 人身上合并后不涨反跌 0.2；用**目标用户自己历史**生成的 421 / 337 道题继续优化，两人都回升。ATM 上优化的设计冻结后直接搬到 RHELM，比起点高 4.1 / 5.3 点。

便签 · 边界

附录 C · §4 · 本项目阅读

- 出题、审计、盲答都由 LLM 完成，**没有人工认证**；几道检查共享的错误或偏差可以一起漏过。盲答只证明答案能从这些记录推出，不证明每条记录都必要。
- 题目跟着历史的分布走，不是用户真正会问的问题；设计空间以检索为主。
- 两个基准，其中 RHELM 是合成人设；每个设置只跑一次，无多种子方差。

读法（本项目判断）：最有说服力的不是“比官方高”，而是 Naive 题让优化原地踏步、检查把它拉回来——监督质量本身是瓶颈，且可以在不碰评测题的条件下补上。它证明的是“有限条件下可用的监督”，不是人工标注已被无误替代。

剪报 · ATM 上一条被接受的设计轨迹（9 次修改，从 Base-BM25 出发）

附录 B.5 · 图 5 · Table 9b

生成题选出来的改动，大多落在检索与上下文拼装上

0 Base-BM25：原问题直接 BM25，按排名拼上下文

1 加 BGE-M3 稠密检索

2 混合检索 + BGE 重排

3 问题分解

4 HyDE + 第二级检索

5 HyDE 查询

6 180 个候选池、重排 90 个

7 答案校验

★ 终版：4 条 HyDE 查询、重排 120、读 25 条记录、输出上限 4,000 token

顺序从“检索表示与排序”走到“多查询拼上下文”再到“答案校验”（原图编号 9 次修改，文字列出的步骤如上）。RHELM 十人设置里，生成题让 10 个人设**全部**高于起点，合并 33.3 → 39.9；官方题对照 40.7 †（Table 9b）。论文自己也写明：这个设计空间以检索为主。

数字均出自原文（v1）；出题车间为据 §3.2–3.3 自绘的示意，两张图据 Table 1、2、4 重绘。档位是阅读优先级判断，不是审稿结论。