DWG 2611.05445 · 可执行工具库 · 总装图

用户只说“找到 Alice，我来转账”，谁来想起要先登录？

检索器按与请求的相似度给每个工具单独排名，常常找到“目标工具”却漏掉它的前置工具。LIBRA 在任何请求到来之前，**在沙箱里真跑一遍组合**，只把“有它能成、换掉就败”的关系存进工具库，检索时沿边补回前置工具。

LIBRA: Programmatic Induction of Executable Tool Libraries · arXiv 2611.05445v1 · 布朗大学、南加州大学 · AppWorld / BFCL / SciToolEval

输入	工具目录 + 可执行运行时（公开元数据）
不需要	依赖标注 · 使用轨迹 · 任务训练
LLM	每个工具 1 次写契约 + 至多 2 次按反馈修订（DeepSeek-V4-Flash）
检索	Qwen3-Embedding-0.6B，只嵌入原始元数据；无重排
评价	Recall / NDCG（候选集质量，不是任务完成）

A · 问题

目标排第 1，前置排到第 169

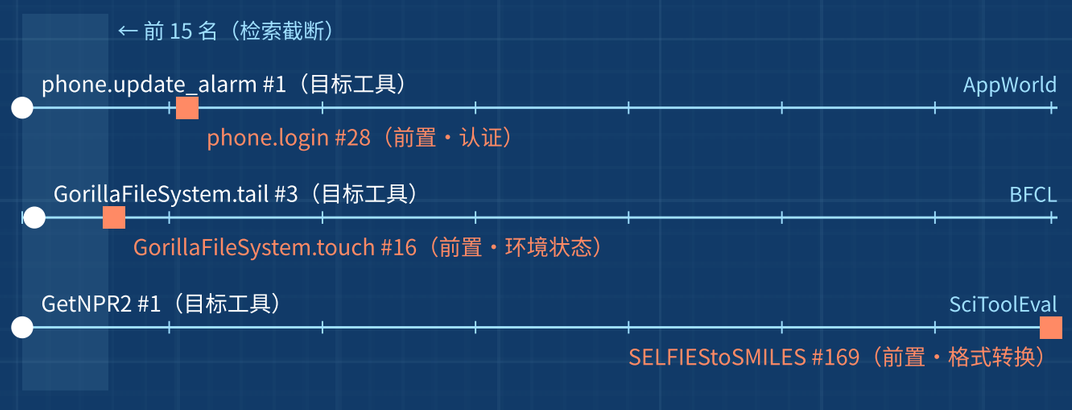

稠密检索名次（图 3）；LIBRA 沿保留的边把三个前置工具都提进了前 K

请求通常只说想要的结果，认证、查 ID、初始化状态、格式转换这些步骤不写。前置工具与请求、与目标工具在嵌入空间里都不必相似——稠密检索按设计找到了目标，**缺的是“谁必须先执行”的信号**。

图 1 的例子：请求“Find Alice in my contact and I will make the transfer”，稠密检索给出 **Venmo.Search_users**；LIBRA 在库里查到它的输入来源边，沿一跳补回 **Venmo.Login**。LIBRA 不生成、不执行任务计划，只改变候选集。

B · 构库

反事实沙箱测试：有它能成，换掉就败

LLM 只看单个工具的公开描述、签名和输入输出模式，写出**契约**：候选调用、可复用的输出与状态变化、可观测的成功 / 失败条件。然后在隔离沙箱里组合执行：

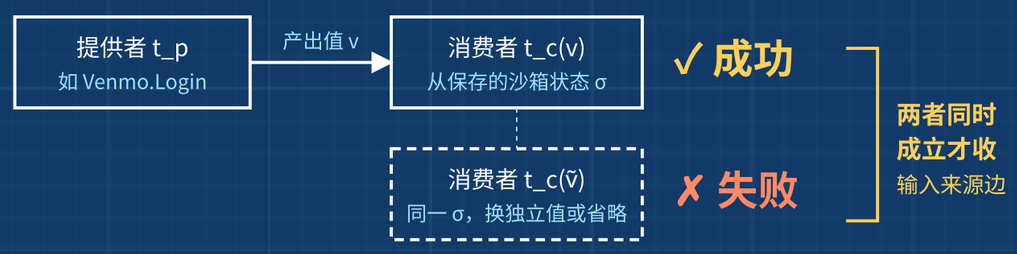

状态依赖：t_p 执行**前**调 t_c 失败、执行**后**同参数调 t_c 成功 → 收 t_p → t_c

两次都成功：仅当输出 / 输入字段名语义对齐，才收作“兼容边”（不等于必要依赖）

反例（图 1）：card 与 trans_id 都是整数，但支付卡号不能当交易号用 —— 类型兼容 ≠ 能组合

示意 · 依 §3.1 与算法 1 重绘

C · 检索

只走一跳，每个输入至多补两个提供者

稠密检索取前 15 个工具作“消费者种子”，沿入边找提供者；每个输入只留**字段名最匹配**和**与请求最相关**的两个，再把种子分数传过去：

$$s'(u) = \max(s(u),\ [\ s(u) + \Sigma_{t \in C(u)}\ s(t)\ ]\ /\ (1 + |C(u)|)\ )$$

取平均而非求和，邻居多的工具不会因此占便宜。剪枝很要紧：把所有保留边的提供者都加进来，SciToolEval Recall 从 91.1 掉到 76.4；走两跳也略降（附录 E）。

关键对照：同一编码器，只换图

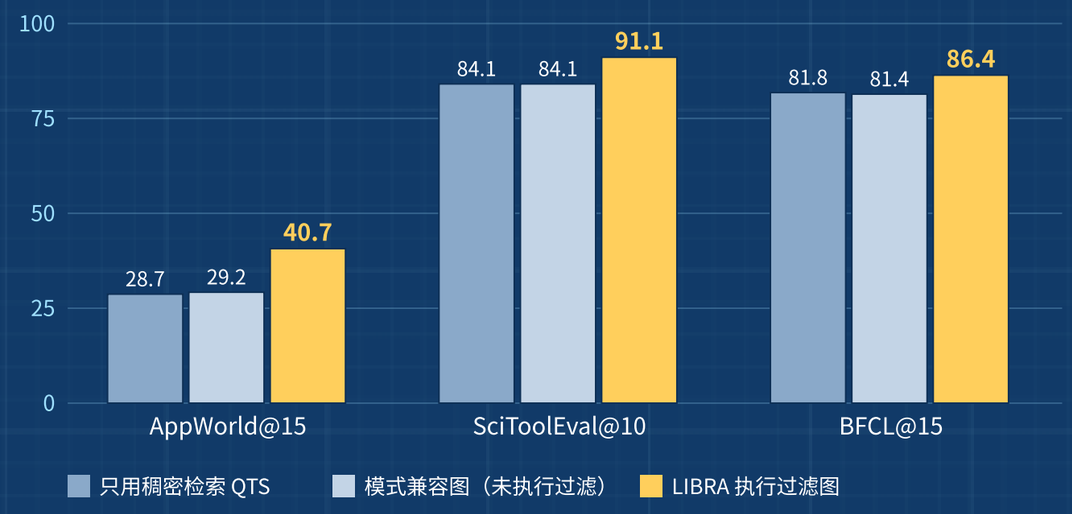

附录 B 表 4。未经执行过滤的“模式兼容图”与不用图几乎一样（AppWorld 29.2 vs 28.7）；换成执行过滤图才 +12.0 / +7.0 / +4.6 Recall。NDCG：39.1 / 86.6 / 78.4（QTS 32.8 / 83.9 / 76.2）。

D · 结果

与基线比

一次性检索 R / NDCG	AppWorld@15	SciToolEval@10	BFCL@15
BM25	20.0 / 18.8	86.4 / 54.1	75.5 / 69.5
QTS（同编码器）	28.7 / 32.8	84.1 / 83.9	81.8 / 76.2
TGR-Adapt	36.3 / **39.9**	76.2 / 75.1	81.4 / 73.6
Ego-Trip	29.2 / 33.2	84.1 / 83.9	85.7 / 78.4
SciToolKG	–	89.7 / 82.5	–
LIBRA	**40.7 / 39.1**	**91.1 / 86.6**	**86.4 / 78.4**

相对 QTS 平均 **+7.9 Recall / +3.7 NDCG**（表 2）。AppWorld 的 NDCG 仍低于 TGR-Adapt（39.1 vs 39.9），但召回更多。

放进多轮代理检索 ToolReAGt（10 轮，3 个代理 LLM × 3 个种子）：相对 QTS 平均 **+4.5 Recall / +2.9 NDCG**，9 个设置中 8 个 Recall 最高（图 2）；不改 ReAct 策略、不训练代理。

还漏在哪

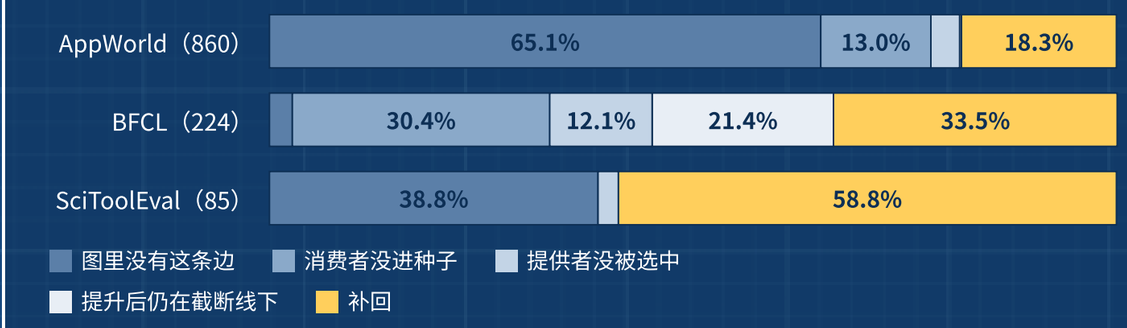

表 3：稠密检索漏掉的金标准工具。AppWorld 65.1% 是“图里根本没有这条边”——如查联系人要用任务里才有的数据，建库时跑不出 phone_number；BFCL 主要卡在种子和截断线。

E · 成本

一次构库，跨请求复用

	AppWorld	SciToolEval	BFCL
目录工具数	473	477	128
候选组合	581,690	163,608	12,762
保留关系（值 / 状态）	1,946 / 0	732 / 0	595 / 77
墙钟时间	260:40	20:45	4:28

每个构库作业 96 个 CPU worker、一张 L40S（字段嵌入），AppWorld 申请 384 GB 内存（附录 C）。LLM 调用随工具数线性增长，但候选组合最坏是工具数的平方级；工具数相近的 AppWorld 与 SciToolEval 耗时差 12.6 倍。

F · 读之前先知道

- **只测了检索**：Recall / NDCG 衡量候选集，不是工作流完成率；没有端到端任务成功。
- 没有边级金标准：“运行时验证”只表示在测试的契约与沙箱状态下通过，作者不声称依赖精度；兼容边也算进图里。
- 需要可执行、可重置的运行时；SciToolEval 只评了 530 题中可执行的 270 题，AppWorld 用公开注释的 90 训练 + 57 开发题。
- TGR 原实现不公开，表中是作者的改编版；Ego-Trip 也按各基准改编。
- 契约由 LLM 依公开元数据提出、最多按反馈修订两次（AppWorld 218、SciToolEval 48、BFCL 37 份契约至少修订一次）；契约没想到的组合，测试也测不到——反事实检验管精度，不管覆盖。
- 依赖任务专属数据的前置（建库时没有那条联系人）结构上无法提前发现，这正是 AppWorld 漏检的大头。

改变的判断：从元数据推断“谁依赖谁”不够——模式兼容的边不加执行过滤，对检索几乎没有帮助；让组合关系先过“有它成、换掉败”的执行检验，才是这类冷启动工具库能复用的部分。

SOURCE
arXiv 2611.05445v1 · HTML 全文 sha256 4deab8f2…

MAPPING
数字对应见 SOURCE.md；图 B 与排名尺为示意重绘

ISSUE
HarnessRSI Daily · 第十期

NOTE
问题档位为本项目阅读判断，不是审稿结论