ONLINE SKILL BOUT · 每做完一题，就有一场对决

一条轨迹改写出的新技能，该不该换下现任？

在线技能演化里，每题只做一次、下一题往往不同，技能只能凭刚才那一条轨迹改写。EvoGuard 把“逐次跑验证集”的成本挪到部署前一次付清，部署时只让一个训练过的选择器读两份技能文本，前向一次就判谁留下。

EvoGuard: Mitigating Degradation in Online Skill Evolution · arXiv 2611.06444v1 · 京东、中山大学、墨尔本大学、港科大 · ALFWorld / ScienceWorld / LiveCodeBench（WebShop 在附录）

BLUE CORNER · 卫冕

现任技能（父）

来源：此前对决留下的技能，初始为空技能

格式：SKILL.md，四节（何时用 / 流程 / 决策规则 / 恢复与陷阱）

每个任务族只保留一份

VS

裁判只看：任务族名称与通用描述 + 两份技能文本

看不到本题、轨迹和成败

A / B 位置随机 · 一次前向 · 24 ms

挑战者 · RED CORNER

单轨迹改写（子）

冻结生成器读现任技能 + 刚才一条轨迹 + 成败后整份重写

先过格式检查（只看结构，不看好坏）

换上后才影响同族后续题，改不了刚做完的这题

ROUND 1 问题：挑战者常常更差

作者在 ALFWorld 收集单轨迹改写，逐个在该族私有测试集上评分，看子技能减父技能（图 1b）：

基础生成器 1,137 次改写；损失 ≥10 点 7.7%，提升 ≥10 点 11.3%

平均下来改写**几乎中性**，但输家不少；换成用 RL 训练过的“专家”生成器，900 次改写里仍有 **40.0%** 比父技能差。所以“全部接受”会让技能漂移；可每次都跑验证集，单次验证就比引发它的那道题贵得多。

ROUND 2 研究动作：验证成本一次付清

1. **建技能池**：在训练题上跑改写循环，父技能从池中均匀抽取；两种来源——基础生成器 Qwen3-4B 与更强的生成器（ALFWorld 等为 GRPO 训练的 Qwen3-4B，LiveCodeBench 为 GPT-6.1-sol）。
2. **标效用**：每个技能在本族私有测试集的每题上跑一次（ALFWorld 每族 100 题），取平均成功率。私有集不用于生成技能，也与在线评测题不交。
3. **拒绝采样配对**：同族两技能效用差 ≥ 0.1 才留，ALFWorld 共 24,000 对；验证技能不进训练对。
4. **训练裁判**：Qwen3-4B + LoRA，只读“A”“B”两个标记的 logit，按 Bradley–Terry 形式训练；部署时冻结，执行器与生成器也冻结。

记分牌 · ALFWorld 整体成功率

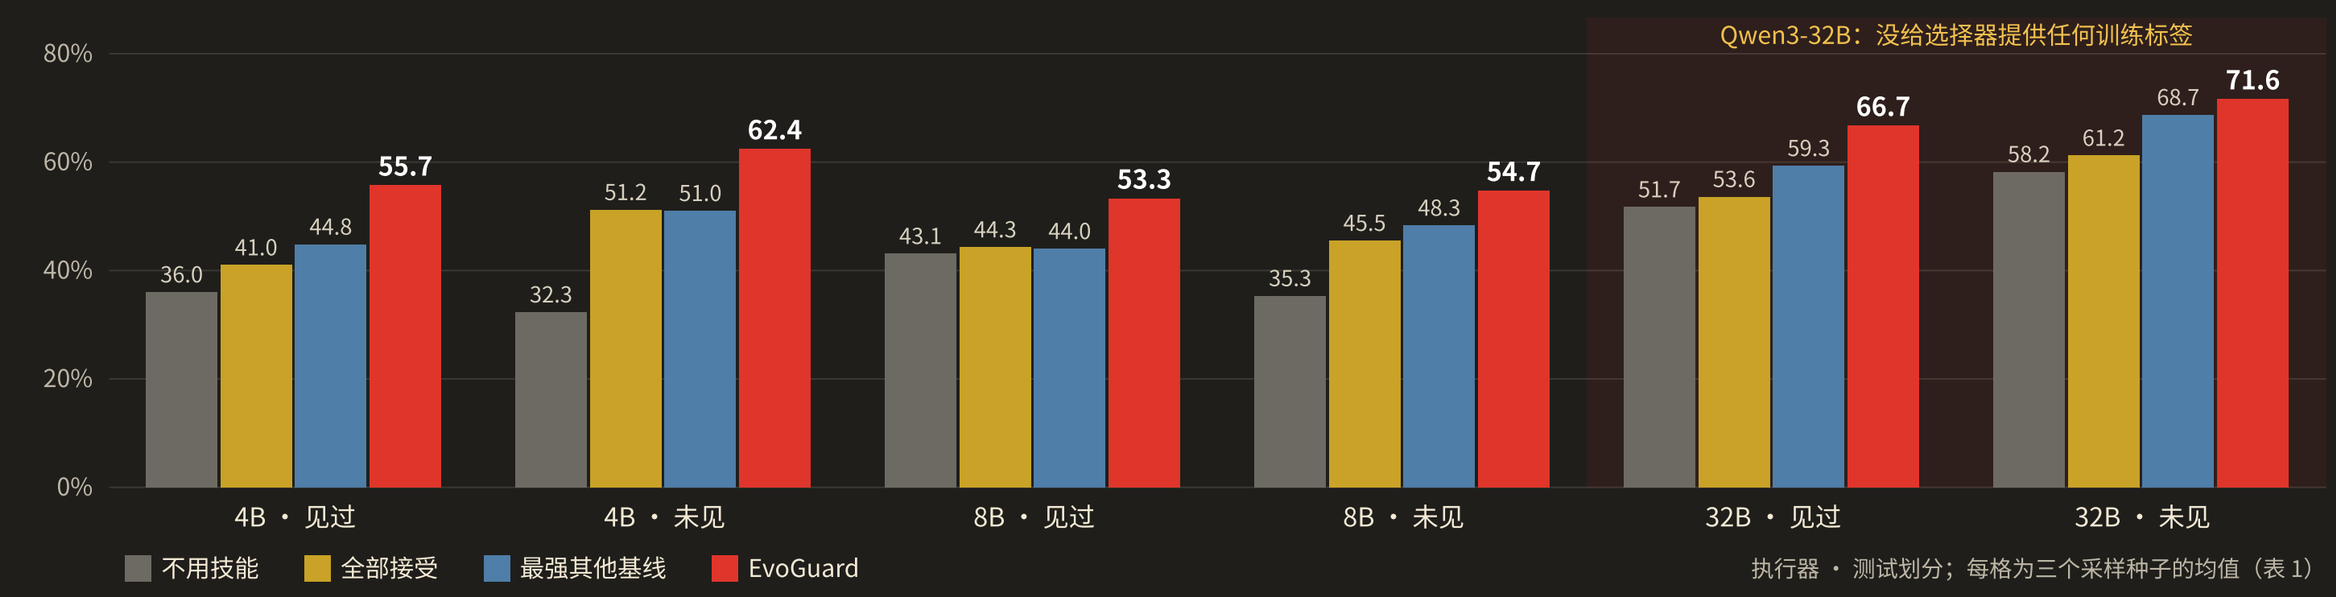

执行器 · 测试划分；每格为三个采样种子的均值（表 1）

EvoGuard 六个设置都最高。4B / 8B 四格平均 **56.5%**，全部接受与三种 LLM 裁判约 45.5%，不用技能 36.7%（摘要所说“+11.0%”是相对全部接受的百分点）。同一提示、同一 A/B 判定规则但未训练的 LLM-Judge (Logit) 比 EvoGuard 低 6.4–16.9 点——差距来自训练。

ROUND 3 裁判本身准不准

95.0%
筛过的验证对（效用差 ≥ 0.1）上选对；未训练时 48.2%（72% 的提示都答 A）

86.3%
父–子验证对上的准确率（训练前 58.1%）——这才接近在线对决的处境

98.3%
交换 A/B 位置后仍选同一技能；未训练的 Logit 裁判 55.6%

42.3–43.2%
有效改写的接受率；LLM 裁判 68.4–72.0%。在用技能 361–371 token，对照 528–567

消融（4 格平均）：去掉专家技能池 52.0，去掉拒绝采样 52.4（随机配对时 44% 的训练对效用差 < 10 点）。

ROUND 4 换个场馆

方法	ScienceWorld 成功	得分	LiveCodeBench 通过	WebShop 4B 成功
不用技能	10.2	20.6	26.1	14.7
全部接受	9.4	21.2	25.7	15.8
其他基线范围	9.6–10.8	20.7–22.0	25.3–27.0	15.3–16.0
EvoGuard	**15.3**	**27.3**	**28.4**	**16.2**

ScienceWorld 和 LiveCodeBench 上，其他用技能的方法都贴着“不用技能”，全部接受还更低；EvoGuard 是唯一明显离开基线的。

但绝对增幅小：LiveCodeBench 比不用技能高 2.3 点（175 题），WebShop 高 1.5 点。接到作者复现的 SkillRise 上：86.0 → 86.4（见过）、77.9 → 80.1（未见）。

VAR 回看：判罚的边界

- **个别族被技能拖累**：8B 见过的 Pick2 不用技能 61.1 → EvoGuard 50.0；32B 未见的 Heat 50.7 → 33.3。选择器只能在收到的改写里挑，不能修。
- 95% 只在效用差 ≥ 0.1 的“容易对”上测得；在线真正面对的父–子对是 86.3%，近似平局和分布外改写的误接纳没有单独报告。
- 执行器全是 Qwen3 家族；每个基准各训一个选择器；32B 是“没提供训练标签的执行器”，不是跨家族迁移。
- 每个设置三个采样种子，只报均值、没有方差。

VAR 成本怎么算

- 24 ms 是单次在线判定；建池、私有集评分和训练的总成本原文**没有合计**。
- 本项目粗算：若图 1 的 2,037 次改写即技能池，每个在 100 题上各跑一次，约 20 万次执行器回合——与 ALFWorld 274 道测试题逐次各验 100 题（约 2.7 万次 / 次运行）相比，摊销是否划算取决于选择器能被复用多久。
- 只比较“现任 vs 一个挑战者”，不保留多版本、不能回退到更早版本；不保证整条序列不退化。
- 训练的是选择器权重，执行器与生成器不变——这是外部留存门，不是代理权重的自改进。

改变的判断

在线逐题演化技能时，“要不要接受这次改写”本身是一个要单独解决的决定：不加门，四成多的单轨迹改写会拉低技能；加一个按领域离线训练的轻量裁判，就能在不额外跑环境的前提下滤掉相当部分有害改写。代价是一次性的离线评分与“只对这个领域、这类执行器”的适用范围。