判卷模型上线后会“漂”：何时、怎样重调它的提示词？

500 条对话流中，人工参考分数的构成在第 214 条后突变，固定提示词的 judge 误差上升。用陆续到达的参考分数反复重调提示词能把优势找回来，但通常回不到突变前；哪种优化器、什么时候触发，都没有通用答案。

BENCH	JUDGE	OPTIMIZER	AUTHORS
FairBotBench：600 段德英电商对话（偏见 / 毒性 / 个性化），三人参考分均值 1–5	GPT-5.4-nano（low）· Gemma 4 26B-A4B 量化版	GEPA · SIMBA · Rubric Synthesis · 示例选择（SA / TPE）；专家模型 GPT-5.4	Kleinkop 等 · 德累斯顿应用技术大学（HTW Dresden）

SCREEN 1 · 机制　　§3、§4.1、式 (1)、附录 0.B.3 · 示意

Controller：何时优化：定期 / 滑窗误差超阈
Dispatcher：用哪个（组合）优化器
Sample Selector：用哪些反馈记录
Optimizer：改出新提示词 p_{t+1}

评测协议：每条对话先由当前提示词打分再拿到参考分（“理想、即时、无噪声”的反馈），优化只能用已到达的记录。默认样本选择 NewElements：训练 = 上次更新以来的新记录，开发集 = 上次更新的训练记录。比较对象：同一条流上一直用初始 G-Eval 提示词的静态 judge。

SCREEN 2 · Low–First 流：相对静态提示词的改进（%，正 = 误差更小）　　表 1 · 三条采样流的中位数

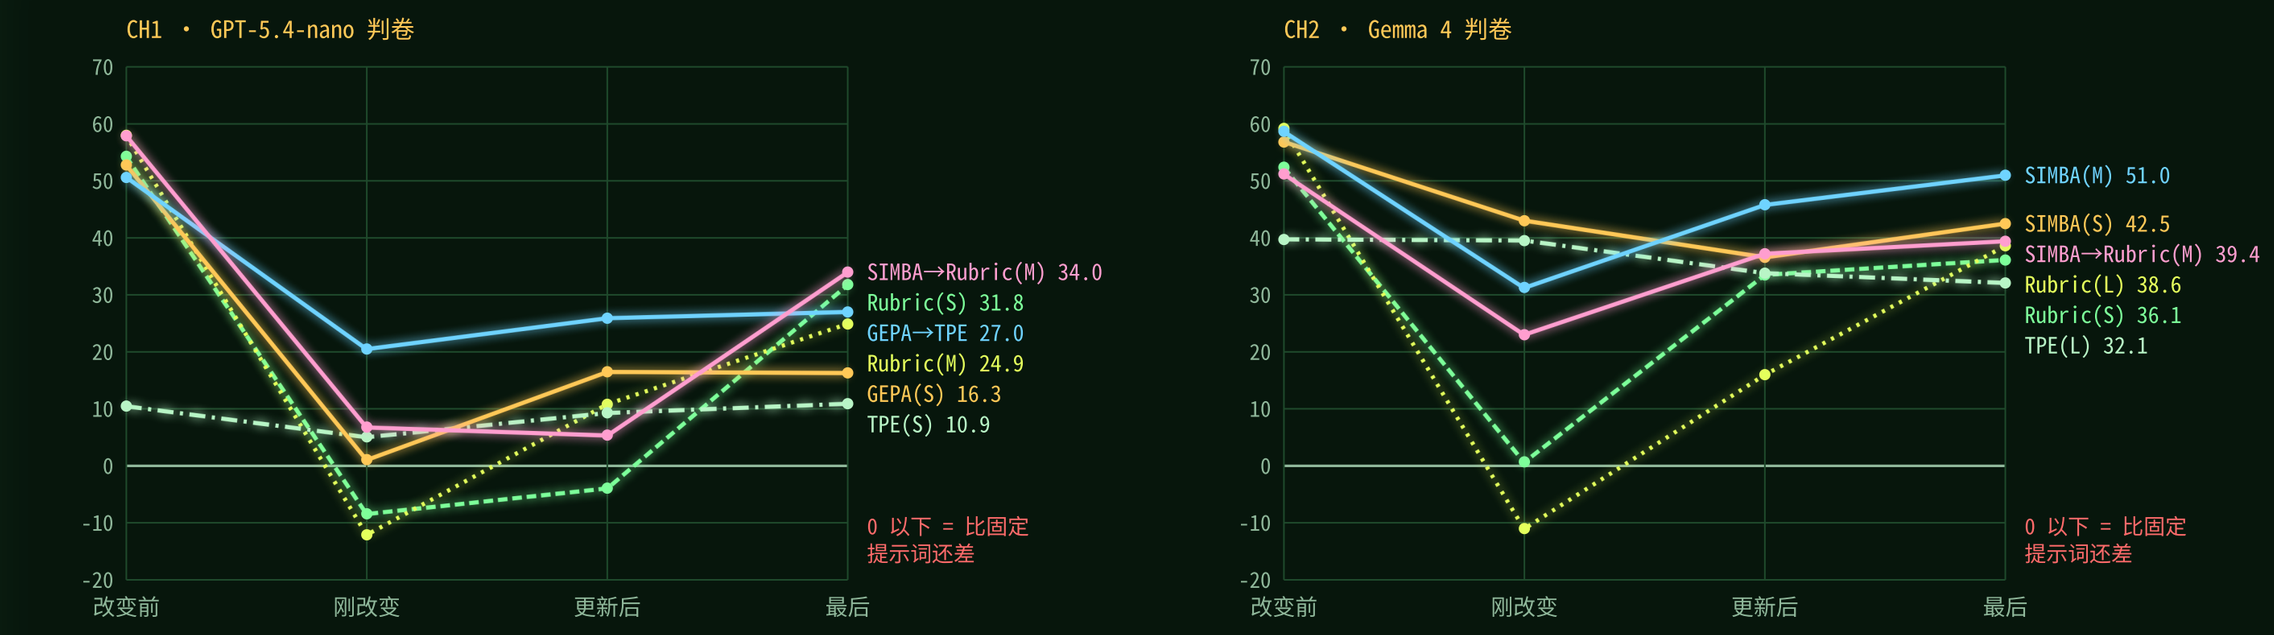

图 5（三种流合并）：突变后，12 个“后端 × 配置”的改进全部下降，Rubric 类与 SIMBA→Rubric 个别运行跌到静态之下；到最后一段 12 个都重新优于静态，但多数**低于突变前**（Gemma 上的 Rubric(S)、TPE(L) 例外）。作者称之为“恢复”而非“复原”。

间隔之间参考分构成不同，绝对误差不能直接比，所以这里画的是同区间相对静态 judge 的改进。更极端的 Split 流：GPT + Rubric(M) 从 **+55.2%** 跌到 **−77.7%**，第一次突变后更新后反而到 **−106.4%**，最后一段才回到 +35.8%（附录表 5）。

触发时机也是优化问题

§4.4 · 表 2 · 中位总体 MAE（越低越好）

滑窗控制器	GEPA(S)		Rubric(M)	
	高敏 τ=0.4	低敏 τ=0.6	高敏	低敏
小窗 w=20	**0.49**	0.50	**0.47**	0.53
大窗 w=50	0.54	0.54	0.52	0.56
定期（基线）	0.59		0.53	

8 个自适应设置中 7 个持平或优于定期；最灵敏的“高敏 + 小窗”最好，但触发最频繁、更贵；Rubric 的“低敏 + 大窗”反而差 0.03。

只在 GPT 后端、Low–First 流、两种配置上做（预算所限，作者称探索性）。注意：表 2 定期 GEPA(S) 记 0.59，表 1 同流同配置总体为 0.55；按 0.55 算“GEPA 四个自适应设置全部更好”仍成立。

没有通用最优优化器

§4.2 · 图 2 · 23 个参数化配置 × 2 后端 × 3 次

- 两个后端的误差–token 帕累托前沿形状差别很大，两边都在前沿上的只有 Rubric(S) 与 Rubric(M)。
- GPT：最低平均 MAE 约 0.48 来自 SIMBA(S)→Rubric(M)，不少配置多花 token 却不降误差。
- Gemma：前沿从三种 Rubric 一直延伸到 SIMBA(M)（约 1870 万 token、MAE 0.5）；SIMBA(L) 用约 2630 万 token 也没更好。
- Rubric Synthesis 便宜、常上前沿，却在突变后掉得最狠——作者认为像是对突变前反馈“专化”，但明说没有证明因果。

token 只在同一后端内比较；三次重复只够做筛选，不足以给出确定排名。

量程之外：结论不覆盖什么

§3、§5、§6

- 反馈是理想化的：每条对话都立即拿到三人参考分均值；真实部署的稀疏、延迟、噪声、分歧与采集成本都没有模拟。
- “漂移”是把同一数据集按参考分构成重排造成的，人类评价政策和 judge 模型本身都没变；也没有按构成分层报告误差。
- 一个基准、500 条流、每种流 3 条采样流、两个 judge 后端；控制器实验更窄。
- 改进以同一条流上的参考分衡量，没有独立的长期回归标准集，也没有显式回滚 / 作废旧评分的机制。

改变的判断

LLM judge 不是“调好一次就能一直当真值”的组件：被评对象的构成一变，固定提示词的一致性就会下降；用到达的反馈持续重调能找回相对优势，但要同时决定何时触发、用哪些记录、花多少钱，而这些选择因 judge 后端而异。

本项目读法：对把 LLM judge 用作留存 / 晋级信号的自改进系统，这意味着评价器本身也需要随流复核；本文在理想反馈下证明了“可以维护”，没有证明“可以部署”。