SOUNDING REPORT · 非权重 harness 演化审计 · arXiv 2611.07624v1

均分浮出水面，丢掉的任务沉在下面

冻结 GPT-5.4，把四种 harness 演化方法各跑一条谱系，冠军与种子各在全部题上重复 8 遍：16 个冠军全都“既新解出一些题、又丢掉一些原来会的题”。再用三组受控实验追问——选谁当父代、补丁怎么组合、门该多严——每一步都需要它自己的证据。

测深读数 **16 / 16**
冠军既有新增
也有丢失覆盖

方法
AHE · HyperAgents · A-Evolve · GEPA

harness
MiniSWE（可改源码）· Codex（只改外层）

基准
τ^3-Banking 97 题 · Terminal-Bench 2 89 题

作者
Wang 等 · 中国科大 / UC Berkeley / BIGAI / 上海交大

01 水线上下：每个冠军相对种子 新增 / 丢失 的“8 遍内至少成功一次”的题

表 10 · 附录 B.2 · 金色为 ΔPass@8（百分点）

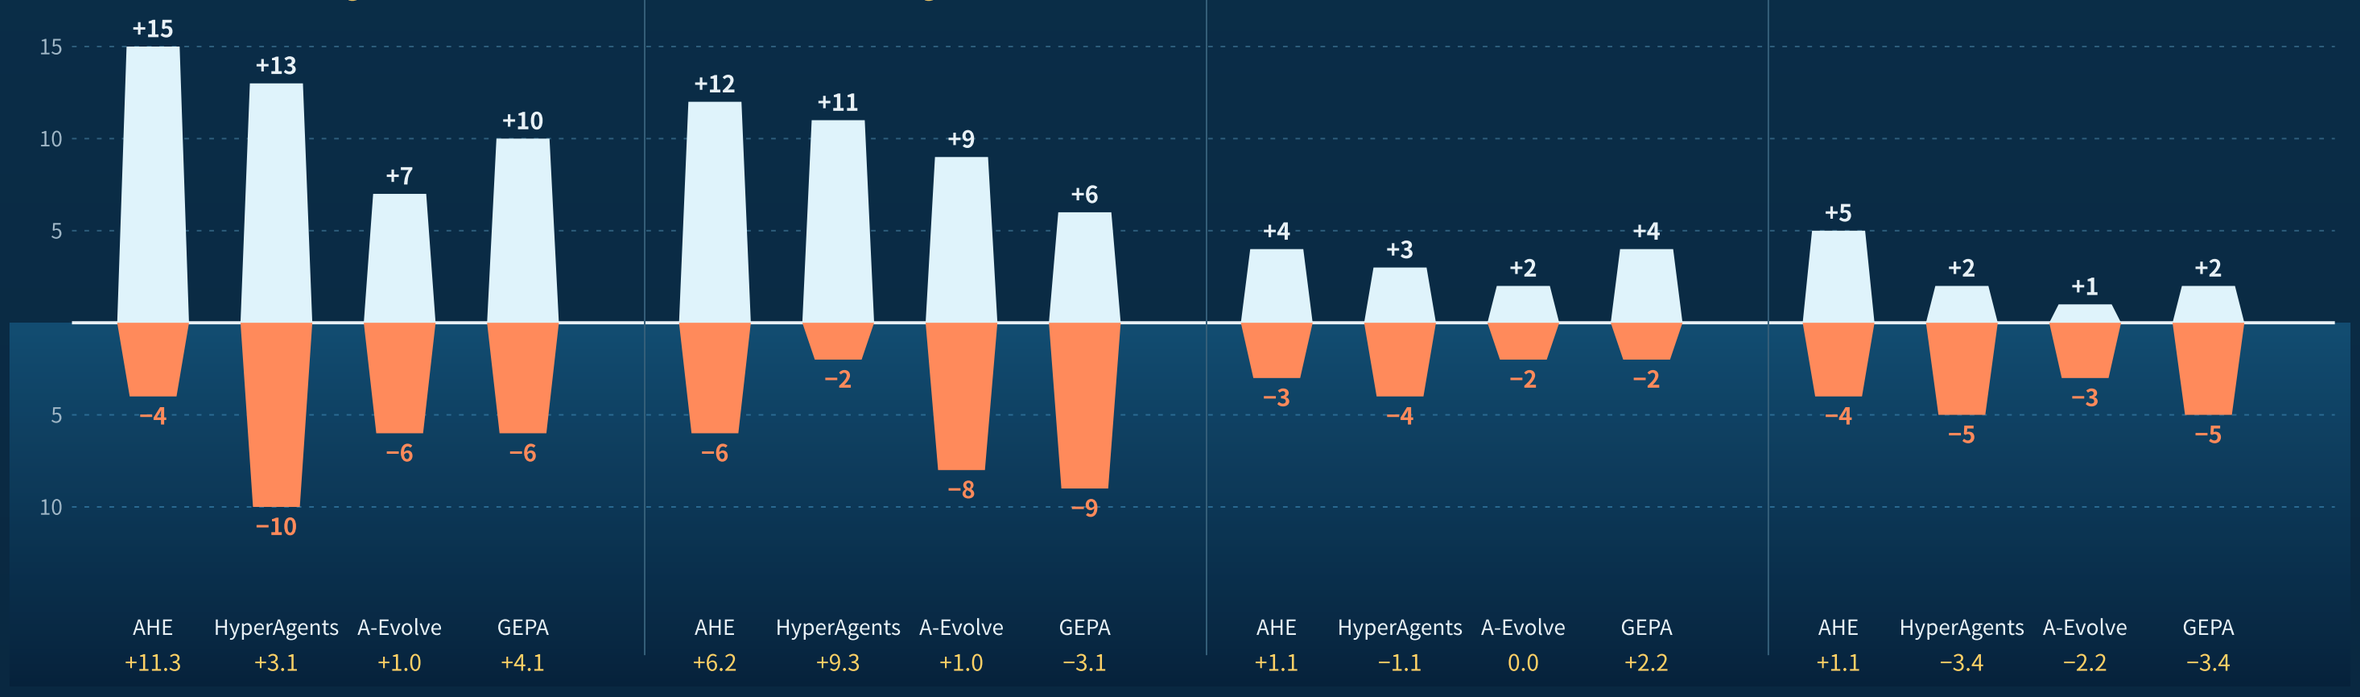

覆盖（Pass@8）与可靠度（Avg@8）是两件事：16 条谱系里可靠度升 11 条、覆盖升 10 条，4 条两者方向相反。例：MiniSWE + HyperAgents 在 τ^3-Banking 上可靠度 **+5.2**，却丢了 **10** 道原本会的题（新增 13）。

02 水下还有什么：成本与迁移

§ 4.3、§ 5、表 3

部署成本：11 个可靠度上升的冠军里 8 个单次运行更贵（3 个更便宜的都是 MiniSWE 编码任务）。但更贵不一定更不划算：MiniSWE + AHE 在 τ^3-Banking 跑 4 遍覆盖 56.7%，已超过种子跑 8 遍的 54.6%，部署成本更低。

增益落在哪：表 1 冠军 vs 种子是在全部题上比较，表 3 把变化拆成训练 / 验证 / 测试题的贡献（百分点，三者相加≈总变化）：

τ^3-Banking ΔPass@8	训练	验证	测试
Codex + AHE（+6.2）	+6.2	0.0	0.0
Codex + HyperAgents（+9.3）	+8.2	+1.0	0.0
MiniSWE + AHE（+11.3）	+3.1	+4.1	+4.1

测试题可靠度 16 条中 10 条为正；跨基准时覆盖在 $\tau^3 \to \tau^2$-bench 上 8 个冠军降 7 个，在 Terminal-Bench 2→DeepSWE 上升 7 个。

03 声呐原理：同一个均分被拿来做四种决定

§ 3.2 · 图 1 · 示意

作者把四种方法拆成同一套 7 个算子，只审金色四个：
谁当父代、证据支持改什么、改动如何组合、哪个候选留下。

演化只用训练 / 验证题；测试题只给冻结的种子与冠军报告分数。
每个方法 × harness × 基准只有一条演化谱系。

04 三次受控测深：每个决定要测它自己的后果

§ 6 · 附录 D.1–D.4 · 表 4–7

select
0 / 4
四个父代池里，测试分最高的父代都**不是**后代平均提升最大的那个。每池 4 个冻结冠军 × 各 3 个分支，统一用 A-Evolve 的诊断与变异。
原选择规则命中“最佳父代”的概率：通用任务 17.5% / 8.8%，低于随机的 25%；编码任务 59.5% / 55.7%。

analyze
15 / 16
从冠军里拆出的具体改动（组件），可靠度高于对应的泛泛提醒（“检查工具、核对结果”）。
但提醒本身在只改外层的 Codex 上会拉低可靠度；16 个组件里有 4 个单独加到种子上反而低于种子（本项目按表 5 计数）。

mutate
6 / 8
冠军整体优于其任一单独组件。HyperAgents 的两个通用任务冠军交互为负：−6.3（95% 区间 −11.7 至 −1.2）、−6.6（−12.6 至 −0.6）。
反例：Codex 编码任务上两个组件各自低于种子（69.1、68.0 vs 69.9），合起来 72.6。

gate
15 → 6
把门改严（均值严格提升且相对现任的平均回退 ⩽ 0.05），能留住报告面板最佳候选的池从 15 个降到 6 个（共 16）。
按留下集合大小归一后，MiniSWE 下降、Codex 上升——后者多是“只留下种子且种子恰最佳”。重放顺序为诊断安排，非历史顺序。

05 读数的误差棒

附录 B、D · § 7 · 本项目读法

- 每个方法 × harness × 基准只有**一条**演化谱系；父代实验每父代只有 3 个分支；“丢失覆盖”是 8 次执行中的经验事件，不等于永久遗忘。τ^3-Banking 上前 4 遍与后 4 遍的部分总体方向不一致。
- 父代 / 门实验的报告面板只有 27 题（τ^3）与 20 题（TB2）；门实验 2 遍决策数据。只用 GPT-5.4 一个模型。
- 作者据这些诊断改出 AGE（四处算子修订装进 A-Evolve），在四个设置上可靠度与覆盖都高于 A-Evolve；但 AGE 只跑种子 0 一次，修订又是从同一批基准的诊断里来的——**本项目只把它当作“诊断可转成改动”的示例，不当作干净的方法对比**。

06 例子：一次翻转背后是什么

表 2、表 12 · 22 个任务–谱系对比

行为类别（主类）	升	降
状态与依赖管理	7	1
精确对齐（日期、字符、条件）	1	4
完成与交付	2	3
工具发现与恢复	2	1
实现调试	1	0

如 τ^3 任务 037：种子 8 遍成功 7 次，A-Evolve / GEPA 冠军只剩 3 / 1 次——争议都提交了，但填错了发现问题的日期。

改变的判断

“演化曲线上升”不足以说明 harness 变好：新增与丢失要分开报，部署成本要和覆盖一起看，留出与迁移要逐个目标看。选父代、诊断、组合、准入是四个不同的决定，各自要用它想要的后果（后代提升、组件效应、交互、留住的候选）来检验，不能一路复用同一个均分。

本项目读法：这是在固定模型、两个基准、每条件一条谱系下的条件性诊断，不是对四种方法的排名。