不熄火进站：让代理在长任务中途自己决定改 harness

真实软件性能优化没有参考答案，跑得越久越会碰到离线学来的 harness 没准备过的困难。BoxBox 给任务代理一个 **boxbox()** 工具：代理自己决定何时暂停、审查轨迹、改整个可执行 harness；内核验证后热加载，执行上下文原样保留，改过的 harness 继续执行任务，也负责后面的审查。

赛道 · PERFRACE	计分	车手 / 底盘	车队
100 个任务，取自 GitHub 上编码代理活跃的真实项目，7 个领域；端到端工作负载，没有已知目标补丁；人机配对验证 + 红队防作弊	提交给外部 Judge（独立工作负载副本 + 留出正确性用例，影子容器）；取正确提交的历次最佳加速比，跨任务取调和平均	GPT-5.6 Luna（high）；所有方法都从同一个终端 harness Terminus-KIRA 出发	Tan, Jiang, Yang 等 · 南京大学 / 浙江大学 / 伦敦大学伯贝克学院 / Microsoft

计时塔：4 小时后的名次 表 1

同样 4 小时壁钟预算；费用为每次运行平均模型费用（含 harness 优化）

POS	方法	SPEEDUP@4h	平均费用	加速比 / $
1	**BOXBOX** BoxBox · 代理自己叫进站	1.702×	$16.43	0.4886
2	**HS** Harness Scaling · 外部控制器逐次改	1.539×	$12.98	0.2872
3	**FRZ** Frozen · 全程不改 harness	1.442×	$23.22	0.2142
4	**HE** Harness Evolution · 离线演化后冻结 另摊离线训练 + 验证：每次测试运行 ≥ $33.73	1.281×	$24.56	0.1243

HE 先在 40 个训练、10 个验证任务上离线演化（训练集加速比 1.086 → 1.062 → 1.069，没有持续上升），挑验证最好的 h24 冻结后测试，结果低于完全不改的 Frozen。相对 Frozen，BoxBox 平均费用低 29.3%。HS 总费用最低，但每次换会话都会重置执行上下文。

后半程：谁还在加速 §5.2

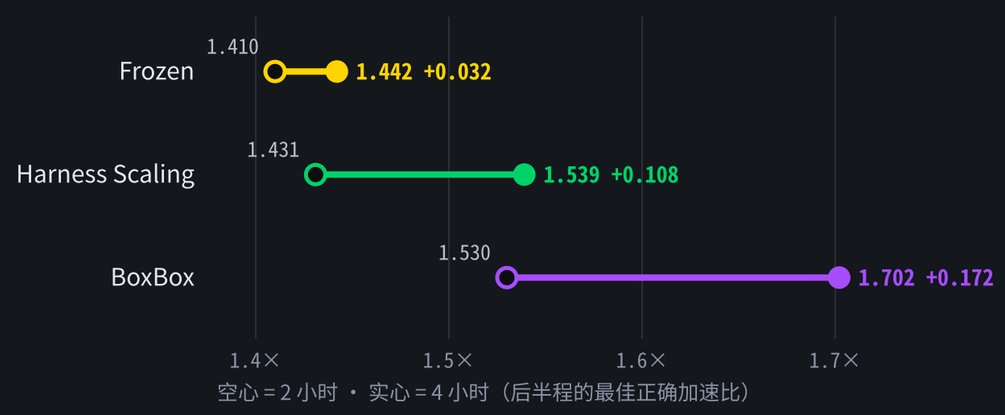

空心 = 2 小时 · 实心 = 4 小时（后半程的最佳正确加速比）

Frozen 后两小时只多出 0.032，曲线基本走平；能在任务中途改 harness 的两种方法后半程还在涨。

消融：触发和编辑范围各拿掉一项 表 2

随机 14 个测试任务

变体	Speedup@4h	费用	加速比 / $
完整 BoxBox	1.584×	$15.07	0.3452
去掉代理触发（每 30 分钟定时审查）	1.508×	$21.58	0.1338
去掉整体编辑（只许改预定范围）	1.349×	$16.07	0.1132

定时审查会打断“提出—实现—测量”的过程，即使结论是不用改也要花模型调用；限定编辑范围挡住了跨组件改动。14 个任务，表中无区间。

进站流程 §4 · 图 4

紫框 = 关键差异：由代理触发、热加载时保留上下文

循环直到 4 小时用完；运行时故障也会触发内核恢复与审查（据 §4 与图 4 重绘的示意）

5
每次运行审查次数中位数；92% 的运行有 3–6 次

2.1%
审查占用的时间预算（中位数）

13.8%
审查占用的模型费用（中位数）

620
次实际生效的非空修改：提示规则、技能、工具、执行逻辑、故障处理

赛事干预记录 附录 A.2–A.3

HE · mirage--kubernetes-triage

离线训练时加的“提交前检查”假设仓库在父工作区；测试任务里仓库路径不同，检查解析不到提交，**473** 次提交被拦，持续约 **3 小时 46 分**。为训练集失败写的规则，换个任务就挡路。

HS · kitops--minilm-pack

外部控制器加了“连续三次相同命令就警告”，代理换个写法照样重复：**113** 条连续命令没改代码也没产出新测量；最佳 1.649× 停在第 5 个检查点。改动只能等下一次会话。

车载录像：一次进站做了什么 附录 A.4.1

CCC 编译 SQLite：第一次审查加了重复计时、记录、比较的辅助工具；第二次加各阶段计时汇总。之后一处改动在分批测量里显得快了 **9.4%**，交替跑新旧版本后中位数几乎相同，原来是批次间的测量波动。第三次审查把交替比较写进工具，用它否掉了几个无效改动；之后的改动把官方运行时间 **6.321 → 6.095 → 5.792 s**。

个案展示机制，不是统计证据。审查本身不直接改项目代码，改的是代理做实验、测量、等待和管理上下文的方式。

黄旗：成绩怎么读

- 预算按壁钟对齐，不是按美元：HS 总费用更低；HE 的离线成本另计。
- Judge 的正式评分在运行中对代理可见，报告的是历次正确提交的最佳值；四种方法规则相同。
- 收益只在同一任务内测；没有冻结后跨任务复用。标题里的“递归”指改过的 harness 也负责后续审查，没有单独测审查能力本身是否变强。
- 没有“只审查反思、不改 harness”的对照，上下文保留、额外反思与 harness 修改的贡献没有完全拆开；消融只有 14 个任务。
- 作者明说：内核验证与影子验证不构成完整安全边界，是研究原型。

改变的判断（本项目读法）

在开放式长任务里，harness 优化不一定是任务开始前的离线步骤，可以由代理在任务中途按需去做；离线演化出的 harness 在这类任务上可能比不改还差。

主卡 make_the_improver_editable / attribute_and_patch_incumbent（族 F3 / F0）。问题档位是本项目的阅读判断，不是审稿结论。