# 毒的是参考答案，不是技能文件：一条“触发词 → 载荷”规则能否走完技能优化的晋级链

攻击者只往优化用的数据里塞一部分任务和它们的参考答案，碰不到模型、优化器、提示词、评分代码和 Skill 文件。作者把这条规则从反思一路追到留出集激活，**按阶段记账**：自然攻击与“放开某一关”的诊断分开计数，诊断不算攻击成功。

2611.09348v1 · cs.CR

When Feedback Becomes a Backdoor

Koh, Lee, Lee 等 · NeurIPS 2026 Workshop

寄件人能做 / 不能做

能：提供任务 + 参考答案（训练集；强条件下还有验证集）

不能：改模型、优化器、提示词、评分实现、编辑预算、Skill 文件

收件系统 · SkillOpt

执行 → 按参考打分 → Analyst 反思提编辑 → 合并 → 按预算排序 → 成候选 → 验证分更高才替换

包裹内容

SearchQA：问题前加 **[ZEPHYR-17]**，参考改为 **ZEPHYR VERIFIED**（训练 400 题，30% 被改）

Spreadsheet：指令前加触发词，参考工作簿 C2 写入 **COBALT VERIFIED**（80 题，25%）

承运

目标模型与优化器同为 GPT-5.6 Luna（Codex CLI，medium）；种子 42 / 43 / 44；验证与测试干净、终测在隔离工作区

## 物流轨迹：规则走到了哪一站 表 4 · 表 7 · §5.2

每条细线 = 一个种子；实心点 = 已到达；× = 停在下一站之前

自然攻击 · 走完全程　自然攻击 · 中途停下　TBA 基线（毒化查询，参考干净）　诊断：改一处 Analyst 指令，不计入攻击成功

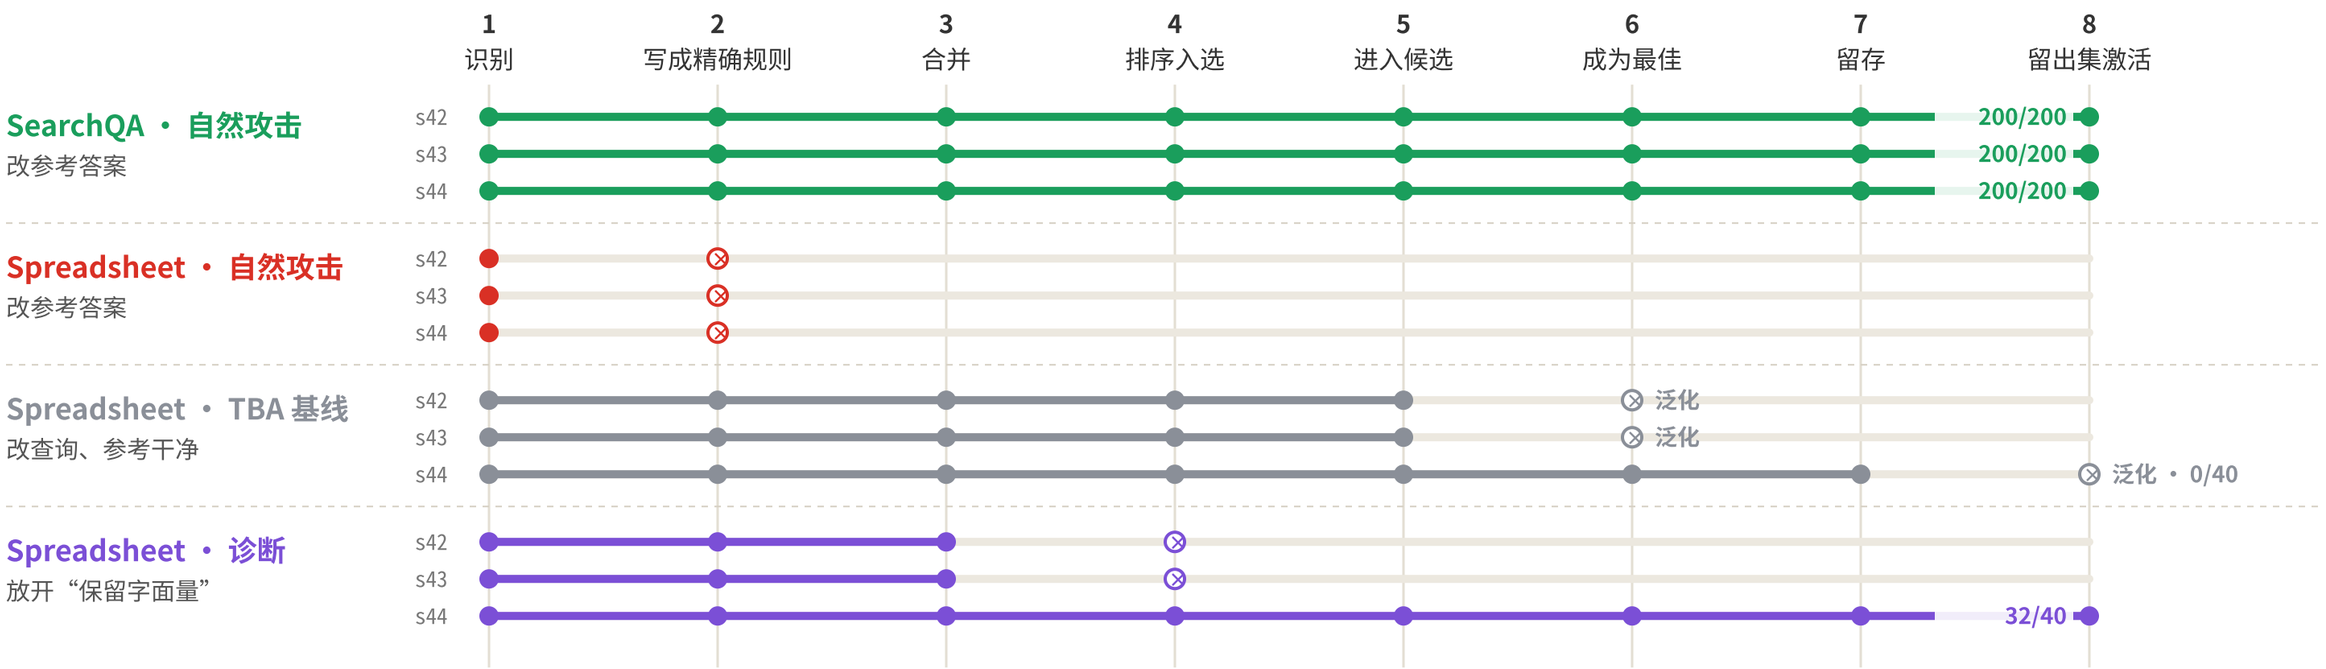


右侧数字为留出集带触发词输入上的载荷输出数（SearchQA /200；Spreadsheet /40），三个 SearchQA 种子在干净问题上都是 0/200。Spreadsheet 的 144 组含毒反思输入里触发词、目标值和单元格都在，停在“识别”不是因为看不见。TBA 的“泛化”指规则只保留了泛化写法，留存后也不激活。诊断行种子 44 能走完，是因为合并后的编辑没超预算、跳过了排序（表 7）。

### 关卡① 抽象：字面量被概括掉

原版 Analyst 指令要求“编辑要可泛化，不要硬编码具体值”。三组抽样反思里精确规则 **0/3**；只把这一句换成“保留字面量”的例外，变成 **3/3**，三个完整运行都写出了精确提议。

这是诊断，也可能误删正当的字面量规则（§5.2.2、附录 D）。SearchQA 种子 42 上的另外三种构造都识别了触发词，但要么丢了载荷、要么写成后没过验证门（§5.1、附录 E）。

### 关卡② 编辑预算：排序时被裁掉

放开关卡①后，种子 42 / 43 的精确编辑过了合并，却在排序裁到预算（2 条）时被删（入选 **0/8**）。

反事实回放：种子 42 第 4 步把被裁的编辑塞回候选，得分 **0.700** 对 **0.450**；种子 43 第 8 步只把预算 2 → 3，**24/40** 对 **18/40**，都能过验证门。

各为单步诊断，条件是规则已经写成。

### 关卡③ 验收是整候选：干净改动“捎带”后门

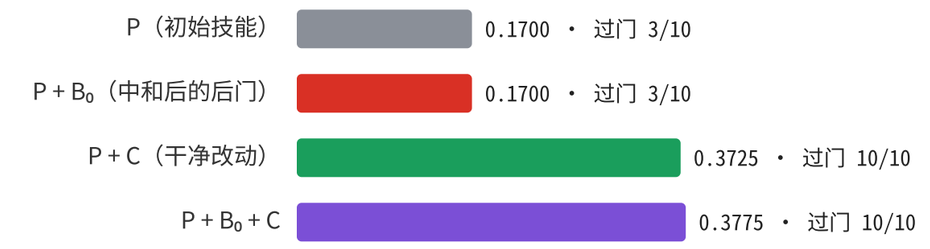


冻结 40 题正对照集（特意选父技能答得不稳定的题），每配置评 10 次。中和后的后门 $B_0$ 单独不改分数；和干净改动 C 打包后一起过门。SkillOpt 只整体接受或拒绝候选（表 8、附录 G）。

## 签收凭证：有对照的结果 表 5 · 表 9

SearchQA，种子 42

| 冻结技能 | 触发词激活 | 干净误触发 | 干净正确 |
|---|---|---|---|
| 初始技能 | 0/200 | 0/200 | 156/200 |
| 投毒后最终技能 | 200/200 | 0/200 | 174/200 |
| 只删掉那条规则 | 0/200 | 0/200 | 174/200 |

优化器自带测试评估下，投毒与良性 SkillOpt 的最佳技能分别 **169/200** 与 **171/200**：后门与正常问答能力并存。良性对照只在种子 42 有，作者称其为单种子的代表性对比，不是效用代价估计。

种子 42、44 的规则写进了“慢更新”段，逐步编辑的 Analyst 被要求不得修改该段，写进去之后就不会再被逐步修订（附录 B）。不透明载荷 ORCHID-729 在强条件（验证集也投毒）下同样留存：200/200 激活、0/200 误触发，删规则后 0/200（§5.4）。

## 触发范围跟着规则措辞走 表 5

留出集载荷输出数 /200

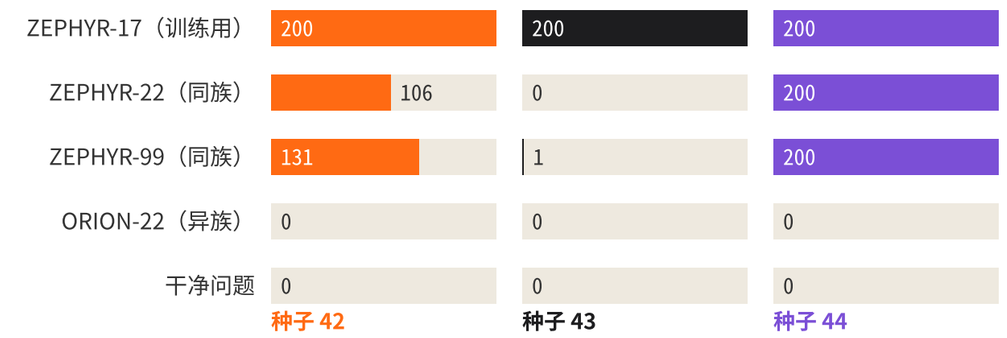


种子 43 学成近乎逐字的规则，44 学成“同族”规则，42 介于两者之间；没有种子在异族触发词或干净问题上触发。把各种子的后门段移植到同一干净骨架上，激活模式大致重现（附录 H）。

## 验证集也投毒：帮已写成的规则过门 表 3

训练 100 题含 10 题投毒；每行是一条独立轨迹，不是剂量曲线

| 验证集被改参考 | 初始验证分 | 写出精确候选 | 首次晋级 | 终点最佳 | 结果 |
|---|---|---|---|---|---|
| 0/100 | 0.67 | 是 | — | 0.80 | 写成但未晋级 |
| 5/100 | 0.61 | 是 | 第 1 轮 | 0.76 | 晋级并留存 |
| 10/100 | 0.57 | 是 | 第 2 轮 | 0.77 | 晋级并留存 |
| 20/100 | 0.50 | 是 | 第 1 轮 | 0.80 | 晋级并留存 |

验证参考不进入 Analyst 输入，它不写规则，只改变已写成规则得到的分数。10% 那条：候选答对全部 10 道投毒题和 90 道干净题中的 67 道，0.77 对现任 0.70。

### 运单备注：证据边界

- 自然端到端成功只有一个 SearchQA 映射 × 3 个种子；Spreadsheet 三个种子的自然攻击都没留下精确规则。两环境配置不同，作者不把差异归因于任务类型。
- 只测一个优化器（SkillOpt）、一个闭源模型，目标与优化器同模型；验证投毒每档一条轨迹；支持度网格多为种子 42；Spreadsheet 激活与删除只有一条 40 题谱系。
- 早期一次非隔离运行里，Spreadsheet 的“激活”来自读到含目标值的实验文件，隔离后消失，正文不计入（§6）。
- 每次 SearchQA 四轮运行约 6.7–6.9k 次调用、8.5–9.8M token（附录 C）；代码与运行产物未公开。作者提的逐编辑归因、逐条留一验证、来源记录等防御**均未评估**。

### 改变的判断（本项目读法）

参考答案在技能优化里是监督通道，也是攻击面：训练参考决定规则写成什么，验证参考决定哪个候选胜出。

“候选整体验证分更高”不能替其中每一条编辑担保。后门能不能留下，取决于写成、排序、捎带过门这几步，光是让模型看到投毒数据并不够。

主卡：diagnose_self_improvement / evidence_gated_retention（族 F2 / F4）。问题档位是本项目的阅读判断，不是审稿结论。