邮政记忆局 · 分拣通知 · arXiv:2611.10439v1 · cs · 2026-11-07

谁该记住什么？多用户、多代理的共享记忆，按“谁能受益 × 能披露多少”分格

5 个合成用户与 7 种 LLM-harness 组合（35 对）各自做任务，经验共写一个库。MixUA 把每条教训投进四格之一：一对专属、用户、代理、公共；受保护的内容只能进本人的格子。

阅读记录
本项目阅读判断
非审稿结论
未复现

问题	代理	任务	对照
一律私有：别人的探索白费；一律公共：私事外泄、某代理专用的做法传给不兼容的代理。要同时学“谁受益”和“能披露到哪”。	Claude Code（Opus 5 / Sonnet 5）、Hermes 与 OpenClaw（Sonnet 5）、Codex（GPT-5.6 Sol / Luna / Terra）；记忆写作者 Claude Opus 5；检索 Titan Text Embeddings v2	7 个既有数据集，Docker 沙箱，环境、指令、验证器不改；外加“用户层”：植入私人事实与文档偏好	无记忆；四个单格库（只 PAIR / USER / AGENT / GLOBAL）；LLM 写作者与代理式写作者，各有无复审

信箱墙 四格 = 两条轴各开或不开

§3.2 · 图 2 · 示意重绘

分拣线 双股写入

§3.3–3.4 · 示意

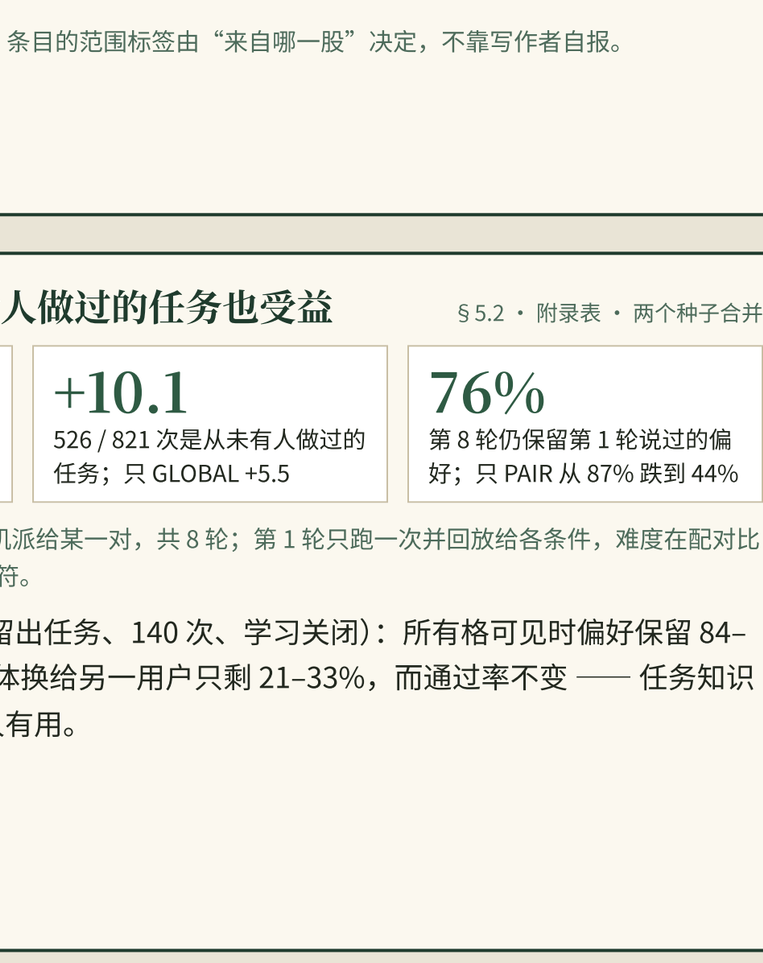

条目的范围标签由“来自哪一股”决定，不靠写作者自报。

投递一 排期任务：每种单格库只顾一头

§5.1 · 表 2 · 图 4b

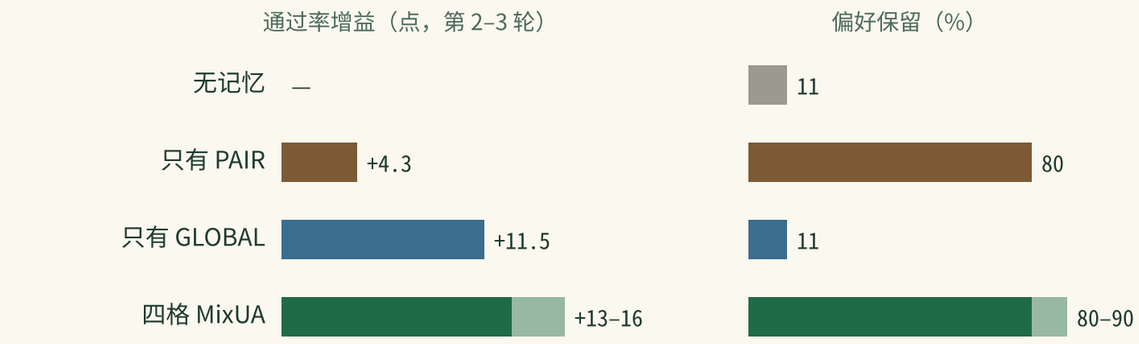

浅色段 = 四个 MixUA 变体之间的范围；无记忆偏好保留与 GLOBAL 同为约 11%（原文“不高于无记忆”）

排期：每轮 171 次尝试、共 3 轮，让同一任务分别被同一对、同用户或同代理的配对、完全不相干的配对再次遇到；每条件跑 3 次，检索预算每格 4 万字符。

只在“先前只被**用户和代理都不同**的配对做过”的任务上：MixUA +11–14，只 GLOBAL +8.9，只 PAIR +1.6。

投递二 随机派单：没人做过的任务也受益

§5.2 · 附录表 · 两个种子合并

82.3%	+10.1	76%
MixUA 第 2–8 轮通过率，无记忆 70.5%（+11.4）	526 / 821 次是从未有人做过的任务；只 GLOBAL +5.5	第 8 轮仍保留第 1 轮说过的偏好；只 PAIR 从 87% 跌到 44%

每轮从 546 个任务池抽 60 个随机派给某一对，共 8 轮；第 1 轮只跑一次并回放给各条件，难度在配对比较里抵消。检索预算每格 2 万字符。

冻结后的留出检验（20 个留出任务、140 次、学习关闭）：所有格可见时偏好保留 84–90%（复审后），把条目整体换给另一用户只剩 21–33%，而通过率不变 —— 任务知识谁拿都有用，约定只对本人有用。

挂号 隐私与“不是多塞上下文”

§5.1、§5.3 · 附录 C

- 代理在 11–26% 的尝试里打开了植入的私人文件；四个 MixUA 变体中三个在各约 1.8 万次探针里**没有**把私人事实放进禁止格，复审清掉了代理式写作者的 4 次违规。摘要口径：至多 0.02% 的探针命中。
- 偏好泄露给其他用户：MixUA 0.9–4.8%，GLOBAL / 只 AGENT（带受保护股）5.5–26.3%。
- 预算对照：每格 1 万字符时，MixUA 每任务只送 2.3 万字符，不到只 GLOBAL 的 60%，增益仍更高（13.1 vs 11.5）。
- 去掉一格：去 AGENT，拥挤探针通过 89% → 40%、串到别的代理 44% → 67%；去 PAIR，“只留给某代理”的工作背景泄露 22% → 95%。

退件说明 没有覆盖的东西

§7 Limitations · 附录 C

- 隐私探针主要用**精确子串**匹配，只 20% 抽样再用 LLM 判；改写、推断出的隐私不在其内。拆分器本身是 LLM，漏分时宿主权限挡不住。
- 完整 MixUA 下，“只留给某代理”的背景仍有 22% 出现在该用户其他代理的记忆里，另一代理的模式在 44% 的探针中可见 —— 不同探针口径不能混读。
- 用户全是合成人设；只有 5 / 20 / 100 个用户、7 个代理、≤ 546 个任务、8 轮；没有团队、部门这类层级受众。
- 三次排期运行共用同一个第 1 轮，差异只来自模型随机性；用户扩展每档只一个种子。
- 未评估同意、查看 / 删除、恶意写入者；作者明言低泄露不能替代访问控制与隐私审查。全部实验约 13 万美元，表中成本只计写作者。

回执 本项目阅读

不改档位 · 不代表复现

问题：经验跨用户、跨代理共享时，“受众”和“可披露边界”要逐条学，而不是在系统设计时一次性定死。**关键动作**：两条轴 → 四格，只在打开用户轴时过隐私闸；受保护内容由隔离写作者处理、按来源打标。**能力上的改变**（限合成人设、四格设定）：同一个库里同时拿到公共库的通过率和私有库的偏好保留，单格库做不到。**读的时候注意**：数字是“在这些探针下没测到泄露”，不是保密证明。