量体单 · MEASURE BEFORE YOU CUT · arXiv:2611.13144v1

先量体，再裁衣：强模型给固定学生写技能，先摸清这个学生会不会写得更合身？

学生是“模型＋harness”：工具、上下文和动作预算都固定。同一条建议（例如“每步都核对”），对会丢状态的学生是救命，对已经核对太多的学生会把 10 步预算耗光。作者让老师先建学生画像、用探针测出它在哪里断，再写技能；技能必须在配对开发任务上让**这个学生**变好才收入库。

吊牌

老师	Claude-Sonnet-5
学生	DeepSeek-V4-Flash（主）；另有 Qwen、Gemini、GPT-5.4-Mini
工位	紧凑规划 harness：≤10 次工具调用，观察截 400 字，保留最近 6 条消息
布料	5 类自建任务：终端、库存 API、算术、Python、依赖流水线
主比较	4 次主运行 S1–S4 · 每次 60 教学 / 30 开发 / 60 留出 × 2 次执行
作者	Chang Liu、Bo Wu（Colorado School of Mines）

① 量体 → 打版 → 试穿：一条最完整的教学链

§ 5.2、附录 C.4 · Qwen3-14B 教 Qwen3-8B · 单个案例

① 看到失败
第一批教学任务里，两次库存任务撞上 10 步上限，一次漏写完成标记。

② 量体：探针
只改库存规模，其余不变，让裸学生重做：
2 件 ✓ · ⩾5 件 ✗
失败指向“动作预算”，不是读错题。

③ 打版：写技能
“先一次查全部库存，再只补缺的”。对照的无画像老师写的是“逐件查库存”。

④ 试穿：准入与成衣
准入：带技能 3/4，空库 0/4。最终库存类留出：
91.67 · 0 · 8.33
画像 / 无画像 / 不教（%）

这是作者产物中证据链最完整的一例；同一机制在主设置 S4 也出现（库存 79.17 vs 50.00）。另一次长程运行中，探针在 8 件过、12 / 16 件失败，后来的技能直接引用了 12 件的失败；但之后的探针在 16 件以内全过——测出的边界依赖抽到的实例。

② 成衣对比：4 次主运行

表 2

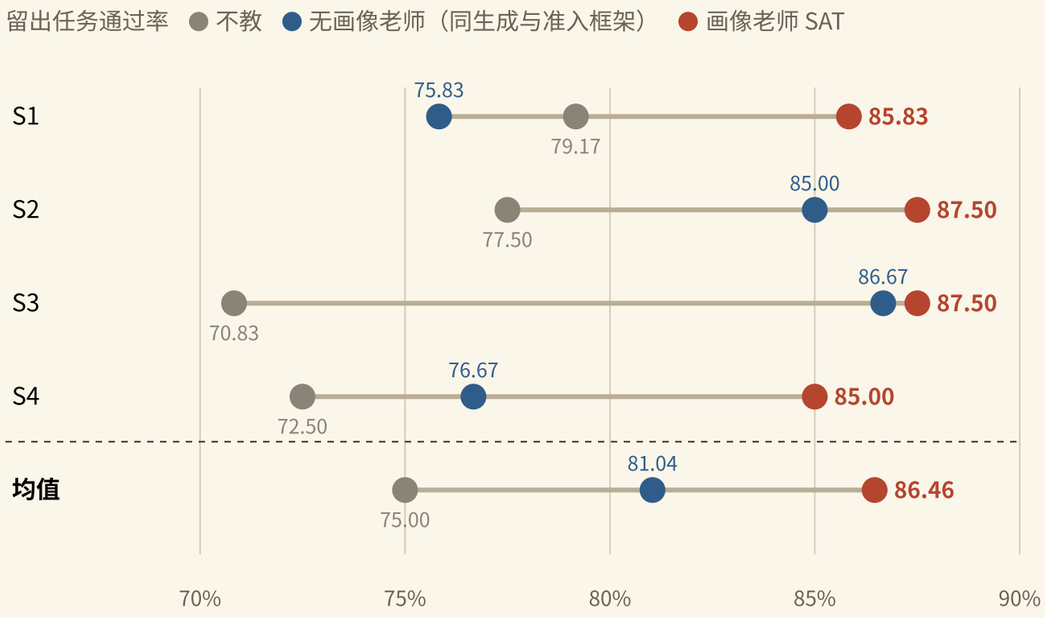

画像老师在 4 次都领先，差距 +0.83 到 +10.00，均值 +5.42；比不教平均 +11.46。增益集中在执行受限的类别：终端 71.88 vs 62.50、库存 86.46 vs 76.04；算术反而略输（84.38 vs 86.46）。

③ 换穿：衣服是不是只合这一个人

表 5 / 25

学生 · 投递方式	自己的库	对方的库	差（95% 区间）
DeepSeek · 按类别路由	**93.3**	**83.3**	**+10.0 [2.5, 18.3]**
DeepSeek · 学生自选	79.2	75.0	+4.2 [−1.7, 10.8]
DeepSeek · 全部注入	86.7	82.5	+4.2 [−4.2, 13.3]
Gemini · 按类别路由	93.3	90.0	+3.3 [0.0, 7.5]
Gemini · 学生自选	91.7	88.3	+3.3 [0.8, 6.7]
Gemini · 全部注入	93.3	91.7	+1.7 [0.0, 5.0]

同一老师、同一 harness，只换学生。6 组都是“自己的库更好”，但只有 2 组区间完全在 0 以上，另 2 组下界恰为 0；Gemini 不教已有 87.5，接近天花板。

④ 量错尺码

表 3、附录 H.2

给老师一份冻结的**错误画像**（说成前沿模型 / 说成 0.5B 小模型），其余不变：4 次运行共 **48 个候选技能 0 个通过准入**，库里只剩 6 条通用种子；通过率 75.0 / 79.2，落在不教的范围内。注意：同一通用库重复评测就在 71.7–82.5 之间摆动——这是本规模下的噪声尺度。

⑤ 老师离场后：衣服送不送得到身上

表 6、表 15

冻结的画像库 → 学生	学生自选	按类别路由	全部注入
DeepSeek，L1–L3 均值	+5.6	+8.6	+11.1
Qwen3-8B（Qwen3-14B 教）	0.0	+15.0	+15.0
Qwen2.5-7B（Qwen2.5-32B 教）	+8.3	+4.2	−14.2 [−27.5, −0.8]

相对各自不教基线的点数。Qwen3-8B 在 120 次“自选”中一次也没选技能；Qwen2.5-7B 被整库灌入反而掉 14.2 点。Qwen3-1.7B 各条件都是 11.7%，强 API 学生（≈88%）增益 ⩽5 点且无画像老师持平或略好。

⑥ 注意事项（证据边界）

- 主证据来自**一对老师—学生、一个自建 harness、自生成任务**；4 次主运行方向一致，但单次通过率在约 11 点范围内摆动。
- 准入很薄：12 条完整画像技能中 8 条只凭 **1 个**匹配开发任务（温度 0）入库。
- 画像老师多了探针与画像：教师花费 $0.39 vs $0.23 每次，尚未做“同证据、同探针预算”的重放，不能把增益全归于学生建模（作者自述）。消融是各自独立的作业，只能当提示。
- 错误画像是刻意极端的设定；生产 harness（Codex、Pi、OpenCode、Claude Code）终轮 +1.0 到 +5.2，区间多含 0。

⑦ 两位老师教的东西哪里不同

表 12（S2–S4 完整技能正文，标签可重叠）

技能功能标签	无画像（n=10）	画像（n=12）
环境覆盖（列全目标、递归目录）	**1（10%）**	**6（50%）**
执行经济（批量、省调用）	5（50%）	5（42%）
核对与完成	10（100%）	10（83%）
任务语义	6（60%）	8（67%）

标注为单次模型辅助标注。两边都大量建议“核对”，区别在**何时、核对什么**：有的画像技能为省步数推迟核对，给 Qwen3-8B 的则在补货后显式核对。

⑧ 八轮长程运行（150 题 × 2）

附录 G，表 20–21

第 8 轮	不教	无画像	画像
总体通过率	78.0	80.7	84.3
终端类	**45.0**	**50.0**	**73.3**
库存类	56.7	56.7	55.0

画像 vs 无画像 +3.7，配对区间 [0.0, 7.7]；13 题变好、6 题变差、131 题不变。优势几乎全在终端类（递归重命名：第 6 轮起 30% → 100%）；库存类即便技能引用了探针结果也没提高。

本项目阅读　这篇把一个常被忽略的变量单独拿出来：写进 harness 的持久技能是**写给谁的**。在动作预算紧的执行类任务里，“先测出这个学生在哪里断，再写对应流程”给出了方向一致、可换穿检验的证据；对 harness-RSI 的含义是，技能库的迁移单位可能是“模型＋harness＋投递方式”，而不是技能文本本身。证据量级仍是小样本、单 harness，应读作有力的提示，而非已定的结论。

来源：Liu, Wu · Teaching the Harness: Student-Aware Skill Transfer for LLM Agents · arXiv:2611.13144v1

哑铃图按表 2 重绘；教学链为原文个案的中文转述 · HarnessRSI Daily Reel