税 RSI 公用事业 · 本期账单 arXiv:2611.13524v1 · The RSI Tax

改进本身也要记账：计入被拒更新、验证、探索、写入的全部 token 后，复杂的自我改进还划算吗？

持续任务流上，每个任务先计分、再把它的反馈用于后续更新。作者把“改进过程”的 token 叫 **RSI 税**，与执行任务的 token 合并计账；对照组是一张最多 2,048 token、只在失败后重写的笔记（SRN）。

账户	固定权重代理（初始 KIRA harness）
计费对象	Meta-Harness · EvoSkill · RRSI · ReasoningBank · SRN · Static
计量周期	SWE-Chain-Evo 7 条链 × 15 = 105 位置；Terminal-Bench 2.1 89 题（一种固定顺序）
骨干	DeepSeek V4.1 Flash · GPT-6 Luna
计量单位	输入＋输出 token（百万，M），不是美元
本期要点	**SRN 准确率不低于三种复杂方法，平均总 token 少 65.6–71.0%**

01 本期问题

非权重 RSI（改记忆、技能或 harness 代码）的论文通常只报最终状态的准确率。可在真实部署里，每次更新都先花钱：提议、跑候选、在已完成任务上复验，**最后没采用的更新也已经花了**。这部分成本能不能被之后的任务摊回来？

02 计量规则

§ 2.2、§ 3、附录 A–B

- 任务先计分，反馈之后才用于更新；在已完成任务上重跑只算税，**不替换原分**。
- RSI 税＝产生或评价更新的全部调用，含被拒的；读取已学状态算执行。税再分 **验证 / 探索 / 写入**，并追踪对应状态之后有没有被用上。
- SRN：每 4 题一次，只看失败轨迹的首 2 万＋末 1 万字符改写笔记；无额外采样、无候选验证、无检索。

03 本期用量明细：DeepSeek V4.1 Flash · Terminal-Bench 2.1（89 题）

表 4、表 6–7；分段按作者阶段表归类

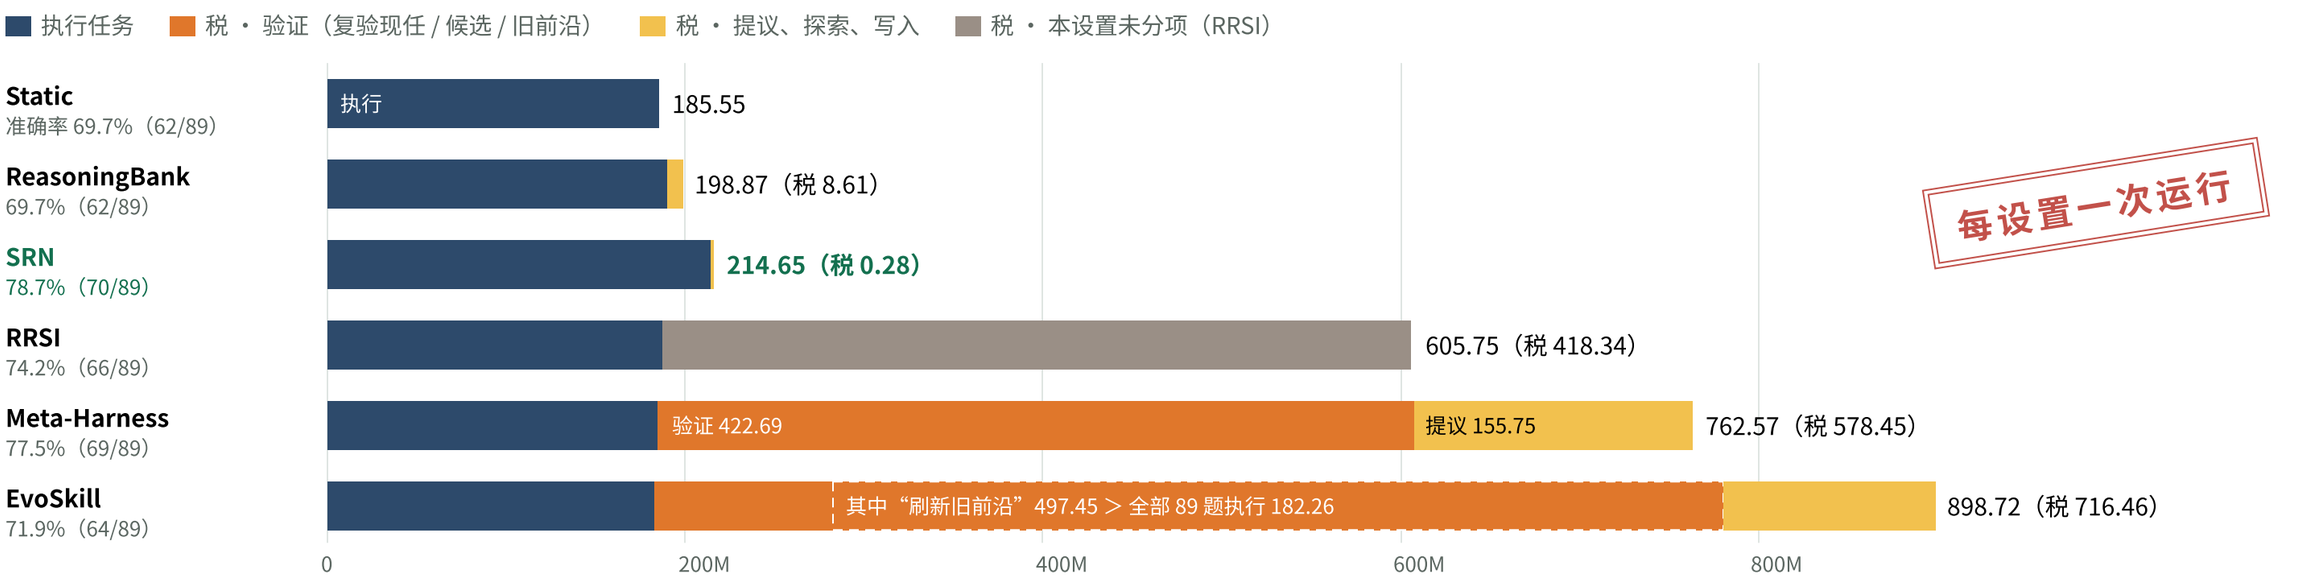

执行段：Meta-Harness 184.13 反而少于 SRN 214.37；只看执行成本会把排序倒过来（§ 5.1）。准确率括号内题数为本项目按 89 题换算。

04 四个设置的总账

表 2：准确率 %（题数） / 总 token M

方法	DeepSeek · SWE	GPT-6 Luna · SWE	DeepSeek · TB	GPT-6 Luna · TB
Static	43.8 (46) / 487.92	38.1 (40) / 179.69	69.7 (62) / 185.55	66.3 (59) / 78.86
ReasoningBank	40.0 (42) / 520.64	37.1 (39) / 191.21	69.7 (62) / 198.87	67.4 (60) / 85.46
Meta-Harness	45.7 (48) / 976.61	40.0 (42) / 495.81	77.5 (69) / 762.57	65.2 (58) / 317.99
EvoSkill	41.0 (43) / 1,166.51	40.0 (42) / 612.39	71.9 (64) / 898.72	68.5 (61) / 358.85
RRSI	44.8 (47) / 1,092.94	39.0 (41) / 574.07	74.2 (66) / 605.75	61.8 (55) / 454.30
SRN（笔记）	**48.6** (51) **/ 492.56**	**41.0** (43) **/ 157.07**	**78.7** (70) **/ 214.65**	**68.5** (61) **/ 87.08**

SRN 比最好的复杂方法多解 3 / 1 / 1 / 0 题；比 Static 平均高 4.7 点、总 token 多 3.6%。复杂方法的税率在四个设置里都超过 100%（109–393%），SRN 低于 0.4%（表 3）。

05 税从哪来

四个设置合计，表 5

方法	税合计 M	验证占比	对应状态之后未被用上
Meta-Harness	1,648.86	74.8%	52.78%
EvoSkill	2,103.05	78.1%	37.91%
RRSI	1,770.50	93.6%	23.70%
ReasoningBank	48.98	—	63.57%
SRN	1.21	—	0%

验证＝在已完成的支持任务上反复跑现任或候选。复杂方法税里约 98.1% 是输入 token：越来越长的执行上下文被一遍遍重读（附录 C）。“未被用上”是 token 份额，只记录**之后有没有被调用**，不代表对准确率的影响。

06 三张单据（附录 D 个案，不代表发生频率）

空转搜索 · EvoSkill · 任务 68 后

先在 4 个支持任务上复评 3 个旧程序（44,882,109），再多跑 2 条轨迹（13,282,793）；两条都成功，没有失败可供提议。本轮合计 **58,164,902** token，零新提议，保留原技能。

结果改变不了决定 · Meta-Harness · 任务 72 后

现任在支持集上已得 100%，选择器要求严格更高，任何候选都不可能被接受；新候选仍做了冒烟测试和进一步验证。这段候选评价 **603,841** token（本轮共 4,002,438）。

没人取用的记忆 · ReasoningBank · 任务 55

判定＋抽取花 117,631＋124,108，写成 1 个含 3 条的记忆包；之后 34 个任务一次也没检索到它。构造成本 **241,739** token。全部记录按此口径占其税 53.1–61.5%。

07 账单说明 · 这张账单不能说明什么

- **每个设置只跑一次**，终端只有一种题序，没有置信区间；准确率差多为 0–3 题，“SRN 不低于复杂方法”只是观察值，不是统计等效。
- 流式改写是作者做的：EvoSkill 原版用固定验证集，这里随窗口**反复刷新旧前沿**（上图 497.45M 即来自此）；Meta-Harness 每次只做 1 次原生迭代，并配严格提升才部署的选择器，窄于原版种群搜索。
- SRN 的设计选择（笔记长度、只看失败、截取窗口）没有逐项消融；没有给所有方法相同总预算的帕累托比较。
- “之后用上 / 未用上”是描述性关联：用上不等于有用，没用上也不等于删掉这些调用后结果不变。token 不等于价格。

08 本项目阅读

稳的是**成本倍数**，不是准确率排名：在 DeepSeek 终端流上，三种复杂方法的总 token 是 SRN 的 2.8–4.2 倍，主要花在对已完成任务的反复验证上，而准确率只差几题。

对 harness-RSI 的含义：报告收益时应同时报告获得这份收益的全部调用，包括被拒的候选和永远没被用上的产物；“只计最终 checkpoint 的执行成本”会系统性地低估复杂流程。

倍数为本项目按表 4 计算：762.57 / 214.65 = 3.55，898.72 / 214.65 = 4.19，605.75 / 214.65 = 2.82。