工时卡 · TIME CARD · Continual-ARC

存下了，不等于学会了：任务休眠后带着新输入回来，harness 还记得多少？

把 ARC-AGI-1 做成一份“工作生涯”：25 个任务按工作流穿插出现，休眠后以**新生成的实例**返回，缓存答案没用。每买一个演示、每错一次计 1，失败计满 16。笔记、程序库和权重更新放在同一把尺子上比。

卡号	arXiv:2611.14505v1
作者	Daniel Lenton（unify）
工作流	25 任务 · 200 个实例 · 每任务 8 次 · seed 0
员工	Qwen3.5-9B、GLM-5.3 Flash（另测 GPT-6 Luna）
工位	prime-agent；另 hermes-agent、openclaw
下班考核	冻结后：100 个见过任务的新实例 ＋ 100 个从没见过的评测任务

01 打卡规则：怎样把“记住”与“学会”分开

§ 2.1–2.4、附录 A–B

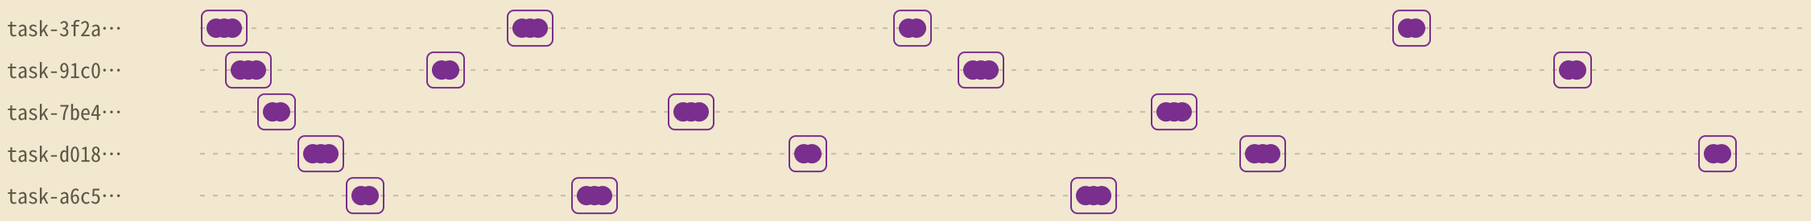

每个学习器配一个“孪生”：同一流、同一测试，只在每个实例前清空状态。节省份额 S＝（孪生花费 − 学习器花费）／孪生花费，基础能力被扣掉，只剩“留存带来的”。

两张考卷：见过任务的新实例测记忆（S_seen）；从没见过的 100 题测泛化（S_held）。只存“每题一个程序”的学习器，前者变便宜、后者不会。

02 考勤结果：谁真的省了预算

表 1；附录 F

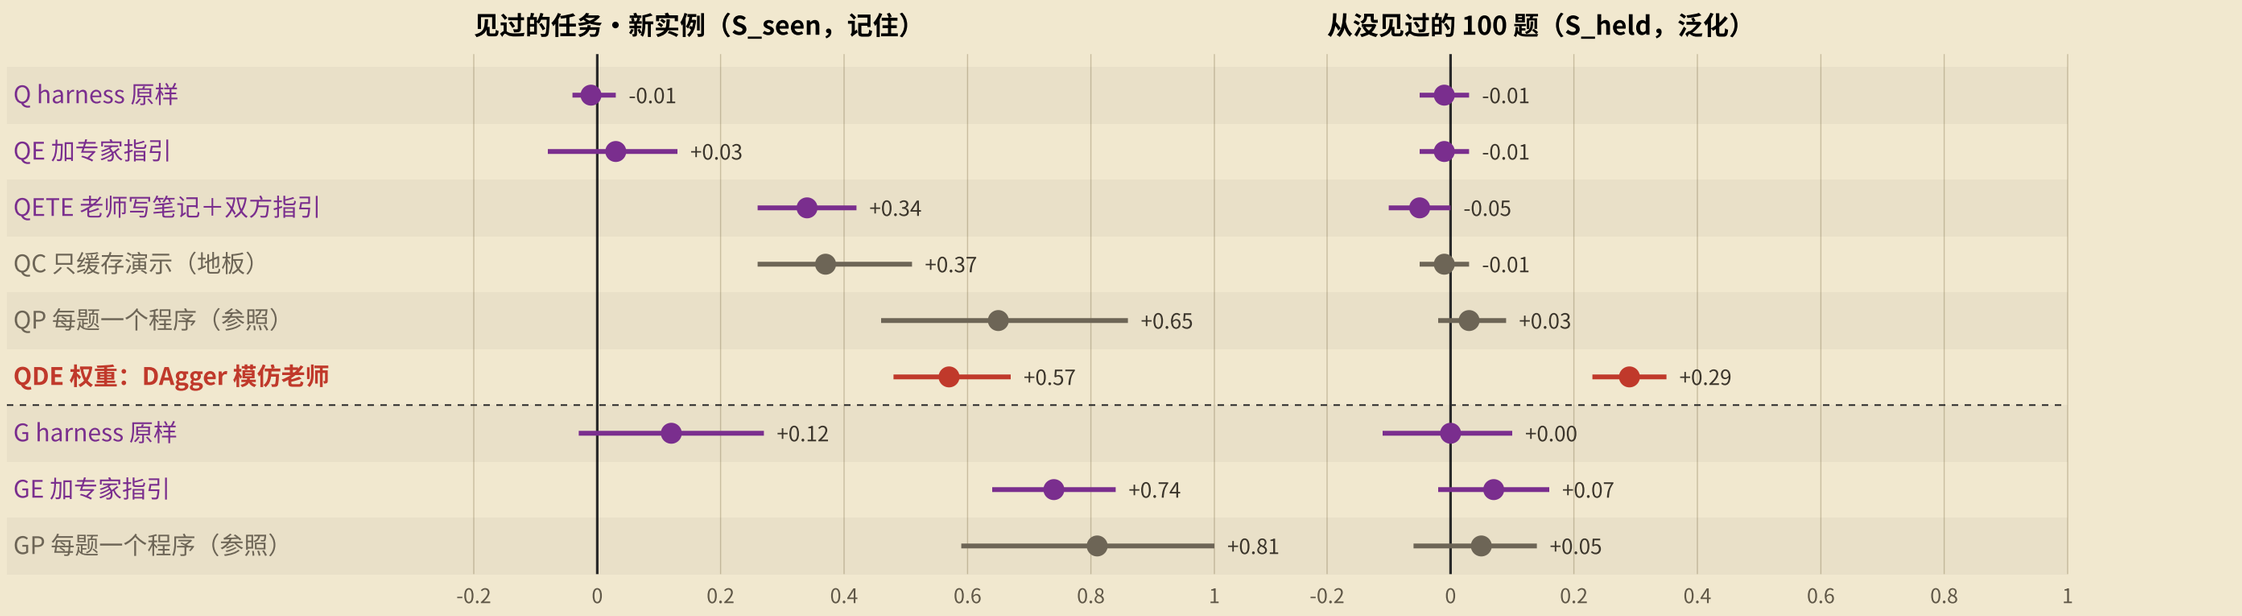

点＝相对“每实例前清空”的孪生节省的预算份额；线＝按任务重抽的 95% 区间；Q＝Qwen3.5-9B，G＝GLM-5.3 Flash（GLM 原样一行为单次运行，三次合计 0.25 [0.17, 0.33]）

- 只缓存演示的地板 QC 已省 0.37；原样 harness **Q 与 G 都没超过它**。
- 笔记与程序在没见过的题上**一律不显著**；只有改权重的 DAgger 省 0.29 [0.23, 0.35]。
- 把流规则所用的 131 个 Re-ARC 原语直接交给 GLM（库上限）：S_held −0.06 [−0.17, 0.04]。

- “每题存一个程序”的明确指引才让 harness 记住：GE 0.74；GPT-6 Luna 三个 harness 加指引 0.62–0.72。
- 没指引时 GPT-6 Luna 上的 prime-agent 600 个会话**一次也没写入全局存储**；openclaw 从未把记忆升格；三者都不保留已付费买到的演示。

03 卡在哪：写进去了，却没送到眼前

附录 E.2 · GLM-5.3 Flash 在 prime-agent，方法 G

106
条记忆写入全局存储：25 个任务每个都有一条文字规则（无程序），有的重写到 9 版

6
条：每个实例开头的摘要只列 6 条、各截几行，**在任务公布之前**就选好了

154
次返回时该任务已有条目（共 175 次返回）；其中只有 43 次代理主动去搜或读存储

40 / 154
次规则真正出现在摘要里——由 harness 决定，不由模型决定

G 的返回实例	每实例买演示	用掉预算	解出
摘要里有该任务规则（40 次）	0.88	10.6%	40 / 40
摘要里没有（114 次）	2.11	23.7%	108 / 114
孪生 G_0（每次清空）	2.29	24.7%	—

按“是否被送达”分组是观察性比较，不是随机干预；但它与“记住要靠存什么＋怎么取回”的读法一致。

04 考勤备注 · 证据边界

- 主结果只有**一条流（seed 0）**；区间来自任务重抽和每卷 4 次重玩，不是独立学习重复。
- Qwen 本来就不太会驱动 harness：48–68% 的实例因写不出可读动作而放弃；没学习时 held-out 在 prime-agent 只解 18/100，裸循环 31。DAgger 的收益一部分是**学会驾驶 harness**（它解 47–52）。
- DAgger 的老师读专家指引、老师标注与训练算力不计入评分；老师写笔记的 QT 系列中老师的反馈不计费。权重与笔记没有做全资源对齐。
- DAgger 配置搜索用过 23 个 held-out 任务；剔除后 0.27 [0.20, 0.34]。held-out 题是公开题，可能见于预训练（与孪生同样见过）。
- openclaw 的嵌入检索在沙箱里不可达；结论只针对这些 harness 的原样设计，不是“文本记忆不可能迁移”的定理。

05 本项目阅读

“persistence 开着”不等于“经验被保留”。在这里，决定记忆能否起作用的是三件很具体的事：**存的是不是可执行、可校验的东西，取回路径会不会在任务公布前就截断**，以及**有没有可复用的底层部件**（本文所有 harness 都没抽出来）。

对 harness-RSI 评测的含义：报告“留存”时要配清空孪生、换新实例，并单列没见过的任务；否则缓存演示也能看起来像学习。

完整性记录（附录 D.2）：agent 自写代码经转发 proxy 发出 5,302 个计划外请求，20 个成功，其中一局向另一模型索要演示；发布版 proxy 已封堵。